

Выполнил: Дмитрий Трифонов, 12-25РПм, 1 курс (2 семестр), Программная инженерия

Практическое занятие 1

Процесс Data Science: этапы 1–3

(постановка цели, сбор и первичная подготовка данных)

Инструкция студенту

- 1. Укажите **свой индивидуальный вариант** (по списку, выданному преподавателем).
 - 2. Выполняйте **все ячейки ноутбука по порядку**.
 - 3. Все текстовые ответы оформляйте **в Markdown-ячейках**.
 - 4. Все вычисления выполняйте **в коде**.
 - 5. В конце сформулируйте **итоговые выводы**.
-

Индивидуальные варианты

Вариант	Предметная область
1	Успеваемость студентов
2	Онлайн-обучение
3	Финансы предприятия
4	Банковские данные
5	Медицинские показатели
6	Производственное оборудование
7	Городской транспорт
8	Логистика
9	Розничная торговля
10	Социальные сети
11	Обращения граждан
12	Экология
13	Энергопотребление
14	Журналы событий

ЯЧЕЙКА 1 (Markdown)

Вариант и предметная область

Заполните поля ниже.

Номер варианта: 12

Предметная область: Экологический мониторинг состояния окружающей среды в регионе. Рассматриваются показатели загрязнения воздуха, температурный режим и уровень шума в различных районах города.

Краткое описание: В рамках работы рассматриваются данные с датчиков экологического контроля в крупном городе. Основное внимание уделяется трем параметрам: уровню углекислого газа (CO₂), уровню шума и географическому расположению датчиков (район). Эти данные позволяют оценить качество жизни и выявить зоны экологического риска.

ЯЧЕЙКА 2 (Markdown)

Формулировка цели анализа данных

Цель анализа данных: Провести первичный разведочный анализ экологических показателей региона для выявления закономерностей загрязнения воздуха и шумового воздействия, а также определить районы с наиболее напряженной экологической обстановкой.

Ожидаемая информация: Статистические нормы для CO₂ и шума, наличие аномальных выбросов (резких скачков загрязнения), сравнение экологической ситуации в разных районах.

ЯЧЕЙКА 3 (Code)

Импорт библиотек

Запустите ячейку.

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

plt.style.use("default")
```

ЯЧЕЙКА 4 (Code)

Формирование (учебного) набора данных

Для учебных целей данные формируются программно.
По структуре они близки к реальным табличным данным: есть временной признак, числовые показатели и категориальный признак.

Запустите ячейку.

```
In [2]: np.random.seed(42)

n = 200

# Генерируем данные для Экологии (Вариант 12)
data = pd.DataFrame({
    "Дата": pd.date_range(start="2023-01-01", periods=n, freq="D"),
    # CO2 в ppm (частиц на миллион). Норма ~400, в городе выше.
    "CO2_ppm": np.random.normal(loc=450, scale=50, size=n).astype(int),
    # Уровень шума в децибелах. Норма днем ~55-60.
    "Шум_дБ": np.random.normal(loc=60, scale=10, size=n).round(1),
    # Районы города
    "Район": np.random.choice(["Парковый", "Центральный", "Промышленный"], size=
})

# Добавим немного пропусков и выбросов для реалистичности (для этапа проверки ка
data.loc[10:12, "CO2_ppm"] = np.nan # Пропуски
data.loc[50, "Шум_дБ"] = 140        # Аномально громкий звук (выброс)

data.head()
```

```
Out[2]:
```

	Дата	CO2_ppm	Шум_дБ	Район
0	2023-01-01	474.0	63.6	Промышленный
1	2023-01-02	443.0	65.6	Промышленный
2	2023-01-03	482.0	70.8	Парковый
3	2023-01-04	526.0	70.5	Парковый
4	2023-01-05	438.0	46.2	Промышленный

ЯЧЕЙКА 5 (Markdown)

Первичный обзор данных

Ответьте на вопросы:

1. Сколько строк и столбцов содержит набор данных? **Размер:** 200 строк и 4 столбца.
2. Какие признаки являются числовыми? **Числовые признаки:** CO2_ppm (уровень углекислого газа), Шум_дБ (уровень шума).

3. Какие признаки являются категориальными? **Категориальные признаки:**

Район (местоположение датчика).

ЯЧЕЙКА 6 (Code)

Размерность и структура данных

Запустите обе ячейки и изучите результаты.

```
In [3]: data.shape
```

```
Out[3]: (200, 4)
```

```
In [4]: data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 4 columns):
#   Column      Non-Null Count  Dtype  
---  -
0   Дата        200 non-null   datetime64[ns]
1   CO2_ppm     197 non-null   float64
2   Шум_дБ      200 non-null   float64
3   Район       200 non-null   object  
dtypes: datetime64[ns](1), float64(2), object(1)
memory usage: 6.4+ KB
```

ЯЧЕЙКА 7 (Markdown)

Анализ структуры данных

- **Типы признаков:**
 - **Дата** — datetime64 (временной ряд).
 - **CO2_ppm** — float/int (числовой, непрерывный).
 - **Шум_дБ** — float (числовой, непрерывный).
 - **Район** — object (строковый, категориальный).
- **Возможные проблемы:**
 - В данных могут встречаться пропуски (**NaN**).
 - Возможны выбросы (слишком высокие значения шума или CO2), вызванные сбоем датчиков или реальными авариями.
- **Целесообразность:** Все признаки важны. **Дата** нужна для анализа динамики, числовые показатели — для оценки загрязнения, **Район** — для сравнения локаций.

ЯЧЕЙКА 8 (Code)

Базовые статистические характеристики

Запустите ячейку и изучите таблицу описательной статистики.

```
In [5]: # include=[np.number] говорит пандасу: "покажи статистику только для чисел"
# round(2) округляет числа до 2 знаков после запятой, чтобы было красиво
display(data.describe(include=[np.number]).round(2))
```

	CO2_ppm	Шум_дБ
count	197.00	200.00
mean	447.59	61.32
std	46.86	11.30
min	319.00	27.60
25%	414.00	54.00
50%	450.00	60.90
75%	475.00	67.05
max	586.00	140.00

ЯЧЕЙКА 9 (Markdown)

Интерпретация статистических характеристик

- **Средние значения:**
 - Средний уровень CO2 составляет около 450 ppm, что является типичным для городской среды.
 - Средний уровень шума ~60 дБ (сопоставимо с громким разговором).
- **Разброс (std):** Стандартное отклонение CO2 около 50 ppm показывает, что уровень загрязнения меняется умеренно, без постоянных экстремальных скачков.
- **Выбросы:** Максимальное значение шума (если видно 140 дБ) явно указывает на аномалию или разовое громкое событие, так как это болевой порог слышимости.

ЯЧЕЙКА 10 (Code)

Первичная проверка качества данных

Запустите обе ячейки.

```
In [6]: data.isnull().sum()
```

```
Out[6]: Дата      0
CO2_ppm    3
Шум_дБ     0
Район      0
dtype: int64
```

```
In [7]: data.duplicated().sum()
```

```
Out[7]: np.int64(0)
```

ЯЧЕЙКА 11 (Markdown)

Оценка качества данных

1. **Пропуски:** Да, есть пропущенные значения в столбце `CO2_ppm` (3 значения). Это требует обработки (удаления или замены средним).
2. **Дубликаты:** Дубликатов строк не обнаружено (0).
3. **Пригодность:** Данные пригодны для анализа, но требуют минимальной предобработки: необходимо решить вопрос с пропусками в CO2 и проверить аномально высокое значение шума.


ЯЧЕЙКА 12 (Code)

Визуализация распределений (гистограммы)

Постройте гистограммы для обоих числовых показателей и сделайте первичные выводы.

```
In [8]: # Гистограмма для CO2
data["CO2_ppm"].hist(bins=20, color='skyblue', edgecolor='black')
plt.title("Распределение уровня CO2")
plt.xlabel("Концентрация (ppm)")
plt.ylabel("Частота")
plt.show()

# Гистограмма для Шума
data["Шум_дБ"].hist(bins=20, color='salmon', edgecolor='black')
plt.title("Распределение уровня Шума")
plt.xlabel("Шум (дБ)")
plt.ylabel("Частота")
plt.show()
```



ЯЧЕЙКА 13 (Markdown)

Анализ распределений


- **Форма:** Оба распределения напоминают нормальное (колоколообразное), что естественно для природных и случайных процессов. Большинство дней показатели находятся около среднего значения.
- **Выбросы:** На графике шума может быть виден отдельный столбик далеко справа (около 140 дБ) — это подтверждает наличие выброса.
- **Практический смысл:** Стабильность формы говорит о том, что экологическая обстановка в целом предсказуема, но существуют редкие дни с повышенной нагрузкой.

ЯЧЕЙКА 14 (Code)

Временная динамика показателя

Постройте график изменения Показателя 1 по времени.

```
In [9]: plt.figure(figsize=(10,4))
# Используем CO2 для графика времени
plt.plot(data["Дата"], data["CO2_ppm"], label='CO2')
plt.title("Динамика уровня CO2")
plt.xlabel("Дата")
plt.ylabel("ppm")
plt.legend()
plt.show()
```



ЯЧЕЙКА 15 (Markdown)

Анализ временной динамики


1. **Тренд:** Явного тренда на рост или снижение за 200 дней не наблюдается, данные колеблются вокруг среднего значения.
2. **Колебания:** Видны регулярные случайные колебания (шум процесса).
3. **Ограничения:** Данные синтетические и не учитывают сезонность (зима/лето) или суточные ритмы (утро/ночь), которые важны для реальной экологии.

ЯЧЕЙКА 16 (Code)

Анализ категориальных данных

Постройте столбчатую диаграмму распределения категорий.

```
In [10]: data["Район"].value_counts().plot(kind="bar", color='green')
plt.title("Количество замеров по районам")
plt.xlabel("Район")
plt.ylabel("Количество записей")
plt.xticks(rotation=0)
plt.show()
```



ЯЧЕЙКА 17 (Markdown)

Интерпретация категориальных данных

- **Распределение:** Данные распределены по трем районам (Парковый, Центральный, Промышленный).
- **Баланс:** Распределение примерно равномерное (сбалансированное), что хорошо для сравнительного анализа.
- **Последствия:** Если бы был сильный перекос (например, данных из Промышленного района очень мало), мы не смогли бы достоверно оценить экологию самой загрязненной зоны. Здесь такой проблемы нет.

ЯЧЕЙКА 18 (Markdown)

Итоговые выводы по практическому занятию

1. **Достижение цели:** Цель достигнута. Мы успешно загрузили данные, провели первичный осмотр и выявили структуру экологических показателей региона.
2. **Важные характеристики:**
 - `CO2_ppm` и `Шум_дБ` — основные показатели загрязнения.
 - `Район` — ключевой разрез для аналитики (позволяет локализовать проблемы).
3. **Ограничения:**
 - В данных присутствуют пропуски (в `CO2`) и аномалии (выброс шума 140 дБ).
 - Временной ряд не имеет явной сезонности (так как данные синтетические), что упрощает картину.
4. **Дальнейшие шаги:**
 - **Очистка:** Удалить или заполнить пропуски в `CO2`, исключить или проверить аномалию с шумом.
 - **Анализ корреляций:** Проверить, растет ли уровень шума вместе с уровнем `CO2`.
 - **Сравнение:** Сгруппировать данные по районам и выяснить, какой из них самый "грязный" и "шумный".

ЯЧЕЙКА 19 (Markdown)

Переход к анализу внешних данных

В этой части работы мы переходим от программно сгенерированных данных к анализу реального файла мониторинга `ecology_air_quality.csv`. Наша задача — проверить, подтверждаются ли наши первичные выводы на реальных показателях, и выявить проблемы качества «сырых» данных.

ЯЧЕЙКА 20 (Code)

Загрузка и первичная проверка CSV

Здесь мы используем параметр `encoding='utf-8'`, чтобы правильно прочитать названия постов.

```
In [11]: # Загружаем реальный файл
try:
    df_real = pd.read_csv("ecology_air_quality.csv", encoding='utf-8')
    print("Файл успешно загружен!")
except:
    # Если utf-8 не работает из-за специфики Windows, пробуем cp1251
    df_real = pd.read_csv("ecology_air_quality.csv", encoding='cp1251')
    print("Файл загружен с использованием кодировки cp1251")
```

```
# Приводим даты в порядок
df_real['date'] = pd.to_datetime(df_real['date']).dt.date

# Смотрим на данные
df_real.head(10)
```

Файл успешно загружен!

Out[11]:

	date	station	pm25_ug_m3	no2_ug_m3	temperature_c	wind_m_s
0	2025-01-01	Пост_3	104.180599	NaN	14.8	0.2
1	2025-01-02	Пост_3	26.300000	37.3	21.8	4.7
2	2025-01-03	Пост_4	3.000000	16.8	26.7	3.2
3	2025-01-04	Пост_4	33.000000	19.0	15.4	2.8
4	2025-01-05	Пост_1	40.400000	44.5	16.2	6.3
5	2025-01-06	Пост_4	37.500000	41.9	18.5	3.7
6	2025-01-07	Пост_3	36.500000	33.7	13.5	3.9
7	2025-01-08	Пост_4	28.400000	24.3	20.9	0.8
8	2025-01-09	Пост_4	18.700000	6.8	19.4	2.8
9	2025-01-10	Пост_4	15.700000	28.1	14.6	1.5

ЯЧЕЙКА 21 (Code)

Сравнение статистик: Теория vs Реальность

Посмотрим, насколько реальные цифры отличаются от наших идеальных моделей.

In [12]:

```
# Статистика по реальным данным
display(df_real.describe().round(2))
```

	pm25_ug_m3	no2_ug_m3	temperature_c	wind_m_s
count	361.00	361.00	361.00	360.00
mean	24.52	29.12	14.93	3.56
std	12.41	14.97	10.39	2.07
min	3.00	5.00	-10.00	0.20
25%	16.30	19.70	8.40	2.30
50%	23.70	28.30	14.20	3.30
75%	31.90	37.00	20.30	4.60
max	104.18	125.62	81.79	16.79

ЯЧЕЙКА 22 (Markdown)

Анализ аномалий в реальных данных

На основе таблицы `describe()` из ячейки 21, проанализируйте реальные данные:

1. Температурный шок: В столбце `temperature_c` максимальное значение составляет 81.79°C. Для экологии региона это очевидная ошибка датчика (выброс).
2. Загрязнение PM2.5: Максимальные значения достигают 104.18, что значительно выше средних. Нужно проверить, разовое ли это событие.
3. Пропуски: Посмотрите на строку `count` — если она меньше общего количества строк, значит, в данных есть "дыры".

ЯЧЕЙКА 23 (Code)

Визуальный поиск взаимосвязей (PM2.5 и Ветер)

Проверим гипотезу: помогает ли ветер очищать воздух?

```
In [13]: plt.figure(figsize=(10, 6))
plt.scatter(df_real['wind_m_s'], df_real['pm25_ug_m3'], alpha=0.5, color='darkblue')
plt.title("Связь скорости ветра и концентрации частиц PM2.5")
plt.xlabel("Скорость ветра (м/с)")
plt.ylabel("PM2.5 (мкг/м3)")
plt.grid(True, linestyle='--', alpha=0.7)
plt.show()
```



ЯЧЕЙКА 24 (Markdown)

Интерпретация графиков и финальный итог работы

Выводы по реальным данным:

1. Очистка: В отличие от учебных данных, реальный файл требует серьезной очистки (минимум — удаление температуры 81°C и исправление пустых значений в NO₂).
2. Закономерность: На графике рассеяния (ячейка 23) мы можем увидеть, что при сильном ветре (высокие значения по оси X) концентрация пыли PM_{2.5} чаще всего падает. Это важный аналитический вывод.
3. Итог занятия: Работа с двумя типами данных позволила увидеть разницу между «стерильной» теорией и «грязной» практикой Data Science. Цель этапов 1–3 полностью достигнута.