

Самостоятельная работа

По дисциплине: «Системы обработки больших данных»

Вариант 12: Экология (Анализ экологических показателей региона)

Выполнил: Студент группы 12-25РПм, Дмитрий Трифонов

Дата: 11.02.2026 г.

Задание 1. Формулировка цели проекта Data Science

1.1. Предметная область и контекст

Экологическая обстановка в крупных промышленных регионах является критическим фактором, влияющим на здоровье населения и качество жизни. В настоящее время мониторинг состояния воздуха, воды и почвы производится автоматическими станциями, однако эти данные часто используются только для фиксации превышений ПДК (предельно допустимых концентраций) в моменте.

Проблема: Отсутствие глубокого анализа накопленных исторических данных не позволяет выявлять скрытые закономерности (например, влияние розы ветров на распространение выбросов от конкретных заводов) и прогнозировать ухудшение ситуации.

1.2. Цель проекта (Аналитическая задача)

Провести комплексный анализ исторических данных экологического мониторинга региона для выявления устойчивых сезонных и погодных факторов, влияющих на динамику концентрации вредных веществ (PM2.5, NO2) в атмосфере.

1.3. Ценность результата

Результаты анализа позволят:

1. Выявить районы с наиболее неблагоприятной экологической обстановкой.
2. Понять, при каких погодных условиях (ветер, температура) выбросы накапливаются в городе.
3. Предоставить аналитическую базу для принятия решений городскими властями (например, ограничение движения транспорта в безветренные дни).

Задание 2. Проектное задание (Problem Statement)

Параметр	Описание
Формулировка проблемы	Накопленные массивы данных с экологических постов разрознены и не анализируются в связке с метеорологическими условиями, что мешает проактивному управлению качеством среды.
Цель проекта	Объединить данные мониторинга и метеоданные для определения ключевых драйверов загрязнения воздуха.
Тип задачи Data Science	Diagnostic Analytics (Диагностическая аналитика) — поиск причинно-следственных связей и паттернов.
Ожидаемые результаты	1. Очищенный и объединенный датасет. 2. Отчет о корреляции между погодными условиями и уровнем загрязнения. 3. Карта "горячих точек" загрязнения по районам.
Критерии успешности	Выявлены и статистически подтверждены минимум 3 фактора, значимо влияющих на уровень PM2.5 (например, корреляция > 0.5).
Ограничения проекта	1. Возможные сбои в работе датчиков (пропуски данных). 2. Отсутствие доступа к точным данным о выбросах конкретных предприятий (коммерческая тайна).

Задание 3. Анализ источников данных

Для достижения цели необходимо объединить данные из гетерогенных источников:

Источник 1. Данные станций экологического мониторинга (Основной)

- Тип:** Структурированные данные (Time Series).
- Формат:** CSV / API (JSON).
- Состав:** Дата/время, ID станции, концентрации (PM2.5, CO, NO2, SO2).
- Релевантность:** Высокая. Это целевая переменная для анализа.

Источник 2. Метеорологические данные (Вспомогательный)

- Тип:** Структурированные данные.
- Формат:** API погодного сервиса (например, OpenWeatherMap) или архив CSV.
- Состав:** Температура, влажность, скорость и направление ветра, давление, осадки.
- Релевантность:** Высокая. Ветер и осадки — главные факторы рассеивания примесей.

Источник 3. Геоданные расположения постов и промзон (Справочный)

- **Тип:** Геопространственные данные.
- **Формат:** GeoJSON / Shapefile.
- **Состав:** Координаты станций мониторинга, границы промышленных зон и жилых массивов.
- **Релевантность:** Средняя. Необходима для визуализации и привязки данных к местности.

Задание 4. Анализ рисков доступа к данным

1. Технические риски

- **Риск:** "Зашумленность" данных дешевых датчиков (ошибки измерений, выбросы).
- **Последствия:** Искажение аналитических выводов (ложные тревоги).
- **Меры:** Применение алгоритмов сглаживания и фильтрации аномалий (удаление выбросов > 99 перцентиля).

2. Организационные риски

- **Риск:** Изменение форматов данных у поставщика (например, смена API).
- **Последствия:** Поломка пайплайна сбора данных.
- **Меры:** Разработка модульных скриптов загрузки с возможностью быстрой адаптации.

3. Правовые риски

- **Риск:** Использование данных, имеющих ограничения на коммерческое использование.
- **Последствия:** Невозможность монетизации или публикации отчета.
- **Меры:** Использование открытых государственных данных (Open Data) или лицензий CC BY.

Задание 5. Предварительная оценка качества данных

На этапе разведочного анализа (EDA) ожидаются следующие проблемы качества (на примере тестового набора `ecology_air_quality.csv`):

1. **Пропуски (Missing Values):** Датчики могут отключаться, создавая "дыры" во временных рядах.
 - *Метод решения:* Интерполяция по времени (заполнение средним соседним).

2. **Аномалии (Outliers):** Технические сбои (например, температура 81°C или PM2.5 < 0).
 - *Метод решения:* Фильтрация по физически возможным границам (Температура: -50...+50).
3. **Дубликаты:** Повторная запись одного и того же замера при сбоях сети.
 - *Метод решения:* Удаление полных дубликатов строк.
4. **Типы данных:** Даты часто приходят в строковом формате.
 - *Метод решения:* Приведение к типу `datetime64`.

```
In [6]: import pandas as pd

# 1. Загрузка данных для оценки качества
try:
    df = pd.read_csv('ecology_air_quality.csv', encoding='utf-8')
except UnicodeDecodeError:
    df = pd.read_csv('ecology_air_quality.csv', encoding='cp1251')

# 2. Демонстрация проблемы пропусков
print("--- Количество пропусков в данных ---")
missing_values = df.isnull().sum()
print(missing_values[missing_values > 0])

# 3. Демонстрация проблемы типов данных
print("\n--- Типы данных до обработки ---")
print(df.dtypes)

# 4. Демонстрация аномалий (через описательную статистику)
print("\n--- Поиск аномалий (обратите внимание на max temp) ---")
# Используем include='all' чтобы увидеть и даты, и числа
print(df[['temperature_c', 'pm25_ug_m3']].describe().round(2))
```

```

--- Количество пропусков в данных ---
date          7
station       7
pm25_ug_m3    7
no2_ug_m3     7
temperature_c  7
wind_m_s      8
dtype: int64

--- Типы данных до обработки ---
date          object
station       object
pm25_ug_m3    float64
no2_ug_m3     float64
temperature_c float64
wind_m_s      float64
dtype: object

--- Поиск аномалий (обратите внимание на max temp) ---
      temperature_c  pm25_ug_m3
count          361.00    361.00
mean           14.93     24.52
std            10.39     12.41
min            -10.00      3.00
25%             8.40     16.30
50%            14.20     23.70
75%            20.30     31.90
max             81.79    104.18

```

Выводы

В ходе выполнения работы были пройдены этапы 1–3 методологии Data Science применительно к предметной области «Экология»:

1. Сформулирована цель — переход от мониторинга к выявлению факторов загрязнения.
2. Определены источники данных (станции мониторинга + метеослужбы).
3. Выявлены ключевые риски (качество датчиков) и стратегии их минимизации.
4. На практике (в ячейке 7) проведена первичная диагностика качества данных, которая подтвердила наличие пропусков и выбросов, требующих предобработки на следующих этапах.

Практическая визуализация данных

```

In [7]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Настройка красивого стиля графиков
sns.set_theme(style="whitegrid")
plt.rcParams['figure.figsize'] = (12, 6)

# 1. Загрузка и подготовка (на случай, если переменная df потерялась)
try:

```

```

df = pd.read_csv('ecology_air_quality.csv', encoding='utf-8')
except:
    df = pd.read_csv('ecology_air_quality.csv', encoding='cp1251')


df['date'] = pd.to_datetime(df['date'])

# --- ГРАФИК 1: Поиск аномалий (Ящик с усами / Boxplot) ---
# Этот график визуально подтверждает слова из "Задания 5" про проблемы качества
plt.figure(figsize=(10, 5))
sns.boxplot(data=df[['temperature_c', 'pm25_ug_m3', 'no2_ug_m3']], palette="Set2")
plt.title('Диаграмма размаха: Поиск выбросов (аномалий)', fontsize=14)
plt.ylabel('Значения показателей')
plt.show()
print("Комментарий: На графике видны черные точки-выбросы. Например, температура")


# --- ГРАФИК 2: Динамика загрязнения во времени ---
# Иллюстрирует "Задание 3" (Time Series данные)
plt.figure(figsize=(12, 6))
sns.lineplot(data=df, x='date', y='pm25_ug_m3', label='PM2.5 (Пыль)', color='crimson')
sns.lineplot(data=df, x='date', y='no2_ug_m3', label='NO2 (Диоксид азота)', color='blue')
plt.title('Динамика загрязнения воздуха во времени', fontsize=14)
plt.xlabel('Дата')
plt.ylabel('Концентрация (мкг/м3)')
plt.legend()
plt.xticks(rotation=45)
plt.show()

# --- ГРАФИК 3: Корреляция (Влияние ветра на чистоту воздуха) ---
# Подтверждает гипотезу из "Задания 1" (влияние погоды)
plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='wind_m_s', y='pm25_ug_m3', hue='temperature_c', palette='Set2')
plt.title('Зависимость загрязнения (PM2.5) от скорости ветра', fontsize=14)
plt.xlabel('Скорость ветра (м/с)')
plt.ylabel('Уровень PM2.5')
plt.legend(title='Температура °C', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()

```



Комментарий: На графике видны черные точки-выбросы. Например, температура выше 40°C или экстремальные скачки PM2.5.



Выводы по самостоятельной работе

В ходе выполнения самостоятельной работы были успешно реализованы первые три этапа процесса Data Science в рамках задачи анализа экологических показателей региона (**Вариант 12**):

1. **Постановка цели:** Мы перешли от простого наблюдения за цифрами к аналитической постановке задачи — выявлению факторов, влияющих на качество воздуха. Это позволило определить проект не как статистический отчет, а как инструмент поддержки принятия управленческих решений в сфере экологической безопасности.
2. **Сбор данных:** Был проведен системный анализ источников. Мы определили, что для полноценного исследования недостаточно одних лишь показателей

датчиков; необходима интеграция гетерогенных данных (метеорология, геопозиции), что является характерной чертой проектов в области **Big Data**.

3. **Подготовка данных:** Предварительная оценка качества данных на практическом примере (`ecology_air_quality.csv`) подтвердила, что реальные данные всегда содержат «шум»:

- Выявлены технические аномалии (например, некорректные значения температуры свыше 80°C);
- Обнаружены пропуски во временных рядах, требующие дальнейшей обработки (интерполяции);
- Визуальный анализ (диаграммы размаха и графики рассеяния) подтвердил наличие взаимосвязи между метеоусловиями (скорость ветра) и уровнем загрязнения (PM2.5).

Итог: Работа подтвердила методологическую гипотезу о том, что этапы постановки задачи и подготовки данных являются наиболее трудоемкими и критически важными. Без качественной очистки и корректного сопоставления источников данных дальнейшее построение предиктивных моделей было бы неэффективным.