

Методические указания
для выполнения самостоятельной работы
по дисциплине «Системы обработки больших данных»
по материалам лекции 1 «Процесс Data Science: этапы 1–3 (постановка цели,
сбор и подготовка данных)»

1. Общие положения

Настоящие методические указания предназначены для организации и выполнения самостоятельной работы обучающихся по дисциплине «Системы обработки больших данных» в рамках изучения Лекции 1.

Самостоятельная работа является обязательной частью учебного процесса и направлена на формирование у обучающихся системного представления о начальных этапах процесса Data Science, которые играют ключевую роль в проектах анализа данных и построения систем обработки больших данных.

В ходе выполнения самостоятельной работы обучающиеся осваивают методологию постановки задачи анализа данных, приобретают навыки анализа источников данных и оценки качества информации, а также формируют инженерный подход к работе с данными.

2. Цель и задачи самостоятельной работы

2.1. Цель самостоятельной работы

Целью самостоятельной работы является закрепление и углубление знаний, полученных в ходе изучения Лекции 1, а также формирование практических навыков выполнения первых трёх этапов процесса Data Science:

1. постановка цели проекта;
2. сбор данных;
3. подготовка данных.

2.2. Задачи самостоятельной работы

В ходе выполнения самостоятельной работы обучающийся должен:

- научиться формулировать цель проекта Data Science в виде корректной аналитической задачи;
- освоить навыки разработки проектного задания (problem statement);

- уметь определять и анализировать источники данных;
- выявлять возможные риски доступа к данным;
- проводить предварительную оценку качества данных;
- формировать логически связанный аналитический отчёт.

3. Теоретические положения, подлежащие усвоению

Перед выполнением практической части самостоятельной работы обучающемуся необходимо самостоятельно изучить следующие теоретические вопросы:

3.1. Процесс Data Science

Процесс Data Science представляет собой итеративную методологию, включающую последовательность этапов, направленных на получение знаний и принятие решений на основе данных. Особое внимание следует уделить первым этапам процесса, так как именно они формируют фундамент всей последующей аналитической работы.

3.2. Постановка цели проекта

Постановка цели предполагает перевод исходной проблемы или запроса в чётко сформулированную аналитическую задачу. Цель должна быть конкретной, логически обоснованной и не содержать указаний на конкретные алгоритмы или программные средства.

3.3. Сбор данных

Сбор данных включает выбор источников информации, анализ их релевантности, доступности и ограничений. В проектах обработки больших данных источники, как правило, являются гетерогенными и требуют системного анализа.

3.4. Подготовка данных

Подготовка данных включает очистку, преобразование и интеграцию данных, а также выявление и устранение проблем качества информации. Этот этап является наиболее трудоёмким и требует инженерного подхода.

4. Индивидуальные задания для самостоятельной работы

Каждому обучающемуся выдается один индивидуальный вариант задания в соответствии с номером по списку в журнале группы.

Перечень вариантов

Вариант 1. Образование (высшее)

Рассмотреть задачу анализа успеваемости студентов в университете.

Контекст:

Учебный процесс, оценки, посещаемость, результаты сессий.

Вариант 2. Образование (онлайн-курсы)

Рассмотреть задачу анализа поведения слушателей онлайн-курсов.

Контекст:

Платформа дистанционного обучения, видеолекции, тесты, активность пользователей.

Вариант 3. Экономика и финансы

Рассмотреть задачу анализа финансовых показателей предприятия.

Контекст:

Выручка, затраты, прибыль, динамика по периодам.

Вариант 4. Банковская сфера

Рассмотреть задачу оценки кредитных рисков.

Контекст:

Анкетные данные клиентов, история платежей, кредитные продукты.

Вариант 5. Здравоохранение

Рассмотреть задачу анализа данных медицинских обследований пациентов.

Контекст:

Электронные медицинские карты, результаты анализов, диагнозы.

Вариант 6. Промышленность

Рассмотреть задачу анализа данных производственного оборудования.

Контекст:

Датчики, показатели работы станков, отказы и простои.

Вариант 7. Транспорт

Рассмотреть задачу анализа данных городского транспорта.

Контекст:

Маршруты, интервалы движения, загрузка, задержки.

Вариант 8. Логистика

Рассмотреть задачу оптимизации логистических цепочек поставок.

Контекст:

Склады, поставщики, сроки доставки, объёмы грузов.

Вариант 9. Торговля и ритейл

Рассмотреть задачу анализа покупательского спроса.

Контекст:

Продажи товаров, чеки, сезонность, акции.

Вариант 10. Интернет и социальные сети

Рассмотреть задачу анализа активности пользователей социальной сети.

Контекст:

Посты, лайки, комментарии, подписки.

Вариант 11. Государственное управление

Рассмотреть задачу анализа обращений граждан.

Контекст:

Тексты обращений, сроки рассмотрения, категории проблем.

Вариант 12. Экология

Рассмотреть задачу анализа экологических показателей региона.

Контекст:

Данные мониторинга воздуха, воды, почвы.

Вариант 13. Энергетика

Рассмотреть задачу анализа потребления электроэнергии.

Контекст:

Показания счётчиков, временные ряды, категории потребителей.

Вариант 14. Информационная безопасность

Рассмотреть задачу анализа журналов событий информационной системы.

Контекст:

Логи доступа, ошибки, аномальные действия.

Вариант 15. Научные исследования

Рассмотреть задачу анализа экспериментальных научных данных.

Контекст:

Результаты измерений, серии экспериментов, метаданные.

5. Практическая часть самостоятельной работы (обязательная для всех вариантов)

Задание 1. Формулировка цели проекта Data Science

Необходимо:

1. Описать предметную область и контекст задачи.
2. Сформулировать цель проекта в виде аналитической задачи.
3. Указать предполагаемую ценность результата.

Запрещается указывать конкретные алгоритмы, методы машинного обучения и программные инструменты.

Задание 2. Проектное задание (Problem Statement)

Проектное задание должно включать:

- формулировку проблемы;
- цель проекта;
- тип задачи Data Science;
- предполагаемые результаты;
- критерии успешности;
- ограничения проекта.

Задание 3. Анализ источников данных

Для проекта необходимо:

- определить не менее трёх источников данных;
- описать их характеристики;
- оценить их релевантность поставленной цели.

Задание 4. Анализ рисков доступа к данным

Необходимо:

- выявить технические, организационные и правовые риски;
- оценить возможные последствия;
- предложить меры по снижению рисков.

Задание 5. Предварительная оценка качества данных

Следует:

- выявить возможные проблемы качества данных;
- описать предполагаемые меры подготовки данных.

6. Требования к оформлению отчёта

Отчёт должен содержать:

1. Титульный лист
2. Цель и задачи работы
3. Выполнение заданий 1–5
4. Выводы
5. Список использованной литературы

Технические требования:

- шрифт Times New Roman, 14;
- межстрочный интервал 1,5;
- выравнивание по ширине;
- объём 8–12 страниц.

7. Критерии оценки

Критерий	Максимальный балл
Постановка цели	20
Проектное задание	20
Анализ источников данных	20
Анализ рисков и качества данных	20
Выводы и логика изложения	20
Итого	100

8. Пример выполнения самостоятельной работы (для ознакомления краткая структура работы)

Пример предназначен исключительно для ознакомления и демонстрирует:

- рекомендуемую структуру отчёта;
- уровень детализации и аргументации;
- корректную логику раскрытия этапов 1–3 процесса Data Science.

При выполнении индивидуального задания студент должен сохранить общую структуру работы, при этом предметная область и содержание определяются в соответствии с выданным вариантом.

1. Формулировка цели проекта Data Science

Контекст задачи

Розничные торговые сети аккумулируют значительные объёмы данных о продажах товаров, формируемые в процессе повседневной деятельности. Эти данные включают сведения о количестве проданных товаров, ценах, временных характеристиках покупок и результатах маркетинговых акций. Несмотря на наличие больших массивов информации, управленческие решения часто принимаются без системного анализа факторов, влияющих на покупательский спрос.

Использование методов Data Science позволяет перейти от описательной отчётности к аналитическому подходу, основанному на выявлении закономерностей и факторов, определяющих динамику спроса.

Цель проекта

Цель проекта Data Science – выявить факторы, оказывающие влияние на изменение покупательского спроса на товары розничной сети, на основе анализа исторических данных о продажах.

Цель сформулирована:

- в виде аналитической задачи;
- без указания конкретных алгоритмов и инструментов;

- с ориентацией на практическую ценность результатов.

Ожидаемая ценность результата

Результаты анализа могут быть использованы для:

- оптимизации ассортимента товаров;
- повышения эффективности планирования закупок;
- поддержки управленческих решений в сфере продаж.

2. Проектное задание (Problem Statement)

Формулировка проблемы

Имеющиеся данные о продажах используются преимущественно для формирования отчётности и не позволяют в полной мере анализировать причины изменения покупательского спроса и выявлять устойчивые закономерности.

Цель проекта

Проанализировать данные о продажах товаров розничной сети и определить ключевые факторы, влияющие на динамику спроса.

Тип задачи Data Science

Описательная аналитика с выявлением закономерностей и тенденций.

Ожидаемые результаты

- выявление сезонных колебаний спроса;
- анализ влияния ценовых изменений и маркетинговых акций;
- формирование аналитических выводов для поддержки управленческих решений.

Критерии успешности проекта

- логическая обоснованность выводов;
- интерпретируемость результатов для специалистов предметной области;
- соответствие полученных выводов исходным данным.

Ограничения проекта

- анализ проводится на исторических данных;
- возможны пропущенные и ошибочные значения;

- отсутствует полная информация о покупателях.

3. Анализ источников данных

Источник 1. Данные о продажах (POS-система)

- Тип данных: структурированные
- Формат: табличные данные
- Частота обновления: ежедневно
- Преимущества: высокая детализация, полнота информации
- Ограничения: возможные дубликаты и ошибки ввода

Источник 2. Справочник товаров

- Тип данных: структурированные
- Формат: табличные данные
- Назначение: описание товарных категорий
- Ограничения: несогласованность наименований товаров

Источник 3. Данные о маркетинговых акциях

- Тип данных: полуструктурированные
- Формат: таблицы и текстовые описания
- Назначение: анализ влияния акций на спрос

Выбранные источники данных являются релевантными поставленной цели и дополняют друг друга.

4. Анализ рисков доступа к данным

Возможные риски

- технические сбои при выгрузке данных;
- различия форматов данных в разных источниках;
- ограничения доступа к информации о маркетинговых акциях.

Меры по снижению рисков

- автоматизированные проверки целостности данных;
- регламентация прав доступа;
- предварительная нормализация форматов данных.

5. Предварительная оценка качества данных

Возможные проблемы качества данных

- наличие пропущенных значений;
- дублирование записей;
- ошибки в ценах и объёмах продаж;
- несогласованность наименований товаров.

Предполагаемые меры подготовки данных

- удаление или корректировка дубликатов;
- обработка пропущенных значений;
- приведение данных к единому формату;
- использование справочников для нормализации данных.

6. Выводы

В ходе выполнения самостоятельной работы были рассмотрены первые три этапа процесса Data Science: постановка цели, сбор и подготовка данных. Пример показывает, что корректная формулировка цели и тщательный анализ источников данных являются ключевыми факторами успешного проекта. Предварительная оценка качества данных позволяет выявить потенциальные проблемы и определить направления дальнейшей работы.

9. Заключительные положения

Самостоятельная работа по Лекции 1 направлена на формирование у обучающихся методологического мышления и инженерного подхода к работе с данными. Освоение этапов постановки цели, сбора и подготовки данных является необходимым условием успешного изучения последующих разделов дисциплины и выполнения практических и проектных заданий.