

Практическое занятие 2

Подготовка данных (Data Preparation)

Вариант 12 - экология

Выполнил: Дмитрий Трифонов (12-25ППм, Программная инженерия, 1 курс)

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

plt.style.use("seaborn-v0_8")

VARIANT = 12

# Загрузка данных
data_raw = pd.read_csv(f"PZ2_variant_{VARIANT}.csv", encoding="utf-8-sig", sep=";")
data = data_raw.copy()

data.head()
```

```
Out[1]:
```

	pm25	no2	wind
0	3.767731	23.182198	3.071882
1	15.418457	11.821958	5.594203
2	36.608582	18.359308	4.505975
3	37.837067	29.108360	4.234209
4	16.884906	55.287888	3.709215

1. Цель практического занятия

Целью практического занятия является формирование практических навыков подготовки данных: очистки, обработки пропусков, устранения дубликатов, анализа выбросов и нормализации признаков для последующего анализа и моделирования.

2. Описание исходных данных

```
In [2]: data.shape

data.info()

data.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 376 entries, 0 to 375
Data columns (total 3 columns):
 #   Column  Non-Null Count  Dtype
---  -
 0   pm25    357 non-null     float64
 1   no2     358 non-null     float64
 2   wind    358 non-null     float64
dtypes: float64(3)
memory usage: 8.9 KB
```

```
Out[2]:
```

	pm25	no2	wind
count	357.000000	358.000000	358.000000
mean	25.115138	30.232429	3.465544
std	11.029321	15.169746	1.389916
min	-2.012123	-10.959463	-0.055051
25%	18.009601	20.354392	2.502435
50%	24.613618	30.790824	3.459920
75%	32.401322	40.189967	4.486181
max	62.615984	75.169809	7.579868

В данном датасете представлены экологические показатели (предположительно концентрации загрязняющих веществ, погодные параметры и временные метки).

3. Анализ качества данных

3.1 Проверка пропусков

```
In [3]: data.isnull().sum()
```

```
Out[3]: pm25    19
        no2     18
        wind    18
        dtype: int64
```

3.2 Проверка дубликатов

```
In [4]: data.duplicated().sum()
```


```
Out[4]: np.int64(11)
```

3.3 Первичный анализ выбросов


```
In [5]: num_cols = data.select_dtypes(include=[np.number]).columns


for col in num_cols:
    plt.figure()
    plt.boxplot(data[col].dropna())
    plt.title(f"Boxplot для {col}")
    plt.show()
```

Boxplot для pm25



Boxplot для no2





Выявленные проблемы качества данных:

1. Наличие пропущенных значений
2. Наличие дубликатов
3. Наличие выбросов в числовых признаках
4. Возможные некорректные типы данных (если есть даты)

4. Очистка данных от дубликатов

```
In [6]: rows_before = data.shape[0]
data = data.drop_duplicates()
rows_after = data.shape[0]
rows_before, rows_after
```

Out[6]: (376, 365)

Дубликаты не несут новой информации и могут исказить статистические характеристики.

5. Обработка пропущенных значений

5.1 Числовые признаки — замена медианой

```
In [7]: for col in data.select_dtypes(include=[np.number]).columns:  
        data[col] = data[col].fillna(data[col].median())
```

5.2 Категориальные признаки — замена модой

```
In [8]: for col in data.select_dtypes(include=['object']).columns:  
        data[col] = data[col].fillna(data[col].mode()[0])
```

Проверка:

```
In [9]: data.isnull().sum()
```

```
Out[9]: pm25      0  
        no2      0  
        wind     0  
        dtype: int64
```

Обоснование выбора стратегии:

1. Медиана устойчива к выбросам
2. Мода корректна для категориальных данных
3. Удаление строк привело бы к потере информации

6. Анализ и обработка выбросов (IQR)

```
In [10]: def iqr_clean(df):  
        res = df.copy()  
        for col in res.select_dtypes(include=[np.number]).columns:  
            q1 = res[col].quantile(0.25)  
            q3 = res[col].quantile(0.75)  
            iqr = q3 - q1  
            lower = q1 - 1.5 * iqr  
            upper = q3 + 1.5 * iqr  
  
            res = res[(res[col] >= lower) & (res[col] <= upper)]  
        return res  
  
data_clean = iqr_clean(data)  
  
data_clean.shape
```

```
Out[10]: (358, 3)
```

Сравнение размера данных

```
In [11]: data.shape, data_clean.shape
```

```
Out[11]: ((365, 3), (358, 3))
```

Метод IQR позволяет удалить экстремальные значения, не характерные для основной выборки.

7. Преобразование и нормализация данных

7.1 Приведение дат (если есть столбцы с датами)

Если есть столбец типа date:

```
In [12]: # data_clean['date'] = pd.to_datetime(data_clean['date'])
```

7.2 Нормализация числовых признаков (Z-score)

```
In [13]: data_norm = data_clean.copy()

for col in data_norm.select_dtypes(include=[np.number]).columns:
    mean = data_norm[col].mean()
    std = data_norm[col].std()
    data_norm[col] = (data_norm[col] - mean) / std

data_norm.describe()
```

```
Out[13]:
```

	pm25	no2	wind
count	3.580000e+02	3.580000e+02	3.580000e+02
mean	3.572561e-16	1.091616e-16	3.026753e-16
std	1.000000e+00	1.000000e+00	1.000000e+00
min	-2.576595e+00	-2.605373e+00	-2.631280e+00
25%	-6.147328e-01	-6.591882e-01	-6.456940e-01
50%	1.846987e-02	4.566642e-02	6.962057e-03
75%	7.020750e-01	6.250994e-01	7.322040e-01
max	2.484648e+00	2.558904e+00	2.743598e+00

8. Сравнительный анализ «до / после»

8.1 Статистическое сравнение

```
In [14]: print("До обработки:")
display(data_raw.describe())

print("После обработки:")
display(data_clean.describe())
```

До обработки:


	pm25	no2	wind
count	357.000000	358.000000	358.000000
mean	25.115138	30.232429	3.465544
std	11.029321	15.169746	1.389916
min	-2.012123	-10.959463	-0.055051
25%	18.009601	20.354392	2.502435
50%	24.613618	30.790824	3.459920
75%	32.401322	40.189967	4.486181
max	62.615984	75.169809	7.579868

После обработки:


	pm25	no2	wind
count	358.000000	358.000000	358.000000
mean	24.949398	30.127612	3.489414
std	10.464011	14.196288	1.347049
min	-2.012123	-6.859008	-0.055051
25%	18.516827	20.769586	2.619632
50%	25.142667	30.775905	3.498792
75%	32.295919	39.001703	4.475729
max	50.948788	66.454551	7.185176

8.2 Визуальное сравнение


```
In [15]: for col in data_clean.select_dtypes(include=[np.number]).columns:
plt.figure()
plt.hist(data_raw[col].dropna(), alpha=0.5, bins=20)
plt.hist(data_clean[col], alpha=0.5, bins=20)
plt.title(f"До / После для {col}")
plt.show()
```



До / После для no2



До / После для wind



9. Итоговые выводы

В ходе выполнения практического занятия:

1. Были выявлены проблемы качества данных:

- пропущенные значения;
- дубликаты;
- выбросы.

2. Выполнены следующие шаги подготовки:

- удаление дубликатов;
- заполнение пропусков медианой и модой;
- удаление выбросов методом IQR;
- нормализация числовых признаков.

3. После обработки:

- уменьшилась размерность набора данных;
- стабилизировались статистические показатели;
- данные стали пригодны для последующего моделирования.

4. Ограничения:

- удаление выбросов может привести к потере редких, но реальных событий;
- замена пропусков медианой снижает вариативность признаков.