

Практическое занятие 2
по дисциплине «Системы обработки больших данных»
Тема практического занятия
Подготовка данных в процессе Data Science
(очистка, преобразование, анализ качества, воспроизводимость)

1. Общие положения

Практическое занятие 2 является логическим продолжением Практического занятия 1 и направлено на **углублённое освоение этапа подготовки данных (Data Preparation)** в процессе Data Science.

Если в Практическом занятии 1 основное внимание уделялось первичному анализу и оценке данных, то в Практическом занятии 2 обучающиеся переходят к **инженерной обработке данных**, включающей:

- очистку данных;
- обработку пропусков;
- устранение дубликатов;
- работу с выбросами;
- преобразование признаков;
- документирование всех шагов подготовки данных.

2. Цель и задачи практического занятия

2.1. Цель практического занятия

Целью практического занятия является **формирование практических навыков подготовки данных**, необходимых для последующего анализа и моделирования в проектах Data Science и системах обработки больших данных.

2.2. Задачи практического занятия

В ходе выполнения практического занятия обучающийся должен:

- выявлять и классифицировать проблемы качества данных;
- применять базовые методы очистки данных;
- корректно обрабатывать пропущенные значения;
- устранять или обосновывать наличие дубликатов;
- анализировать и интерпретировать выбросы;
- выполнять преобразование и стандартизацию признаков;
- формировать отчёт о качестве данных;
- обеспечивать воспроизводимость подготовки данных.

3. Место практического занятия в структуре дисциплины

Практическое занятие 2:

- выполняется **после ПЗ 1**;
- опирается на результаты первичного анализа данных;
- подготавливает обучающихся к изучению:
 - масштабируемых пайплайнов обработки данных;
 - распределённых систем хранения и обработки;
 - практик промышленного Data Science.

4. Используемые инструменты и среда выполнения

Практическое занятие выполняется с использованием:

- языка программирования **Python**;
- среды **Jupyter Notebook**;
- библиотек:
 - pandas;
 - numpy;
 - matplotlib.

Все операции подготовки данных должны быть **выполнены программно** и сопровождаться пояснениями.

5. Исходные данные и индивидуализация

5.1. Индивидуальные варианты

Используются **15 индивидуальных вариантов**, соответствующих предметным областям ПЗ 1:

1. Успеваемость студентов
2. Онлайн-обучение
3. Финансы предприятия
4. Банковские данные
5. Медицинские показатели
6. Производственное оборудование
7. Городской транспорт
8. Логистика
9. Розничная торговля
10. Социальные сети
11. Обращения граждан
12. Экология
13. Энергопотребление
14. Журналы событий

15. Научные эксперименты

Для каждого варианта используется **индивидуальный CSV-датасет**, содержащий:

- пропуски;
- дубликаты;
- выбросы;
- неоднородные типы данных.

6. Структура практического занятия

Практическое занятие 2 состоит из следующих этапов:

1. Загрузка и воспроизводимая инициализация данных
2. Повторная оценка качества данных
3. Очистка данных от дубликатов
4. Обработка пропущенных значений
5. Анализ и обработка выбросов
6. Преобразование и нормализация признаков
7. Повторный анализ и сравнение «до / после»
8. Формирование отчёта о подготовке данных

7. Порядок выполнения практического занятия

Этап 1. Загрузка и фиксация исходного состояния данных

Обучающийся должен:

- загрузить индивидуальный датасет;
- зафиксировать размерность данных;
- сохранить контрольную информацию (shape, типы данных).

Цель этапа — обеспечить **воспроизводимость обработки**.

Этап 2. Повторная оценка качества данных

Необходимо:

- определить количество пропусков по каждому столбцу;
- выявить дубликаты;
- повторно проанализировать выбросы;
- классифицировать проблемы качества данных.

Этап 3. Очистка данных от дубликатов

Следует:

- определить критерии дублирования;
- удалить или агрегировать дубликаты;
- обосновать принятое решение.

Этап 4. Обработка пропущенных значений

Для каждого столбца необходимо:

- определить допустимость пропусков;
- выбрать стратегию обработки:
 - удаление;
 - замена;
 - сохранение с обоснованием;
- документировать принятое решение.

Этап 5. Анализ и обработка выбросов

Необходимо:

- использовать статистические методы (IQR, квантили);
- визуализировать выбросы;
- принять решение:
 - оставить;
 - скорректировать;
 - удалить;
- обосновать каждое действие.

Этап 6. Преобразование и нормализация данных

Следует:

- привести даты и время к корректным типам;
- нормализовать числовые признаки;
- переименовать столбцы при необходимости;
- подготовить данные к дальнейшему анализу.

Этап 7. Сравнительный анализ «до / после»

Необходимо:

- сравнить размерность данных;
- сравнить статистические характеристики;
- визуально показать изменения;
- сделать вывод о качестве подготовки данных.

Этап 8. Отчёт о подготовке данных

В завершение студент формирует **структурированный отчёт**, включающий:

- перечень выявленных проблем;
- выполненные шаги подготовки;
- обоснование решений;
- ограничения подготовленных данных.

8. Требования к отчёту

Отчёт по ПЗ 2 должен содержать:

1. Цель практического занятия
2. Описание исходных данных
3. Анализ проблем качества данных
4. Описание выполненных преобразований
5. Сравнение «до / после»
6. Итоговые выводы

9. Критерии оценки

Критерий	Баллы
Анализ качества данных	20
Корректность очистки данных	20
Работа с пропусками	15
Анализ и обработка выбросов	15
Преобразование признаков	15
Итоговые выводы	15
Итого	100

10. Ожидаемые результаты

После выполнения Практического занятия 2 обучающийся должен:

- уверенно владеть базовыми методами подготовки данных;
- понимать инженерную роль этапа Data Preparation;
- быть готовым к работе с более сложными пайплайнами обработки данных.