

ПРАКТИЧЕСКОЕ ЗАНЯТИЕ №3 (ПЗ-3)

Этап 3 процесса Data Science: подготовка данных
(очистка, преобразование, воспроизводимый pipeline)

1. Общая характеристика практического занятия

Дисциплина: Системы обработки больших данных

Раздел дисциплины: Процесс Data Science

Связь с лекциями:

- продолжение Лекции 2.1 (этапы 1–3);
- логическая основа для Лекции 2.2 (этапы 4–6).

Связь с предыдущими практиками:

ПЗ-3 является прямым продолжением ПЗ-1 и ПЗ-2.

Если в первых практиках студент учился:

- знакомиться с данными,
- формировать словарь данных,
- выполнять первичную проверку качества,

то в ПЗ-3 он переходит на профессиональный уровень:

не просто «чистит данные», а строит воспроизводимый слой подготовки данных, который можно повторно применять и включать в систему обработки данных.

2. Цель практического занятия

Целью практического занятия является формирование у студентов устойчивых навыков подготовки данных как отдельного этапа процесса Data Science.

В ходе выполнения ПЗ-3 студент должен научиться:

- выявлять и классифицировать проблемы качества данных;
- выбирать и обосновывать стратегии очистки;
- выполнять преобразование признаков;
- собирать все операции в воспроизводимый pipeline;
- фиксировать результат в виде артефактов проекта Data Science.

3. Планируемые результаты обучения

После выполнения практического занятия студент умеет:

- выявлять пропуски, дубликаты, выбросы и логические ошибки в данных;
- аргументированно выбирать стратегии обработки пропусков;
- выполнять нормализацию и кодирование категориальных признаков;
- выполнять масштабирование числовых признаков;
- собирать подготовку данных в виде pipeline (цепочки преобразований);
- сравнивать качество данных до и после очистки;
- документировать выполненные преобразования.

4. Входные данные для практического занятия

Каждому студенту выдаётся индивидуальный вариант датасета.

4.1. Количество вариантов

Всего предусмотрено 15 вариантов датасетов:

PZ3_PZ4_variant_01.csv ... PZ3_PZ4_variant_15.csv.

Каждый вариант:

- имеет одинаковую структуру;
- содержит разные реализации проблем качества данных;
- предназначен для индивидуальной работы студента.

4.2. Структура данных (кратко)

Поле	Описание
client_id	идентификатор клиента
age	возраст (в данных есть заведомо некорректные значения)
income_rub	доход (есть пропуски и выбросы)
city	город (есть разные варианты написания)
education	уровень образования (есть пропуски)
contract_type	тип договора
tenure_months	стаж клиента
purchases_6m	покупки за 6 месяцев (есть выбросы)
support_calls_6m	обращения в поддержку

Поле	Описание
churn	целевая переменная (0/1)

5. Результаты, которые студент должен сдать

По итогам выполнения ПЗ-3 студент сдаёт:

5.1. Основные материалы

1. Очищенный датасет (или результат применения pipeline).
2. Код pipeline подготовки данных.
3. Таблицу сравнения качества данных «до / после».

5.2. Текстовые разделы

4. План очистки данных (что исправлялось и почему).
5. Краткие выводы о качестве данных после обработки.

6. Пошаговая инструкция выполнения ПЗ-3

Шаг 1. Выбор индивидуального варианта датасета

Каждый студент работает строго со своим вариантом.

В начале работы студент указывает:

- номер своего варианта (от 1 до 15);
- имя файла датасета;
- краткое описание набора данных (2–3 предложения).

Шаг 2. Формирование плана очистки данных

Перед выполнением любых преобразований студент обязан составить план очистки.

В плане должны быть отражены минимум следующие пункты:

1. Какие признаки могут содержать пропуски.
2. Какие признаки могут содержать выбросы.
3. Возможные дубликаты.
4. Категориальные признаки с ошибками написания.
5. Какие преобразования планируется выполнить.

План оформляется текстом или таблицей.

Шаг 3. Анализ и обработка пропусков

Студент:

- определяет количество и долю пропусков по каждому признаку;
- выбирает стратегию обработки пропусков:
 - среднее (mean),
 - медиана (median),
 - мода (mode),
 - константа,
 - удаление строк.

Для каждого признака студент обязан:

- указать выбранную стратегию;
- обосновать её выбор.

Шаг 4. Обнаружение и обработка дубликатов

Студент:

- проверяет наличие полных дубликатов строк;
- определяет количество дубликатов;
- принимает решение об их удалении или сохранении.

В отчёте обязательно фиксируется:

- количество найденных дубликатов;
- принятое решение.

Шаг 5. Выявление и обработка выбросов

Студент:

- выбирает не менее двух числовых признаков;
- строит boxplot (коробчатую диаграмму);
- определяет наличие выбросов (например, по IQR).

После этого студент:

- решает, что делать с выбросами (удаление, ограничение, сохранение);
- обосновывает своё решение.

Шаг 6. Обработка категориальных признаков

Для категориальных признаков студент:

- приводит строки к единому регистру;
- удаляет лишние пробелы;
- объединяет эквивалентные значения.

Результат оформляется в виде таблицы

«было → стало».

Шаг 7. Преобразование признаков

Студент выполняет минимум два типа преобразований:

1. Кодирование категориальных признаков
(one-hot encoding).
2. Масштабирование числовых признаков
(standard scaling или аналог).

Опционально (для желающих получить «Отлично»):

создание нового признака с пояснением его смысла.

Шаг 8. Сборка pipeline подготовки данных

Все выполненные шаги студент обязан объединить в pipeline.

Pipeline должен:

- включать обработку пропусков;
- включать масштабирование и кодирование;
- быть применим к новым данным без ручной правки.

Студент текстом поясняет:

- структуру pipeline;
- назначение каждого шага.

Шаг 9. Контроль качества данных «до и после»

Студент формирует таблицу сравнения:

Показатель	До обработки	После обработки
Пропуски	...	...
Дубликаты	...	...
Выбросы (пример) ...	...	...

После таблицы делается краткий вывод о том, улучшилось ли качество данных.

7. Контрольные вопросы

Студент письменно отвечает на два вопроса:

1. Почему подготовка данных должна быть оформлена в виде pipeline, а не выполняться вручную?
2. В каких случаях удаление данных предпочтительнее заполнения пропусков?

8. Исследовательские задания (*на отлично*)

1. Сравнить две стратегии обработки пропусков и сделать вывод.
2. Добавить один новый признак и оценить его полезность.

9. Критерии оценивания

Элемент	Баллы
План очистки данных	15
Работа с пропусками (анализ + обоснование)	20
Дубликаты и выбросы	20
Категориальные признаки	10
Преобразования признаков	15
Pipeline	15
Контроль качества и выводы	5
Итого	100