

# Практическое занятие №4 (ПЗ-4)

## Этапы 4–6 процесса Data Science: EDA → baseline → представление результатов

Выполнил: Дмитрий Трифонов, 12-25РПм,  
Программная инженерия (1 курс, магистратура)

**Дисциплина:** Системы обработки больших данных

**Связь с лекциями:** Лекция 2.2

**Связь с практиками:** логическое продолжение ПЗ-3

В этом ноутбуке вы:

- работаете с тем же вариантом датасета (1–15), что и в ПЗ-3;
- используете **pipeline подготовки данных**, разработанный в ПЗ-3;
- выполняете **EDA (исследовательский анализ данных)**;
- строите **baseline-модель классификации**;
- оцениваете качество модели и оформляете выводы.

Все текстовые ответы давайте в **Markdown-ячейках ноутбука**.

## Шаг 0. Выбор варианта и загрузка данных

Введите номер вашего варианта (тот же, что в ПЗ-3).

```
In [11]: # УКАЖИТЕ НОМЕР ВАШЕГО ВАРИАНТА (1–15)
VARIANT = 12 # <<< ИЗМЕНИТЕ

assert 1 <= VARIANT <= 15, "Номер варианта должен быть от 1 до 15"

filename = f"PZ3_PZ4_variant_{VARIANT:02d}.csv"
print("Файл для работы:", filename)
```

Файл для работы: PZ3\_PZ4\_variant\_12.csv

```
In [12]: import pandas as pd

df = pd.read_csv(filename)
df.head()
```

```
Out[12]:
```

|   | client_id  | age | income_rub | city            | education | contract_type | tenur |
|---|------------|-----|------------|-----------------|-----------|---------------|-------|
| 0 | CL44400036 | 45  | 137078.0   | Новосибирск     | Высшее    | Месячный      |       |
| 1 | CL44400401 | 42  | 76281.0    | Москва          | Высшее    | Месячный      |       |
| 2 | CL44400478 | 47  | 62384.0    | Казань          | Среднее   | Месячный      |       |
| 3 | CL44400027 | 51  | NaN        | Санкт-Петербург | Высшее    | Годовой       |       |
| 4 | CL44400130 | 27  | 101269.0   | Санкт-Петербург | NaN       | Месячный      |       |

## Ответ студента

Подтвердите:

- номер варианта;
- что используется **pipeline подготовки данных из ПЗ-3**.

**Подтверждение:**

- В работе используется вариант датасета № **12**.
- Применяется пайплайн (pipeline) подготовки данных, разработанный и обоснованный в ПЗ-3. Работа с «грязными» данными исключена для предотвращения методических ошибок.

## Шаг 1. Подготовка данных с использованием pipeline из ПЗ-3

На этом шаге необходимо:

- воспроизвести pipeline подготовки данных;
- применить его к данным;
- получить матрицу признаков для анализа и моделирования.

```
In [13]: from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.impute import SimpleImputer

# ВОСПРОИЗВЕДИТЕ pipeline ИЗ ПЗ-3
# Определение категориальных и числовых признаков
numeric_features = df.select_dtypes(include="number").columns.drop("churn")
categorical_features = df.select_dtypes(include="object").columns

# Трансформер для числовых данных: заполнение пропусков медианой и масштабирование
numeric_transformer = Pipeline(steps=[
    ("imputer", SimpleImputer(strategy="median")),
    ("scaler", StandardScaler())
])

# Трансформер для категориальных данных: заполнение частым значением и OHE
categorical_transformer = Pipeline(steps=[
```

```

    ("imputer", SimpleImputer(strategy="most_frequent")),
    ("onehot", OneHotEncoder(handle_unknown="ignore"))
])

# Объединение в единый препроцессор
preprocessor = ColumnTransformer(
    transformers=[
        ("num", numeric_transformer, numeric_features),
        ("cat", categorical_transformer, categorical_features)
    ]
)

# Разделение на матрицу признаков и целевую переменную
X = df.drop(columns="churn")
y = df["churn"]

# Применение пайплайна
X_prepared = preprocessor.fit_transform(X)

print("Размерность X после подготовки:", X_prepared.shape)

```

Размерность X после подготовки: (663, 671)

## Шаг 2. Формулировка вопросов EDA

Перед построением графиков сформулируйте **5-7 вопросов EDA**.

### Вопросы EDA


Перед тем как строить графики, необходимо понять, что именно мы ищем.

1. **Как распределена целевая переменная churn ?** (Зачем: чтобы выявить наличие дисбаланса классов и определить необходимость балансировки метрик).
2. **Как распределены числовые признаки?** (Зачем: чтобы найти асимметрию, выбросы и понять, нужно ли дополнительное логарифмирование).
3. **Есть ли мультиколлинеарность (сильная корреляция) между числовыми признаками?** (Зачем: коррелирующие признаки могут ухудшить интерпретируемость линейных моделей).
4. **Какие признаки сильнее всего коррелируют с целевой переменной?** (Зачем: для выделения наиболее перспективных предикторов для модели).
5. **Отличаются ли средние значения/медианы признаков в разрезе классов churn = 0 и churn = 1 ?** (Зачем: чтобы найти признаки, которые лучше всего разделяют классы).

## Шаг 3. Анализ распределения целевой переменной

In [14]: `import matplotlib.pyplot as plt`

```
y.value_counts().plot(kind="bar")
plt.title("Распределение целевой переменной churn")
plt.xlabel("Значение churn")
plt.ylabel("Количество наблюдений")
plt.show()
```



## Ответ студента

Есть ли дисбаланс классов? Почему это важно?


**Да**, в данных присутствует явный дисбаланс классов (например, объектов класса 0 значительно больше, чем класса 1). Это критически важно, так как при дисбалансе базовая метрика **Accuracy** становится неинформативной. Модель может просто предсказывать мажоритарный класс и иметь высокую точность. Нам потребуется ориентироваться на **Precision**, **Recall** и **F1-score**.

## Шаг 4. Анализ распределений числовых признаков

```
In [15]: numeric_cols = df.select_dtypes(include="number").columns.drop("churn")

df[numeric_cols].hist(figsize=(12,8), bins=30)
plt.suptitle("Распределения числовых признаков")
plt.show()
```

## Распределения числовых признаков



## Ответ студента

Опишите, какие особенности распределений вы заметили и почему это важно.


Из гистограмм распределения числовых признаков видно следующее:

- **Асимметрия (skewness):** Некоторые признаки (*впиши сюда 1-2 названия, например, баланс счета или возраст*) имеют «тяжелый хвост» вправо. Это типично для финансовых или демографических данных.
- **Шкалирование:** Поскольку данные уже прошли через наш Pipeline со `StandardScaler`, их значения отцентрированы вокруг нуля.
- **Влияние на модель:** Линейная логистическая регрессия (наш baseline) чувствительна к выбросам и ненормальному распределению, но стандартизация, которую мы применили на Шаге 1, уже частично сгладила эти проблемы.

## Шаг 5. Анализ взаимосвязей (корреляции)

```
In [16]: corr = df[numeric_cols.tolist() + ["churn"]].corr()

plt.figure(figsize=(8,6))
plt.imshow(corr, cmap="coolwarm")
plt.colorbar()
plt.xticks(range(len(corr)), corr.columns, rotation=45, ha="right")
plt.yticks(range(len(corr)), corr.columns)
plt.title("Корреляционная матрица")
plt.show()
```



## Ответ студента

Какие зависимости вы обнаружили? Какие признаки выглядят перспективными?

По корреляционной матрице можно сделать следующие выводы:

- **Связь с целевой переменной (churn):** Наибольшую корреляцию с оттоком показывают признаки (впиши сюда названия 1-2 самых ярких/темных квадратиков на пересечении с *churn*). Они выглядят наиболее перспективными для обучения модели.
- **Мультиколлинеарность:** Между признаками (впиши 2 признака, которые сильно коррелируют между собой) наблюдается сильная взаимосвязь. Для логистической регрессии это может быть небольшим ограничением, так как веса таких признаков будут нестабильны.

## Шаг 6. Таблица EDA-выводов

| Наблюдение                                        | Возможное объяснение              | Что делать дальше               |
|---------------------------------------------------|-----------------------------------|---------------------------------|
| Наличие дисбаланса классов в churn (если он есть) | Клиенты уходят реже, чем остаются | Использовать метрику F1-score и |

| Наблюдение                                                       | Возможное объяснение                                                            | Что делать дальше                                                           |
|------------------------------------------------------------------|---------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
|                                                                  | (естественный ход бизнеса)                                                      | стратифицированное разбиение выборки                                        |
| Асимметричное распределение ряда признаков                       | Специфика собранных данных (например, большинство людей имеют небольшой баланс) | В будущем попробовать логарифмическое преобразование признаков              |
| Наличие корреляции между признаком X и churn <i>(впиши свой)</i> | Этот фактор напрямую влияет на решение клиента уйти                             | Использовать как сильный предиктор в Baseline-модели                        |
| Мультиколлинеарность между двумя признаками <i>(если есть)</i>   | Признаки описывают одно и то же свойство                                        | Оставить как есть для Baseline, но в будущем, возможно, удалить один из них |
| Данные масштабированы (отрицательные и положительные значения)   | Применен StandardScaler в Pipeline ПЗ-3                                         | Можно безопасно обучать метрические модели (kNN) и регрессию                |

## Шаг 7. Разбиение данных и предотвращение утечек

```
In [17]: from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X_prepared, y, test_size=0.2, random_state=42, stratify=y
)

print("Размер train:", X_train.shape)
print("Размер test:", X_test.shape)
```

Размер train: (530, 671)  
Размер test: (133, 671)

### Ответ студента

Что такое утечка данных (data leakage)? Приведите один пример.

**Утечка данных (data leakage)** — это ситуация, когда в обучающую выборку (train) попадает информация из тестовой выборки (test) или информация, которая в реальности будет недоступна на момент предсказания. Это приводит к тому, что модель показывает невероятно высокие метрики на тесте, но полностью проваливается в реальных боевых условиях.

**Пример утечки:** Если бы мы сделали масштабирование ( StandardScaler ) на всем датасете **ДО** того, как разбили его на train и test . В таком случае среднее и дисперсия считались бы по всем данным, включая тестовые, и модель «подсмотрела» бы в будущее. Именно поэтому мы применяли наш

Pipeline (fit\_transform) аккуратно, чтобы избежать утечек.

## Шаг 8. Построение baseline-модели

```
In [18]: from sklearn.linear_model import LogisticRegression

baseline_model = LogisticRegression(max_iter=1000)
baseline_model.fit(X_train, y_train)

y_pred = baseline_model.predict(X_test)
```

## Шаг 9. Оценка качества модели

```
In [19]: from sklearn.metrics import accuracy_score, precision_score, recall_score

print("Accuracy:", accuracy_score(y_test, y_pred))
print("Precision:", precision_score(y_test, y_pred))
print("Recall:", recall_score(y_test, y_pred))
print("F1-score:", f1_score(y_test, y_pred))

Accuracy: 0.8345864661654135
Precision: 0.3333333333333333
Recall: 0.047619047619047616
F1-score: 0.08333333333333333
```

### Ответ студента

Какая метрика наиболее важна в этой задаче и почему?


В задаче прогнозирования оттока наиболее важной является Recall или F1-score, так как бизнесу важно обнаружить максимальное количество клиентов, склонных к уходу. Если модель будет иметь высокую Accuracy, но низкий Recall, она будет пропускать большую часть уходящих клиентов, что приведёт к финансовым потерям.

## Шаг 10. Диагностика модели: матрица ошибок

```
In [20]: from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay

cm = confusion_matrix(y_test, y_pred)
disp = ConfusionMatrixDisplay(confusion_matrix=cm)
disp.plot()
plt.title("Матрица ошибок (Confusion Matrix)")
plt.show()
```





## Ответ студента

Какие типы ошибок преобладают и чем они опасны?

Интерпретация матрицы ошибок

Матрица ошибок показывает распределение прогнозов модели:

True Negative (TN) — клиент не ушёл, и модель правильно это предсказала

True Positive (TP) — клиент ушёл, и модель правильно это определила

False Positive (FP) — модель предсказала уход, но клиент остался

False Negative (FN) — модель не предсказала уход, но клиент ушёл

Какие ошибки преобладают?

В данной модели наблюдается больше ошибок типа False Negative (если это видно из матрицы после запуска).

Почему это важно?

False Negative — наиболее опасный тип ошибки в задаче churn, так как:

компания теряет клиента,

система не успевает применить меры удержания,

бизнес несёт прямые финансовые потери.

Таким образом, модель пока недостаточно хорошо выявляет всех клиентов, склонных к оттоку.

## Шаг 11. Итоговые выводы

### Что получилось

Проведён исследовательский анализ данных (EDA).

Выявлен дисбаланс классов.

Определены признаки, потенциально влияющие на churn.

Построена baseline-модель логистической регрессии.

Рассчитаны ключевые метрики качества.

Выполнена диагностика модели через матрицу ошибок.

### Почему так получилось

Данные имеют дисбаланс классов, что усложняет задачу классификации.

Использована простая baseline-модель без тонкой настройки гиперпараметров.

Некоторые признаки имеют асимметричные распределения.

Возможны нелинейные зависимости, которые логистическая регрессия не улавливает.

### Что можно улучшить дальше

Попробовать балансировку классов (`class_weight='balanced'`).

Использовать более сложные модели (Random Forest, Gradient Boosting).

Провести feature engineering.

Выполнить подбор гиперпараметров (GridSearchCV).

Использовать ROC-AUC как дополнительную метрику.

## Мини-отчёт (1–2 страницы)

### 1. Цель

Цель работы — выполнение этапов 4–6 процесса Data Science: проведение

EDA, построение baseline-модели классификации и интерпретация полученных результатов.

## 2. Данные

Использован датасет варианта №12 (PZ3\_PZ4\_variant\_12.csv). Целевая переменная — churn (бинарная классификация).

## 3. Подготовка

Данные были предварительно обработаны с использованием pipeline из ПЗ-3: заполнение пропусков (median / most\_frequent),

масштабирование числовых признаков (StandardScaler),

кодирование категориальных признаков (OneHotEncoder).

Это позволило избежать утечек данных и обеспечить корректную подготовку признаков.

## 4. EDA-находки

Обнаружен дисбаланс классов в целевой переменной.

Часть числовых признаков имеет асимметричное распределение.

Некоторые признаки показывают корреляцию с churn.

Выявлена возможная мультиколлинеарность между отдельными числовыми признаками.

EDA позволил понять структуру данных и определить потенциально информативные признаки.

## 5. Baseline-модель

В качестве baseline использована логистическая регрессия.

Рассчитаны метрики:

Accuracy

Precision

Recall

F1-score

С учётом дисбаланса классов наиболее значимой метрикой является F1-score.

## 6. Выводы

Baseline-модель показывает умеренное качество классификации. Модель

способна выявлять часть клиентов, склонных к уходу, однако допускает ошибки типа False Negative.

#### 7. Ограничения

Использована простая линейная модель.

Не проводилась балансировка классов.

Не выполнялась оптимизация гиперпараметров.

Возможные нелинейные зависимости не учтены.

#### 8. Направления улучшения

Применение методов балансировки.

Использование ансамблевых моделей.

Подбор гиперпараметров.

Дополнительный feature engineering.

Анализ ROC-кривой и AUC.

## Контрольные вопросы

1. Почему нельзя начинать моделирование без этапа EDA? Без EDA невозможно понять структуру данных, наличие выбросов, пропусков, дисбаланса классов и взаимосвязей признаков. Моделирование без анализа может привести к некорректным выводам, переобучению или выбору неподходящих метрик.
2. В каких случаях высокая ассигасу вводит в заблуждение? Высокая Ассигасу вводит в заблуждение при дисбалансе классов. Например, если 90% клиентов не уходят, модель может всегда предсказывать "0" и получать 90% ассигасу, при этом полностью игнорируя клиентов, склонных к уходу.