

ПРАКТИЧЕСКОЕ ЗАНЯТИЕ №4

Этапы 4–6 процесса Data Science

Исследовательский анализ данных (EDA) → baseline-модель → представление результатов

1. Общая характеристика практического занятия

Связь с лекциями:

- Лекция 2.2 «Процесс Data Science: этапы 4–6».

Связь с предыдущими практиками:

ПЗ-4 является непосредственным продолжением ПЗ-3 и выполняется:

- на том же датасете (тот же вариант 1–15);
- с использованием pipeline подготовки данных, разработанного в

ПЗ-3.

Если ПЗ-3 отвечало на вопрос

«Как корректно подготовить данные?»

то ПЗ-4 отвечает на вопросы:

«Что можно узнать из данных?»

«Как построить базовую модель?»

«Как корректно представить результат?»

2. Цель практического занятия

Целью практического занятия является формирование у студентов целостного понимания второй половины процесса Data Science – от анализа данных до представления результатов.

В ходе выполнения ПЗ-4 студент должен научиться:

- выполнять исследовательский анализ данных (EDA);
- формулировать и проверять гипотезы на основе данных;
- строить baseline-модель как точку отсчёта;
- выбирать и интерпретировать метрики качества;
- выполнять первичную диагностику модели;

- оформлять результат в виде структурированного аналитического отчёта.

3. Планируемые результаты обучения

После выполнения ПЗ-4 студент умеет:

- формулировать вопросы EDA до построения графиков;
- анализировать распределения признаков и целевой переменной;
- выявлять зависимости между признаками;
- фиксировать EDA-выводы в структурированном виде;
- корректно разбивать данные на обучающую и тестовую выборки;
- строить baseline-модель классификации;
- интерпретировать метрики accuracy, precision, recall, F1;
- анализировать матрицу ошибок;
- формулировать выводы, ограничения и направления улучшений.

4. Входные данные для практического занятия

4.1. Индивидуальный вариант датасета

Каждый студент использует:

- тот же вариант (1–15), что и в ПЗ-3;
- файл PZ3_PZ4_variant_XX.csv.

Важно:

Для ПЗ-4 обязательно используется pipeline подготовки данных, разработанный в ПЗ-3.

Работа с «сырыми» данными без pipeline считается методической ошибкой.

5. Результаты, которые студент должен сдать

По итогам выполнения ПЗ-4 студент сдаёт:

5.1. Основные материалы

1. EDA-графики (3–5 шт.) с подписями и выводами.
2. Таблицу EDA-выводов (наблюдение → объяснение → действие).

3. Baseline-модель и значения метрик качества.

4. Матрицу ошибок и её интерпретацию.

5.2. Текстовые материалы

5. Мини-отчёт объёмом 1–2 страницы:

- цель;
- данные;
- подготовка;
- EDA-находки;
- baseline;
- выводы;
- ограничения;
- направления улучшения.

6. Пошаговая инструкция выполнения ПЗ-4

Шаг 1. Подключение результатов ПЗ-3

В начале работы студент обязан явно указать:

- номер варианта;
- что используется pipeline подготовки данных, разработанный в

ПЗ-3.

Студент должен понимать:

EDA и моделирование выполняются не на «грязных» данных, а на подготовленных.

Шаг 2. Формулировка плана EDA

Перед построением графиков студент формулирует 5–7 вопросов EDA.

Примеры вопросов:

- Как распределена целевая переменная churn?
- Есть ли дисбаланс классов?
- Какие признаки имеют асимметричное распределение?
- Есть ли корреляции между числовыми признаками?
- Отличаются ли распределения признаков для разных классов?

- Какие признаки потенциально наиболее информативны?

Каждый вопрос сопровождается кратким пояснением «зачем мы это проверяем».

Шаг 3. Анализ распределения целевой переменной

Студент:

- строит столбчатую диаграмму для churn;
- определяет наличие дисбаланса классов.

В тексте обязательно указывается:

- есть ли дисбаланс;
- почему это важно для выбора метрик и моделей.

Шаг 4. Анализ распределений числовых признаков

Студент выбирает не менее двух числовых признаков и:

- строит гистограммы;
- при необходимости boxplot.

Для каждого графика студент отмечает:

- что видно;
- почему это важно;
- как это может повлиять на модель.

Шаг 5. Анализ взаимосвязей между признаками

Студент выполняет один или оба вида анализа:

- корреляционная матрица числовых признаков;
- сравнение распределений признаков по классам (churn = 0 и churn = 1).

Результат оформляется не просто графиком, а осмысленным выводом.

Шаг 6. Таблица EDA-выводов

Студент формирует таблицу из 5–8 строк:

Наблюдение	Возможное объяснение	Что делать дальше

Примеры:

- «Наблюдается дисбаланс классов → ассурасу может вводить в заблуждение → использовать F1».
- «Признак X отличается по классам → потенциально информативен → использовать в baseline».

Шаг 7. Разбиение данных и риск утечек

Студент:

- выполняет разбиение на обучающую и тестовую выборки;
- использует стратификацию по целевой переменной.

В тексте студент:

- объясняет, что такое утечка данных (data leakage);
- приводит один пример утечки.

Шаг 8. Построение baseline-модели

Студент строит одну простую модель классификации:

- логистическая регрессия или
- k-ближайших соседей (kNN).

В тексте фиксируется:

baseline-модель – это точка отсчёта, а не финальное решение.

Шаг 9. Оценка качества модели

Студент рассчитывает и интерпретирует:

- accuracy;
- precision;
- recall;
- F1-score.

Обязательно:

- пояснить смысл каждой метрики;
- указать, какая метрика наиболее важна в данной задаче.

Шаг 10. Диагностика модели (матрица ошибок)

Студент строит confusion matrix (матрицу ошибок) и отвечает:

- какие ошибки преобладают;
- почему это важно;

- какие последствия это может иметь в реальной задаче.

Шаг 11. Формирование итоговых выводов

Студент оформляет выводы в формате «слайд-стиля»:

1. Что получилось
2. Почему так получилось
3. Что можно улучшить дальше

Шаг 12. Мини-отчёт

Мини-отчёт оформляется строго по структуре:

1. Цель
2. Данные
3. Подготовка
4. EDA-находки
5. Baseline-модель
6. Выводы
7. Ограничения
8. Направления улучшения

7. Контрольные вопросы

Студент письменно отвечает на два вопроса:

1. Почему нельзя начинать моделирование без этапа EDA?
2. В каких случаях высокая ассурасу не означает хорошее качество модели?

8. Исследовательские задания (на отличную оценку)

1. Улучшить baseline-модель одним простым приёмом и сравнить метрики.
2. Предложить вариант автоматизации результата (от ноутбука к системе).

9. Критерии оценивания

Элемент	Баллы
План EDA	15
EDA-графики и выводы	25
Таблица EDA-выводов	15
Разбиение данных и утечки	15
Baseline-модель и метрики	20
Диагностика и выводы	10
Итого	100