

Практическое занятие №5

Контролируемое обучение (Supervised Learning)

Выполнил Дмитрий Трифонов, 12-25РПМ, 1 курс,
Программная инженерия

Этот ноутбук предназначен для выполнения ПЗ-5 по лекции 3.1.

Важно: каждый студент выполняет работу по *своему варианту* (CSV-файлу).
Предполагается, что ноутбук и файлы данных находятся **в одной папке**.

Как работать с ноутбуком

1. В ячейке **«Номер варианта»** укажите VARIANT от 1 до 15.
2. Запустите ноутбук сверху вниз.
3. В текстовых ячейках (где написано *«Ответ студента»*) впишите свои пояснения.

В конце у вас должен получиться отчёт: постановка задачи, описание данных, обучение модели, метрики, анализ переобучения и выводы.

```
In [18]: # Ячейка 1. Импорт библиотек
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression, LinearRegression
from sklearn.metrics import (
    accuracy_score, confusion_matrix,
    mean_squared_error, mean_absolute_error
)

pd.set_option('display.max_columns', 50)
pd.set_option('display.width', 120)
print('Библиотеки успешно импортированы.')
```

Библиотеки успешно импортированы.

```
In [19]: # Ячейка 2. Номер варианта и загрузка данных
# УКАЖИТЕ НОМЕР СВОЕГО ВАРИАНТА (1-15)
VARIANT = 12

# Имя файла по шаблону: dataset_variant_1.csv, dataset_variant_2.csv, ...
filename = f"6-0_dataset_variant_{VARIANT}.csv"
print('Открываю файл:', filename)

df = pd.read_csv(filename)
display(df.head())
print('\nРазмер таблицы:', df.shape)
```

Открываю файл: 6-0_dataset_variant_12.csv

	area_m2	rooms	floor	distance_center_km	year_built	schools_1km	parks_1km	me
0	53.7	3	8	8.42	1966	2	3	
1	73.9	2	2	18.82	1983	1	3	
2	95.3	4	7	4.68	2020	3	1	
3	34.1	3	10	7.93	1989	1	0	
4	83.6	1	13	1.11	2024	1	2	

Размер таблицы: (500, 11)

1. Первичный анализ данных (обязательный)

На этом шаге вы должны понять:

- какие столбцы есть в данных;
- какие типы данных у столбцов;
- есть ли пропуски;
- есть ли очевидные аномалии.

```
In [20]: # Ячейка 3. Информация о данных
df.info()
print('\nЧисло пропусков по столбцам:')
display(df.isna().sum())

print('\nОписательная статистика по числовым столбцам:')
display(df.describe(include=[np.number]))
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  -
0   area_m2               500 non-null   float64
1   rooms                 500 non-null   int64
2   floor                 500 non-null   int64
3   distance_center_km    500 non-null   float64
4   year_built            500 non-null   int64
5   schools_1km           500 non-null   int64
6   parks_1km             500 non-null   int64
7   metro_minutes         500 non-null   float64
8   renovation_score      500 non-null   float64
9   noise_db              500 non-null   float64
10  target                500 non-null   float64
dtypes: float64(6), int64(5)
memory usage: 43.1 KB
```

Число пропусков по столбцам:

```
area_m2          0
rooms            0
floor            0
distance_center_km 0
year_built       0
schools_1km      0
parks_1km        0
metro_minutes    0
renovation_score 0
noise_db         0
target           0
dtype: int64
Описательная статистика по числовым столбцам:
```

	area_m2	rooms	floor	distance_center_km	year_built	schools_1km
count	500.000000	500.000000	500.000000	500.000000	500.000000	500.000000
mean	61.900200	2.720000	7.134000	8.90844	1995.692000	1.964000
std	18.110701	1.05443	3.22814	3.79385	16.539778	1.260906
min	20.000000	1.000000	1.000000	0.500000	1950.000000	0.000000
25%	48.850000	2.000000	5.000000	6.31750	1984.000000	1.000000
50%	62.450000	3.000000	7.000000	8.61500	1996.000000	2.000000
75%	74.625000	3.000000	9.000000	11.39750	2008.000000	3.000000
max	120.000000	6.000000	17.000000	19.30000	2024.000000	6.000000

Ответ студента (кратко, 6–10 предложений)

1. Что это за данные (по смыслу)? Характеристики квартир для предсказания цены или других показателей. Содержат информацию о площади, количестве комнат, этаже, расстоянии до центра, годе постройки, инфраструктуре (школы, парки в 1 км), времени до метро и уровне шума.
2. Сколько объектов и сколько признаков? 11 столбцов (area_m2, rooms, floor, distance_center_km, year_built, schools_1km, parks_1km, metro_minutes, renovation_score, noise_db, target).
3. Есть ли пропуски? Если да — где и сколько? Все статистики (min, max, mean) корректны без NaN.
4. Какие столбцы выглядят как кандидаты на целевую переменную? Почему? target (последний столбец, типично для ML-датасетов) или area_m2 (площадь как цель регрессии). target предпочтительнее — это числовой показатель (mean=9.77, диапазон 1.5-24.9), вероятно цена/рейтинг; площадь обычно признак.

2. Постановка задачи контролируемого обучения

Контролируемое обучение (*Supervised Learning*) означает, что для каждого объекта

известен **правильный ответ**.

Вам нужно:

- определить, что у вас: **классификация** (цель — класс) или **регрессия** (цель — число);
- выбрать **целевой столбец** (target);
- обосновать выбор.

```
In [21]: # Ячейка 4. Выбор целевой переменной и признаков
# УКАЖИТЕ ИМЯ ЦЕЛЕВОГО СТОЛБЦА (как в вашем CSV)
TARGET_COLUMN = 'target'

X = df.drop(columns=[TARGET_COLUMN])
y = df[TARGET_COLUMN]

print('Целевая переменная:', TARGET_COLUMN)
print('Число признаков:', X.shape[1])
print('\nСписок признаков:')
display(pd.Series(X.columns))

print('\nТип целевой переменной:', y.dtype)
display(y.head())
```

Целевая переменная: target

Число признаков: 10

Список признаков:

```
0          area_m2
1           rooms
2           floor
3  distance_center_km
4        year_built
5     schools_1km
6     parks_1km
7    metro_minutes
8  renovation_score
9         noise_db
```

dtype: object

Тип целевой переменной: float64

```
0    10.162
1     9.843
2    12.810
3     7.765
4     5.805
```

Name: target, dtype: float64

Ответ студента

1. Какой столбец вы выбрали в качестве целевой переменной и почему?

Выбрана целевая переменная target — это стандартное название для цели в ML-датасетах, представляет числовое значение (float64) с диапазоном 1.5-24.9 (mean=9.77), что типично для цены недвижимости или рейтинга привлекательности квартиры.

2. Это классификация или регрессия? Обоснуйте. Это регрессия, поскольку target — непрерывная числовая величина (не категории/классы). Задача —

предсказать точное значение (вероятно, цену или score), а не отнести к классу.

3. Какие 2–3 признака, по вашему мнению, наиболее важны для предсказания цели? Почему?

Наиболее важные признаки:

- `area_m2` — площадь напрямую определяет стоимость жилья (больше площадь = дороже).
- `distance_center_km` — близость к центру критически влияет на цену (меньше расстояние = дороже).
- `renovation_score` — качество ремонта существенно повышает рыночную стоимость квартиры.

3. Разделение данных на обучающую и тестовую выборки

Мы должны проверить способность модели **обобщать** на новые данные.

Данные делят на:

- **обучающую выборку (train)** — на ней модель учится;
- **тестовую выборку (test)** — на ней оцениваем качество на данных, которые модель не видела.

```
In [22]: # Ячейка 5. Train/Test split
TEST_SIZE = 0.30
RANDOM_STATE = 42

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=TEST_SIZE, random_state=RANDOM_STATE
)

print('Размер train:', X_train.shape)
print('Размер test :', X_test.shape)
```

Размер train: (350, 10)

Размер test : (150, 10)

4. Выбор модели и обучение

В учебной версии ПЗ-5 используем:

- для **классификации** — `LogisticRegression` (логистическая регрессия);
- для **регрессии** — `LinearRegression` (линейная регрессия).

Важно: тип задачи вы задаёте явно в `MODEL_TYPE` .

```
In [23]: # Ячейка 6. Обучение модели
MODEL_TYPE = 'regression' # 'classification' или 'regression'

if MODEL_TYPE == 'classification':
    model = LogisticRegression(max_iter=2000)
```

```

elif MODEL_TYPE == 'regression':
    model = LinearRegression()
else:
    raise ValueError('MODEL_TYPE должен быть classification или regression')

model.fit(X_train, y_train)
print('Модель обучена:', type(model).__name__)

```

Модель обучена: LinearRegression

5. Прогнозирование и оценка качества

Считаем прогнозы на train и test и оцениваем метрики.

Метрики

- Классификация: **accuracy** и **confusion matrix**.
- Регрессия: **MSE**, **RMSE**, **MAE**.

```

In [24]: # Ячейка 7. Прогнозирование
y_train_pred = model.predict(X_train)
y_test_pred = model.predict(X_test)
print('Прогнозы рассчитаны.')

```

Прогнозы рассчитаны.

```

In [25]: # Ячейка 8. Метрики качества
if MODEL_TYPE == 'classification':
    train_acc = accuracy_score(y_train, y_train_pred)
    test_acc = accuracy_score(y_test, y_test_pred)
    print(f'Accuracy (train): {train_acc:.4f}')
    print(f'Accuracy (test) : {test_acc:.4f}')

    cm = confusion_matrix(y_test, y_test_pred)
    print('\nConfusion matrix (test):')
    display(pd.DataFrame(cm))

    plt.figure()
    plt.imshow(cm)
    plt.title('Матрица несоответствий (test)')
    plt.xlabel('Предсказанный класс')
    plt.ylabel('Истинный класс')
    for i in range(cm.shape[0]):
        for j in range(cm.shape[1]):
            plt.text(j, i, cm[i, j], ha='center', va='center')
    plt.tight_layout()
    plt.show()
else:
    mse = mean_squared_error(y_test, y_test_pred)
    rmse = np.sqrt(mse)
    mae = mean_absolute_error(y_test, y_test_pred)
    print(f'MSE : {mse:.4f}')
    print(f'RMSE: {rmse:.4f}')
    print(f'MAE : {mae:.4f}')

    plt.figure()
    plt.scatter(y_test, y_test_pred)
    plt.title('Истинные значения vs Предсказания (test)')
    plt.xlabel('Истинные значения')
    plt.ylabel('Предсказания')


```

```
plt.tight_layout()
plt.show()
```

MSE : 1.7095

RMSE: 1.3075

MAE : 0.9494



6. Анализ переобучения (overfitting) и обобщения (generalization)

Сравните качество на обучающей и тестовой выборках.

- Если на train качество существенно лучше, чем на test, это может быть признаком **переобучения**.
- Если качество низкое и на train, и на test — возможное **недообучение**.

Ответ студента

1. Есть ли признаки переобучения? (Да/Нет) - Нет, явных признаков переобучения не наблюдается.
2. На чём основан вывод? (сравнение метрик train/test) - Модель линейной регрессии показывает достаточно небольшую ошибку на тестовой выборке:
 - MSE = 1.7095
 - RMSE = 1.3075
 - MAE = 0.9494

Значения ошибок относительно небольшие по сравнению с диапазоном целевой

переменной (1.5 – 24.9). Это говорит о том, что модель достаточно хорошо обобщает данные и способна делать разумные предсказания для новых объектов.

3. Какие 2–3 улучшения можно предложить?

- Добавить масштабирование признаков (StandardScaler) для повышения стабильности модели.
- Попробовать более сложные модели, например Random Forest или Gradient Boosting.
- Выполнить анализ важности признаков и удалить менее значимые признаки.

7. Итоговые выводы

Сформулируйте выводы:

1. Какая задача решалась?
2. Какие признаки и цель использовались?
3. Какое качество получилось и что оно означает?
4. Какие ограничения есть у модели?

Ответ студента

- **Задача:** Решалась задача контролируемого обучения типа регрессии — предсказание числового значения целевой переменной.
- **Целевая переменная:** Целевой переменной выбран столбец target, который представляет числовой показатель (предположительно цену или рейтинг квартиры).
- **Модель:** Для обучения использовалась модель линейной регрессии (LinearRegression).
- **Метрики:** Качество модели оценивалось с помощью метрик регрессии:
 - $MSE = 1.7095$
 - $RMSE = 1.3075$
 - $MAE = 0.9494$

Полученные значения показывают, что средняя ошибка предсказания составляет примерно около 1 единицы целевой переменной.

- **Вывод:** Модель линейной регрессии показала удовлетворительное качество предсказания и способна выявлять зависимости между характеристиками квартиры и целевой переменной. Однако линейная модель имеет ограничения и может не учитывать сложные нелинейные зависимости между признаками. Для повышения точности можно использовать более сложные модели машинного обучения.