

Практическое занятие №6

Неконтролируемое обучение (Unsupervised Learning)

Выполнил: Дмитрий Трифонов, 1 курс, 12-25РПм, Программная инженерия

Цель: освоить базовый цикл неконтролируемого обучения: подготовка данных → кластеризация → оценка качества кластеров → визуализация → интерпретация результатов.

Как работать:

1. Скачайте свой CSV dataset_variant_N.csv .
2. Положите CSV в ту же папку, что и этот ноутбук.
3. В ячейке ниже установите VARIANT = N .
4. Выполните ячейки последовательно и заполните текстовые ответы (где отмечено).

В этом ПЗ **нет** целевой переменной target . Мы ищем структуру данных и/или аномалии.

```
In [1]: # =====
# ЯЧЕЙКА 1. Импорт библиотек
# =====
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.cluster import KMeans, DBSCAN
from sklearn.metrics import silhouette_score

# Для поиска аномалий (используем как доп. инструмент)
from sklearn.ensemble import IsolationForest
```

```
In [2]: # =====
# ЯЧЕЙКА 2. Указание номера варианта и загрузка данных
# =====
VARIANT = 12 # <-- УКАЖИТЕ НОМЕР СВОЕГО ВАРИАНТА (1-15)

filename = f"7-0_dataset_variant_{VARIANT}.csv"
df = pd.read_csv(filename)

print("Файл:", filename)
print("Размер данных:", df.shape)
df.head()
```

Файл: 7-0_dataset_variant_12.csv
Размер данных: (708, 5)

Out[2]:

	temp_c	vibration	pressure_kpa	power_kw	flow_lpm
--	--------	-----------	--------------	----------	----------

0	52.8	2.101	223.7	50.20	223.1
1	53.8	1.900	244.4	41.30	226.3
2	50.2	2.007	229.2	44.76	222.0
3	51.2	1.979	204.6	49.67	234.3
4	48.1	1.617	235.9	53.92	216.0

```
In [3]: # =====
# ЯЧЕЙКА 3. Первичный анализ данных
# =====
df.info()

print("Пропуски по столбцам:")
print(df.isna().sum())

print("Описательная статистика:")
df.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 708 entries, 0 to 707
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  -
0   temp_c          708 non-null   float64
1   vibration        708 non-null   float64
2   pressure_kpa     708 non-null   float64
3   power_kw         708 non-null   float64
4   flow_lpm         708 non-null   float64
dtypes: float64(5)
memory usage: 27.8 KB
Пропуски по столбцам:
temp_c          0
vibration        0
pressure_kpa     0
power_kw         0
flow_lpm         0
dtype: int64
Описательная статистика:
```

Out[3]:

	temp_c	vibration	pressure_kpa	power_kw	flow_lpm
count	708.000000	708.000000	708.000000	708.000000	708.000000
mean	54.995198	2.543880	220.349859	48.052062	209.998588
std	6.909738	1.034898	31.788498	8.677562	18.015141
min	20.000000	0.100000	80.000000	5.000000	100.900000
25%	51.375000	1.985000	203.975000	43.770000	201.150000
50%	54.950000	2.501500	221.050000	48.080000	210.500000
75%	58.400000	2.988000	236.950000	52.305000	218.525000
max	95.000000	8.205000	420.000000	108.910000	317.400000

Ячейка 4. Формулировка задачи (заполнить вручную)

В этой ячейке студент должен написать текстом:

- какую структуру он ожидает увидеть (кластеры/аномалии/сложная форма кластеров);
- какие методы планирует применить (KMeans, DBSCAN, PCA, IsolationForest);
- как будет интерпретировать результат.

Напишите ниже 6–10 предложений.

```
In [4]: # Напишите здесь ваш текстовый ответ (можно оставить как комментарий)

# Предполагается, что набор данных не содержит целевой переменной,
# поэтому основная задача заключается в выявлении скрытой структуры данных

# Ожидается, что в данных могут присутствовать как несколько кластеров,
# так и аномальные наблюдения (выбросы), особенно учитывая специфику вариа

# Для решения задачи будут использованы следующие методы:
# PCA — для снижения размерности и визуализации данных;
# KMeans — для выявления компактных кластеров;
# DBSCAN — для поиска кластеров произвольной формы и обнаружения шумовых т
# Isolation Forest — для дополнительного выявления аномалий.

# Масштабирование признаков будет выполнено с использованием StandardScale
# так как алгоритмы кластеризации чувствительны к различию масштабов призна

# Интерпретация результатов будет выполняться на основе визуализации
# в пространстве главных компонент, анализа количества кластеров,
# их размеров, а также наличия и характера аномалий.

# Основная цель — определить структуру данных и выявить закономерности,
# которые невозможно увидеть без применения методов машинного обучения.
```

```
In [5]: # =====
# ЯЧЕЙКА 5. Подготовка данных: масштабирование
# =====
X = df.values

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

print("Готово: данные масштабированы (StandardScaler).")
```


Готово: данные масштабированы (StandardScaler).

```
In [6]: # =====
# ЯЧЕЙКА 6. PCA для визуализации в 2D
# =====
pca2 = PCA(n_components=2, random_state=42)
X_pca2 = pca2.fit_transform(X_scaled)

print("Доля объяснённой дисперсии (2 компоненты):", np.round(pca2.explaine
plt.figure()
```

```
plt.scatter(X_pca2[:,0], X_pca2[:,1], s=10)
plt.title("PCA (2D) — исходные точки")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.tight_layout()
plt.show()
```

Доля объяснённой дисперсии (2 компоненты): 0.5213



Ячейка 7. Кластеризация KMeans

1. Подберите число кластеров k (например, 2–8).
2. Для каждого k вычислите **silhouette score** (коэффициент силуэта).
3. Выберите k с наилучшим (или близким к лучшему) значением и объясните выбор.

Silhouette score находится в диапазоне примерно от -1 до 1. Чем больше — тем лучше разделены кластеры (в среднем).

```
In [7]: # =====
# ЯЧЕЙКА 7.1. Подбор k по silhouette score
# =====
k_values = list(range(2, 9))
scores = []

for k in k_values:
    km = KMeans(n_clusters=k, n_init=10, random_state=42)
    labels = km.fit_predict(X_scaled)
    score = silhouette_score(X_scaled, labels)
    scores.append(score)
```


```
pd.DataFrame({"k": k_values, "silhouette": scores})
```

Out[7]:

	k	silhouette
0	2	0.191355
1	3	0.198005
2	4	0.142105
3	5	0.141617
4	6	0.147124
5	7	0.147135
6	8	0.148472

	k	silhouette
0	2	0.191355
1	3	0.198005
2	4	0.142105
3	5	0.141617
4	6	0.147124
5	7	0.147135
6	8	0.148472

```
In [8]: # =====  
# ЯЧЕЙКА 7.2. Визуализация silhouette по k  
# =====  
plt.figure()  
plt.plot(k_values, scores, marker='o')  
plt.title("Silhouette score для разных k (KMeans)")  
plt.xlabel("k")  
plt.ylabel("silhouette score")  
plt.tight_layout()  
plt.show()  
  
best_k = k_values[int(np.argmax(scores))]  
print("Лучший k по silhouette:", best_k)
```




Лучший k по silhouette: 3

```
In [9]: # =====
# ЯЧЕЙКА 7.3. KMeans с выбранным k и визуализация кластеров в PCA-2D
# =====
k = best_k # при желании можно заменить вручную
kmeans = KMeans(n_clusters=k, n_init=10, random_state=42)
labels_km = kmeans.fit_predict(X_scaled)

plt.figure()
plt.scatter(X_pca2[:,0], X_pca2[:,1], c=labels_km, s=10)
plt.title(f"KMeans (k={k}) — кластеры в PCA-2D")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.tight_layout()
plt.show()

print("Размеры кластеров:")
pd.Series(labels_km).value_counts().sort_index()
```



Размеры кластеров:

```
Out[9]: 0    345
        1    352
        2     11
        Name: count, dtype: int64
```

Ячейка 8. Кластеризация DBSCAN (для сложных форм и выбросов)

DBSCAN — алгоритм, который умеет находить кластеры произвольной формы и выделять шумовые точки.

- `eps` — радиус окрестности;

- `min_samples` — минимальное число точек в окрестности.

Подберите параметры так, чтобы:

- число кластеров было разумным;
- была выделена часть шумовых точек (метка -1), если они есть.

```
In [10]: # =====
# ЯЧЕЙКА 8.1. DBSCAN: настройка параметров
# =====
eps = 0.7      # попробуйте 0.3–1.2
min_samples = 8 # попробуйте 5–15

db = DBSCAN(eps=eps, min_samples=min_samples)
labels_db = db.fit_predict(X_scaled)


n_clusters = len(set(labels_db)) - (1 if -1 in labels_db else 0)
n_noise = int((labels_db == -1).sum())

print("DBSCAN clusters:", n_clusters)
print("DBSCAN noise points:", n_noise)

plt.figure()
plt.scatter(X_pca2[:,0], X_pca2[:,1], c=labels_db, s=10)
plt.title(f"DBSCAN (eps={eps}, min_samples={min_samples}) — кластеры/шум в PCA-2D")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.tight_layout()
plt.show()
```

DBSCAN clusters: 1

DBSCAN noise points: 216



Ячейка 9. Поиск аномалий (дополнительно) — Isolation Forest

Isolation Forest (Изоляционный лес) — алгоритм, который пытается “изолировать” редкие точки быстрее, чем обычные. Подходит для вариантов 10–12 (датчики + выбросы), но можно попробовать и на других.

- `contamination` — ожидаемая доля аномалий (например, 0.03–0.10).


```
In [11]: # =====
# ЯЧЕЙКА 9.1. Isolation Forest
# =====
contamination = 0.06 # попробуйте 0.03–0.12

iso = IsolationForest(random_state=42, contamination=contamination)
anom_flag = iso.fit_predict(X_scaled) # -1 = аномалия, 1 = нормальная то

n_anom = int((anom_flag == -1).sum())
print("Найдено аномалий:", n_anom)

plt.figure()
plt.scatter(X_pca2[:,0], X_pca2[:,1], s=10)
plt.scatter(X_pca2[anom_flag==-1,0], X_pca2[anom_flag==-1,1], s=20)
plt.title("PCA-2D: найденные аномалии (Isolation Forest)")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.tight_layout()
plt.show()
```

Найдено аномалий: 43



Ячейка 10. Анализ результатов (заполнить вручную)

Напишите развёрнутые ответы:

1. Какие кластеры вы получили? Сколько кластеров кажется содержательным и почему?
2. Как меняется результат при использовании KMeans vs DBSCAN?
3. Если есть аномалии: как вы их интерпретируете?
4. Какие признаки, по вашему мнению, сильнее всего влияют на сегментацию/структуру?

Напишите 10–15 предложений.

```
In [12]: # Напишите здесь ваш текстовый ответ (можно оставить как комментарий)

# В ходе кластеризации методом KMeans было определено оптимальное
# количество кластеров:  $k = 3$ , что подтверждается максимальным значением
# коэффициента силуэта. Это означает, что данные естественным образом
# разделяются на три группы.

# Полученные кластеры являются достаточно компактными и хорошо отделены
# друг от друга, что видно на визуализации в пространстве главных компонен
# Это говорит о том, что в данных присутствует чёткая сегментация.

# При применении алгоритма DBSCAN был обнаружен только один кластер,
# а также значительное количество шумовых точек (216 наблюдений).
# Это указывает на то, что структура данных не является плотной,
# и большая часть точек распределена разреженно.

# Такое поведение DBSCAN может означать, что данные не содержат
# чётко выраженных плотных областей, либо параметры алгоритма
# ( $\epsilon$  и  $\text{min\_samples}$ ) слишком строгие для данного набора данных.

# Наличие большого количества шумовых точек можно интерпретировать
# как присутствие выбросов или нестандартных наблюдений,
# которые не принадлежат ни одному плотному кластеру.

# Результаты, полученные с помощью Isolation Forest, подтверждают
# наличие аномалий, что согласуется с выводами DBSCAN.

# Сравнение методов показывает, что KMeans лучше подходит для данного набо
# так как позволяет выделить осмысленные группы объектов,
# в то время как DBSCAN слишком чувствителен к параметрам и плотности данн

# Основной вклад в разделение данных вносят признаки с высокой дисперсией,
# что отражено в главных компонентах PCA.

# Таким образом, можно сделать вывод, что данные имеют кластерную структур
# представленную тремя основными группами, а также содержат значительное
# количество выбросов.
```

Ячейка 11. Выводы

Сформулируйте выводы по ПЗ-6:

- что удалось выявить в данных;
- какие методы оказались наиболее подходящими;
- что можно улучшить (например, собрать больше данных, добавить признаки, попробовать другие алгоритмы).

Не менее 8–10 предложений.

In [13]: # Напишите здесь выводы (можно оставить как комментарий)

В ходе выполнения практической работы были изучены методы
неконтролируемого обучения и применены к анализу набора данных.

Был проведён первичный анализ данных и выполнено масштабирование признаков
что позволило корректно применять алгоритмы кластеризации.

С помощью метода PCA удалось визуализировать данные и выявить
наличие кластерной структуры.

Метод KMeans показал, что оптимальным является разбиение на 3 кластера,
что свидетельствует о наличии трёх основных групп объектов в данных.

Алгоритм DBSCAN выявил только один кластер и большое количество шумовых
что говорит о разреженности данных и отсутствии выраженных плотных областей.

Это также может указывать на наличие большого числа аномалий
или на необходимость более точного подбора параметров алгоритма.

Применение Isolation Forest подтвердило наличие выбросов,
что усиливает достоверность результатов анализа.

В целом можно сделать вывод, что данные имеют кластерную структуру,
но при этом содержат значительное количество нестандартных наблюдений.

Для улучшения результатов можно было бы:
- более точно подобрать параметры DBSCAN;
- использовать альтернативные алгоритмы (например, HDBSCAN);
- провести дополнительную обработку признаков.

Таким образом, цель работы достигнута, структура данных выявлена,
а методы неконтролируемого обучения успешно применены.