

Практическое занятие №6

Неконтролируемое обучение (Unsupervised Learning)

1. Место практического занятия в структуре курса

Практическое занятие №6 является логическим продолжением **лекции 3.1 «Машинное обучение – основы, процесс и примеры»** и завершает первый практический блок по лекции 3 дисциплины «Системы обработки больших данных».

Если в практическом занятии №5 студенты работали с **контролируемым обучением (Supervised Learning)**, где для каждого объекта известен правильный ответ (целевая переменная), то в данном практическом занятии рассматривается **неконтролируемое обучение (Unsupervised Learning)**, при котором разметка данных отсутствует.

Данное практическое занятие формирует у студентов важное методологическое понимание: во многих реальных проектах Data Science именно методы неконтролируемого обучения применяются на ранних этапах анализа данных – для выявления структуры, сегментации объектов, поиска аномалий и подготовки признаков для последующего моделирования.

2. Цель практического занятия

Целью практического занятия №6 является формирование у студентов практических навыков применения базовых методов неконтролируемого обучения для анализа структуры данных без целевой переменной.

3. Планируемые результаты обучения

После выполнения практического занятия студент должен уметь:

1. объяснять сущность неконтролируемого обучения и его отличие от контролируемого обучения;
2. выполнять первичный анализ набора данных без целевой переменной;
3. применять масштабирование признаков и объяснять необходимость этого этапа;

4. использовать метод главных компонент (РСА) для снижения размерности и визуализации данных;
5. выполнять кластеризацию методом KMeans и обосновывать выбор числа кластеров;
6. оценивать качество кластеризации с использованием коэффициента силуэта (silhouette score);
7. применять алгоритм DBSCAN для поиска кластеров произвольной формы и шумовых точек;
8. интерпретировать полученные кластеры и выявленные аномалии;
9. оформлять результаты анализа в виде структурированного отчёта.

4. Краткие теоретические сведения

4.1. Неконтролируемое обучение

Неконтролируемое обучение (Unsupervised Learning) – это класс методов машинного обучения, при котором алгоритм получает на вход только признаки объектов без правильных ответов. Основная задача таких методов – выявление скрытой структуры данных.

К типовым задачам неконтролируемого обучения относятся:

- кластеризация объектов;
- снижение размерности;
- поиск аномалий.

4.2. Масштабирование признаков

Во многих алгоритмах неконтролируемого обучения (в частности, KMeans и DBSCAN) расстояния между объектами играют ключевую роль. Если признаки имеют разные масштабы, алгоритм будет некорректно оценивать близость объектов. Поэтому перед применением методов кластеризации выполняется масштабирование признаков.

4.3. Метод KMeans

KMeans (К-средних) – алгоритм кластеризации, который разбивает набор данных на заранее заданное число кластеров k , минимизируя внутрикластерное расстояние между объектами.

Алгоритм KMeans эффективен для данных с относительно компактными и близкими по форме кластерами.

4.4. Коэффициент силуэта

Коэффициент силуэта (silhouette score) используется для оценки качества кластеризации и показывает, насколько хорошо объекты отделены друг от друга в рамках кластеров.

4.5. Алгоритм DBSCAN

DBSCAN – алгоритм плотностной кластеризации, который способен выявлять кластеры произвольной формы и выделять шумовые точки, не принадлежащие ни одному кластеру.

4.6. Метод главных компонент (PCA)

PCA (Principal Component Analysis) – метод снижения размерности данных, позволяющий представить многомерные данные в пространстве меньшей размерности с сохранением наибольшей части дисперсии.

5. Описание практического задания

Студенту предлагается выполнить анализ набора данных по индивидуальному варианту (1–15), представленного в формате CSV и не содержащего целевой переменной.

В ходе выполнения работы необходимо:

1. загрузить и проанализировать данные;
2. выполнить масштабирование признаков;
3. применить PCA для визуализации данных;
4. выполнить кластеризацию методом KMeans и оценить её качество;
5. выполнить кластеризацию методом DBSCAN;
6. (при необходимости) выполнить поиск аномалий;
7. проанализировать и интерпретировать полученные результаты.

6. Пошаговый алгоритм выполнения работы

Шаг 1. Подготовка данных

Скачайте файл CSV своего варианта и поместите его в одну папку с ноутбуком практического занятия.

Шаг 2. Первичный анализ данных

Изучите структуру данных, количество признаков, наличие пропусков и описательные статистики.

Шаг 3. Масштабирование признаков

Выполните масштабирование признаков с использованием StandardScaler и объясните необходимость данного шага.

Шаг 4. PCA и визуализация

Примените PCA для снижения размерности до двух компонент и постройте диаграмму рассеяния.

Шаг 5. Кластеризация KMeans

Подберите число кластеров, рассчитайте коэффициент силуэта и визуализируйте результат.

Шаг 6. Кластеризация DBSCAN

Подберите параметры алгоритма DBSCAN, определите число кластеров и шумовых точек, выполните визуализацию.

Шаг 7. Анализ результатов

Сравните результаты KMeans и DBSCAN, сделайте выводы о структуре данных.

7. Требования к отчёту

Отчёт по практическому занятию должен содержать:

1. титульную часть;
2. описание набора данных;
3. результаты PCA и визуализации;
4. результаты кластеризации KMeans;
5. результаты кластеризации DBSCAN;
6. интерпретацию результатов;
7. итоговые выводы.

8. Критерии оценки

Оценка за практическое занятие выставляется с учётом:

- корректности выполнения всех этапов работы;

- обоснованности выбора параметров алгоритмов;
- качества визуализаций;
- глубины интерпретации результатов;
- логичности и полноты выводов.

Практическое занятие №6 считается выполненным при наличии всех обязательных этапов анализа и обоснованных выводов.