

**Федеральное государственное бюджетное образовательное учреждение высшего
образования
«Херсонский государственный педагогический университет»**

Дисциплина «Системы обработки больших данных»

ПРАКТИЧЕСКОЕ ЗАНЯТИЕ ПЗ-7

**Анализ масштабируемости обработки данных на одном
компьютере:
полная загрузка, chunked batch и квазипотоковый режим**

*Методическая разработка для студентов магистратуры
направления 09.04.04 «Программная инженерия»*

Связь с лекцией	Лекция 3.2
Форма работы	Индивидуальный вариант, работа в Jupyter Notebook
Комплект материалов	Методичка, ноутбук, 15 датасетов, каталог вариантов

1. Общая характеристика практического занятия

Практическое занятие ПЗ-7 открывает цикл прикладной работы по Лекции 3.2 «Масштабирование и вычислительные ограничения в Data Science и Big Data». Если в лекции основное внимание уделялось теоретическому осмыслению ограничений памяти, времени, архитектуры и режимов обработки данных, то в настоящей работе студент должен увидеть эти ограничения в реальном вычислительном процессе и научиться переводить их в инженерные решения.

Ключевая идея занятия состоит в том, что граница между «обычным» анализом данных и Big Data определяется не только размером файла, а тем, как меняется логика работы системы. Пока исследователь может безболезненно загрузить датасет в память, выполнить очистку, агрегирование и визуализацию, задача остаётся в пределах комфортного режима локальной аналитики. Но как только объём и частота поступления данных начинают требовать иной организации чтения, инкрементальных вычислений и архитектурных компромиссов, возникает необходимость мыслить как инженер, а не только как аналитик.

Практика построена так, чтобы студент последовательно сравнил три вычислительных режима: полную загрузку датасета в память, пакетную обработку по чанкам и квазипотоковую обработку небольшими порциями событий. Итогом должно стать не просто получение агрегатов, а аргументированное решение: какой режим обработки адекватен конкретной прикладной задаче, где находятся узкие места и в какой момент локальной среды уже недостаточно.

2. Цель, задачи и формируемые результаты обучения

2.1. Цель практического занятия

Научить студента анализировать вычислительные ограничения локальной среды и выбирать режим обработки данных в зависимости от масштаба, структуры событий и требований к задержке результата.

2.2. Задачи практического занятия

- оценить размер датасета и приблизительную стоимость его полной загрузки в память;
- выполнить пакетную обработку с полной загрузкой файла и сформировать ключевые агрегаты;
- реализовать chunked batch-обработку и сравнить её результаты и вычислительную цену с полной загрузкой;
- смоделировать квазипотоковый режим обработки событий;
- подготовить инженерную интерпретацию полученных результатов;
- обосновать, когда локальной обработки достаточно, а когда требуется переход к более сложной архитектуре.

2.3. Результаты обучения

- понимать, какие характеристики данных и вычислительной среды определяют необходимость масштабирования;
- уметь сравнивать полную загрузку, chunked batch и квазипотоковую обработку по времени, памяти и удобству реализации;
- уметь формулировать ограничения локальной среды на языке инженерных рисков;
- уметь связать вычислительные наблюдения с содержательной постановкой прикладной задачи;
- подготавливать аргументированное архитектурное заключение по своему варианту.

3. Место ПЗ-7 в структуре курса

Практическое занятие ПЗ-7 логически продолжает ПЗ-1 – ПЗ-6, но отличается от них акцентом: в центре внимания теперь не выбор модели сам по себе, а вычислительная цена обработки данных и способы адаптации конвейера к росту нагрузки.

ПЗ-7 подготавливает студента к ПЗ-8, где акцент будет сделан на сравнении архитектурных решений и обосновании перехода от локальной аналитики к более сложным системным сценариям.

Материалы занятия концептуально согласуются с линией книги-основы курса: после главы о моделировании и машинном обучении книга переходит к проблемам работы с большими объёмами данных на одном компьютере, затем – к распределённым инфраструктурам и полноценным Big Data-системам. [filecite](#)[turn1file14](#)

4. Программная среда и состав комплекта

Все материалы занятия размещаются в одной папке. Это принципиально важно: ноутбук использует относительные пути и предполагает, что каталог вариантов и соответствующие CSV-файлы лежат рядом с `.ipynb`.

В состав комплекта входят: ноутбук `PZ\_7\_scaling\_big\_data.ipynb`, файл `variant\_catalog.csv` и 15 датасетов `variant\_01.csv` ... `variant\_15.csv`.

Ноутбук рассчитан на выполнение в стандартной среде Python 3 с библиотеками `pandas`, `numpy` и `matplotlib`. Этот выбор осознан: студент должен увидеть, что даже в привычной локальной среде возможно сравнительное исследование режимов обработки данных, но при этом должны быть явно выявлены её границы.

5. Теоретический минимум перед выполнением

Перед началом работы студент должен уверенно различать три понятия: полный пакетный режим, обработка по чанкам и потоковая логика. Полный пакетный режим предполагает чтение всего набора данных в память и последующую работу с завершённым массивом. Chunked batch по-прежнему остаётся пакетной обработкой, но меняет организацию вычислений: файл читается частями, а агрегаты накапливаются инкрементально. Потоковая логика, даже если она моделируется локально, ориентирована не на готовый массив, а на последовательность событий, приходящих небольшими порциями.

Второй обязательный понятийный блок – вычислительная стоимость операций. Для данной работы важно, чтобы студент оценивал не только качество итоговых таблиц, но и цену их получения: память, время, число промежуточных структур, удобство поддержки кода, чувствительность к росту объёма данных.

Третий блок – инженерная интерпретация. Практическая работа не сводится к техническому сравнению двух фрагментов кода. Задача студента – перевести вычислительные наблюдения в вывод о подходящей архитектуре: локальный batch, chunked batch на одном узле, смешанный batch/stream или необходимость перехода к распределённой системе.

6. Пошаговый порядок выполнения работы

Шаг 1. Выбор варианта и чтение каталога вариантов.

Студент указывает номер своего варианта от 1 до 15, открывает каталог ``variant_catalog.csv`` и фиксирует тематику датасета, содержательное описание события и индивидуальный исследовательский вопрос. Этот шаг обязателен: все последующие выводы должны опираться не на абстрактный CSV-файл, а на предметную интерпретацию выбранного кейса.

Шаг 2. Первичная оценка файла без полной загрузки.

Нужно определить размер файла на диске, загрузить небольшую выборку, оценить типы данных и приблизительно посчитать объём памяти, который потребуется при полной загрузке. На этом этапе студент должен письменно ответить, почему анализ масштабируемости следует начинать именно с такой диагностики.

Шаг 3. Полная batch-обработка.

Далее студент загружает датасет целиком, выполняет минимальную подготовку данных, строит базовые агрегаты и измеряет время выполнения. Этот режим является контрольной точкой: он показывает максимально простой и привычный сценарий работы аналитика.

Шаг 4. Chunked batch-обработка.

На этом этапе файл читается частями. Студент должен реализовать накопление агрегатов без хранения полного DataFrame, затем сравнить результаты с предыдущим шагом и

объяснить, почему совпадение результатов не означает тождественности вычислительной логики.

Шаг 5. Квазипотоковая обработка.

Здесь моделируется работа с последовательностью событий. Файл читается малыми порциями, по часам или иным окнам рассчитываются оперативные показатели, выделяются аномальные интервалы. Важно понять, что в данном случае студент не строит полноценную streaming-систему, а воспроизводит её вычислительную логику в учебной среде.

Шаг 6. Инженерная интерпретация и итоговый вывод.

Студент готовит итоговое заключение: какой режим обработки предпочтителен, где находится узкое место, когда локальной среды будет достаточно, а при каком росте нагрузки потребуется переход к другой архитектуре.

7. Индивидуальные варианты

В таблице представлены все 15 вариантов практической работы. Каждый студент выполняет общий вычислительный сценарий, но даёт собственную содержательную интерпретацию и архитектурное заключение.

Вариант	Тематика	Описание	Индивидуальный вопрос
1	Онлайн-ритейл	События оформления и выполнения заказов интернет-магазина	Оцените устойчивость конвейера при росте числа заказов и возвратов.
2	Городской транспорт	События валидаторов и турникетов городского транспорта	Сравните режимы пакетной и квазипотоковой обработки транспортных событий.
3	Агросенсоры	Телеметрия датчиков агропредприятия южного региона	Определите, достаточно ли локальной обработки телеметрии сенсоров.
4	Логистика	События сканирования грузовых единиц на сортировочном узле	Выявите узкие места при пакетной обработке логистических сканов.
5	Здравоохранение	События регистрации пациентов и оказания услуг	Оцените, какие показатели качества сервиса можно считать в потоке, а какие – пакетно.
6	Телеком	События сетевых сессий и сервисных операций	Сравните вычислительную цену агрегирования телеком-событий разными способами.

7	Госуслуги	События цифровых заявок и обращений граждан	Обоснуйте архитектуру обработки массовых цифровых заявок граждан.
8	Умные счётчики	События интеллектуального учёта электроэнергии	Проведите анализ масштабируемости расчёта суточных начислений по показаниям счётчиков.
9	EdTech / LMS	События образовательной платформы университета	Оцените применимость потоковых агрегатов для событий LMS.
10	Туризм и бронирование	События поиска и бронирования туристических услуг	Обоснуйте режим обработки для бронирований и отмен.
11	Складская система	Операции приёмки, размещения и комплектования	Выберите способ агрегирования складских операций с учётом задержки и стоимости.
12	Банковские операции	События карточных и дистанционных операций	Сформулируйте критерии перехода от локальной обработки к распределённой.
13	Погодный мониторинг	События сбора данных с погодных станций	Сравните пакетный и потоковый мониторинг погодных показателей.
14	Дорожные детекторы	События транспортных детекторов и камер наблюдения	Определите, какие дорожные события требуют минимальной задержки обработки.
15	Орошение и мелиорация	События системы управления поливом	Обоснуйте пайплайн для управления поливом при непрерывном поступлении данных.

8. Требования к содержанию студенческого отчёта

В отчёте обязательно должны присутствовать: паспорт датасета, оценка размера и памяти, результаты batch-обработки, результаты chunked batch, результаты квазипотокового режима, ответ на индивидуальный вопрос варианта и итоговая архитектурная рекомендация.

Каждый раздел отчёта должен содержать не только таблицы и рисунки, но и текстовое объяснение. Практика оценивается не по факту запуска кода, а по качеству инженерной интерпретации.

В итоговом выводе студент обязан явно ответить на вопрос: где в данном кейсе проходит граница между обычной локальной аналитикой и задачей, требующей Big Data-подхода.

9. Критерии оценивания

Компонент оценки	Содержание	Баллы
Корректность выполнения ноутбука	Все этапы выполнены, графики и таблицы воспроизводимы, код работает на своём варианте.	0–30
Сравнение режимов обработки	Проведено содержательное и количественное сравнение full batch, chunked batch и квазипотока.	0–20
Инженерная интерпретация	Выявлены ограничения локальной среды, показаны узкие места и сделан корректный архитектурный вывод.	0–25
Индивидуальный вопрос варианта	Дан аргументированный ответ по тематике выбранного кейса.	0–15
Качество оформления и выводов	Структурированный отчёт, ясный научный язык, отсутствие формальных и логических пробелов.	0–10

10. Контрольные вопросы для самопроверки

1. Почему размер CSV-файла на диске не совпадает с объёмом памяти, который нужен для анализа?
2. Почему chunked batch остаётся пакетной обработкой, хотя файл читается частями?
3. В чём принципиальное отличие потоковой логики от частого запуска пакетных пересчётов?
4. Какие операции чаще всего становятся узкими местами локального конвейера обработки данных?
5. В каких случаях усложнение архитектуры оправдано, а в каких – избыточно?

11. Состав файлов, сдаваемых студентом

- заполненный ноутбук `PZ\_7\_scaling\_big\_data.ipynb`;
- краткий текстовый отчёт или развёрнутые выводы в самом ноутбуке;
- при необходимости – экспорт ноутбука в PDF или HTML.

12. Итоговое методическое замечание

Настоящее практическое занятие имеет принципиально важное место в курсе. Оно переводит обсуждение больших данных из плоскости общих слов и перечней технологий в плоскость инженерного мышления. Студент должен увидеть, что Big Data начинаются не там, где файл просто «большой», а там, где требуется пересмотр логики чтения, обработки, контроля задержки и архитектурной организации вычислений. Именно это понимание делает ПЗ-7 естественным мостом к ПЗ-8 и к следующей лекции об инфраструктуре Big Data и промышленных пайплайнах.