

Практическое занятие 3.3.1

Проектирование архитектуры Big Data-системы и промышленного пайплайна обработки данных

1. Общая характеристика занятия

Практическое занятие 3.3.1 проводится после лекции «Инфраструктура Big Data и промышленные пайплайны обработки данных» и является первым практическим закреплением этой темы. Его принципиальная особенность состоит в том, что студент здесь не программирует алгоритм в узком смысле слова, а осваивает **архитектурное мышление**, то есть учится видеть будущую систему обработки данных как целостную инженерную конструкцию.

Если в предыдущих темах студент уже работал с этапами Data Science, очисткой данных, исследовательским анализом и моделированием, то теперь он должен сделать следующий шаг и понять, что аналитика не существует в вакууме. Любая работающая система должна включать источник данных, механизм загрузки, хранилище, вычислительный слой, аналитический слой, средства представления результатов, а также механизмы автоматизации, контроля и сопровождения. Именно поэтому практическое занятие строится не вокруг вычисления метрики или построения модели, а вокруг **проектирования Big Data-пайплайна для прикладной задачи**.

Методически это занятие особенно важно для магистрантов направления «Программная инженерия», поскольку оно формирует у них привычку мыслить не изолированными скриптами, а жизненным циклом данных и архитектурой цифровой системы. В этом смысле ПЗ 3.3.1 является своего рода «мостом» между аналитической логикой курса и инженерной логикой последующих работ.

2. Цель практического занятия

Сформировать у обучающихся умение проектировать **концептуальную архитектуру Big Data-системы** и описывать **промышленный пайплайн обработки данных** для конкретной прикладной задачи на основе анализа источников данных, требований к хранению, обработке, аналитике, представлению результатов и автоматизации.

3. Задачи практического занятия

В ходе выполнения практического занятия студент должен решить следующие задачи.

Во-первых, необходимо проанализировать прикладную задачу и определить, какие данные требуются для её решения, кто является поставщиком этих данных, кто будет использовать результат и в каком режиме этот результат должен формироваться.

Во-вторых, необходимо выделить и охарактеризовать источники данных, определить их тип, формат, структуру, периодичность обновления, ожидаемый объём и возможные проблемы качества.

В-третьих, необходимо спроектировать маршрут движения данных внутри системы, то есть пайплайн: от получения данных до их преобразования, хранения, аналитической обработки и выдачи результата.

В-четвёртых, необходимо определить архитектурные слои системы: интеграцию, хранение, вычисления, аналитику, представление, автоматизацию и контроль.

В-пятых, необходимо разграничить offline- и online-компоненты, если задача предполагает как пакетную, так и оперативную обработку.

В-шестых, необходимо указать, где и каким образом в системе возникают роли Data Engineer и Data Scientist.

В-седьмых, необходимо представить проектное решение в инженерно понятной форме: в виде схемы, таблицы компонентов и пояснительной записки.

4. Планируемые результаты обучения

После выполнения практического занятия студент должен уметь:

понимать прикладную задачу как задачу проектирования системы обработки данных, а не только как задачу анализа;

выделять источники данных и классифицировать их как структурированные, неструктурированные, событийные, потоковые, журнальные, транзакционные и справочные;

проектировать пайплайн обработки данных, отражающий полный жизненный цикл данных;

определять место хранения данных, вычислительного слоя, аналитического слоя и слоя представления результата;

различать пакетную и потоковую логику обработки;

обосновывать необходимость оркестрации и автоматизации;

разграничивать функции Data Engineer и Data Scientist в рамках одного проекта;

представлять архитектурное решение в структурированном виде.

5. Краткие теоретические положения

Перед началом выполнения работы преподаватель должен кратко актуализировать основные понятия, без которых проектирование Big Data-системы невозможно.

Big Data – это большие данные, то есть данные, для которых обычные средства локальной обработки и хранения оказываются недостаточными или неэффективными. Ключевыми характеристиками больших данных обычно называют объём, скорость поступления, разнообразие и достоверность. В книге курса подчёркивается, что большие данные требуют специализированных подходов к сбору, хранению, обработке, поиску, передаче и визуализации.

Pipeline или пайплайн – это технологическая цепочка обработки данных. В общем виде пайплайн описывает, как данные проходят путь от источника до конечного результата. Пайплайн может включать извлечение данных, очистку, интеграцию, преобразование, агрегацию, аналитическую обработку, применение модели, построение отчёта и автоматизацию. В книге Data Science рассматривается как процесс, включающий сбор, подготовку, исследование, моделирование и затем отображение и автоматизацию, что напрямую поддерживает идею пайплайна.

Источник данных – это система, устройство, база, журнал, API или иной объект, из которого данные поступают в анализируемую систему. Источники могут быть внутренними и внешними, периодическими и потоковыми, цифровыми и документальными.

Data ingestion – загрузка или ввод данных в систему. Этот термин часто используется в инженерии данных для обозначения фазы, на которой данные принимаются из внешних или внутренних источников.

Хранилище данных – среда долговременного или оперативного хранения данных. В Big Data-системах могут использоваться распределённые файловые системы, реляционные базы данных, NoSQL-хранилища, витрины данных, озёра данных и индексные хранилища. В книге отдельно выделяются распределённые файловые системы, Hadoop, NoSQL и связанные с ними инструменты.

Вычислительный слой – совокупность средств, выполняющих обработку данных: фильтрацию, агрегацию, преобразование, индексирование, расчёт признаков и другие операции.

Аналитический слой – уровень системы, на котором выполняются аналитические запросы, статистическая обработка, построение признаков, машинное обучение и подготовка результатов для принятия решений.

Слой представления – интерфейсы, отчёты, панели мониторинга, витрины, API и другие механизмы, через которые результат анализа становится доступен пользователю или другой системе.

Оркестрация – управление последовательностью выполнения задач, зависимостями между ними, расписанием и повторным запуском при ошибках. В книге экосистема больших данных включает инструменты планирования, что подчёркивает значимость этого уровня.

Offline-аналитика – пакетная обработка уже накопленных данных.

Online-аналитика – обработка данных в момент поступления или с минимальной задержкой.

Data Scientist – специалист, который отвечает за аналитическую постановку задачи, исследование данных, построение признаков, выбор модели и интерпретацию результата.

Data Engineer – специалист, который отвечает за загрузку, хранение, преобразование, передачу, масштабирование и эксплуатационную надёжность пайплайна.

6. Оснащение и программные средства

Для выполнения работы студенту требуется компьютер и одно или несколько программных средств для построения схем и оформления результата. Допускается использование PowerPoint, Draw.io, Microsoft Visio, Figma, Canva, LibreOffice Draw и иных инструментов, пригодных для построения архитектурной диаграммы.

На данном этапе написание программного кода не является обязательным, поскольку цель занятия – концептуальное проектирование. Однако если студент хочет использовать табличные редакторы или текстовый процессор для оформления таблиц компонентов пайплайна, это допускается.

7. Организация индивидуальной работы

Каждый студент получает **индивидуальный вариант прикладной задачи**. Несмотря на различие предметных областей, структура выполнения работы у всех одина. Это позволяет сохранять единые критерии оценивания и одновременно обеспечивать вариативность содержания. Использование индивидуальных заданий особенно важно, поскольку предотвращает механическое копирование архитектурных схем и заставляет студента проектировать решение осмысленно.

В данном практическом занятии предусмотрено **20 индивидуальных заданий**, из которых преподаватель может распределить 15–20 вариантов в зависимости от численности группы.

8. Порядок выполнения практического занятия

Этап 1. Анализ прикладной задачи

На первом этапе студент внимательно изучает формулировку индивидуального задания и определяет, в чём состоит основная цель разрабатываемой системы. Необходимо ответить на несколько вопросов.

Какова предметная область?

Кто является поставщиком данных?

Кто является конечным пользователем результатов?

Какие решения должны приниматься на основе этих результатов?

Нужна ли реакция в реальном времени или достаточно периодической пакетной обработки?

Результатом этапа является краткое описание прикладной задачи объёмом 0,5–1 страница.

Этап 2. Выделение и характеристика источников данных

На втором этапе студент определяет, какие данные нужны для решения задачи. Для каждого источника необходимо указать:

наименование источника;
тип данных;
примерный формат хранения;
частоту поступления;
предполагаемый объём;
потенциальные проблемы качества.

Возможные типы источников: транзакционные базы, журналы событий, текстовые обращения, телеметрия, файлы CSV, Excel-выгрузки, API, изображения, геоданные, данные датчиков, справочные таблицы.

Результат этапа оформляется в виде таблицы.

Пример структуры таблицы:

№	Источник данных	Тип данных	Формат	Частота поступления	Возможные проблемы
---	-----------------	------------	--------	---------------------	--------------------

Этап 3. Классификация данных

На третьем этапе студент определяет, какие данные являются:

структурированными;
неструктурированными;
полуструктурированными;
потокowymi;
архивными;
оперативными;
справочными.

Это необходимо для того, чтобы обосновать выбор архитектурных компонентов на следующих этапах. Например, потоковые события и архивные таблицы требуют различной логики обработки, а текстовые обращения и транзакционные записи – различного подхода к хранению и анализу.

Результат этапа – текстовый раздел отчёта с классификацией данных.

Этап 4. Проектирование общего пайплайна

На четвёртом этапе студент проектирует общий маршрут движения данных. Пайплайн должен отвечать на вопрос: что происходит с данными от момента их появления до момента использования результата?

Рекомендуется выделить следующие стадии:

- получение данных;
- загрузка в систему;
- первичная проверка и очистка;
- преобразование и нормализация;
- объединение источников;
- сохранение в хранилище;
- агрегация и расчёт признаков;
- аналитическая обработка;
- формирование результата;
- передача результата пользователю или внешней системе.

Студент описывает эти стадии сначала текстом, а затем в виде схемы.

Этап 5. Проектирование архитектурных слоёв

На пятом этапе студент должен представить систему как набор архитектурных слоёв. В простейшем варианте рекомендуется выделить:

- слой источников данных;
- слой интеграции данных;
- слой хранения;
- вычислительный слой;
- аналитический слой;
- слой представления;
- слой оркестрации и контроля.

По каждому слою студент должен кратко описать его функцию. При желании можно дополнительно предложить пример класса технологий, не привязываясь жёстко к конкретному продукту. Например:

- распределённое файловое хранилище;
- реляционная база данных;
- NoSQL-хранилище;
- инструмент потоковой загрузки;
- SQL-движок;

система BI;
планировщик задач.

Результат этапа – архитектурная диаграмма и пояснение к ней.

Этап 6. Определение offline- и online-контуров

Если задача предполагает и накопительный, и оперативный режимы обработки, студент должен разделить их. Нужно указать:

какие данные поступают непрерывно;
какие расчёты могут выполняться ежедневно или еженедельно;
какие результаты нужны в реальном времени;
какие результаты достаточно формировать пакетно.

Если online-компонента отсутствует, студент должен это явно указать и обосновать. Такое решение тоже допустимо, если специфика предметной области не требует мгновенной реакции.

Этап 7. Оркестрация и автоматизация

На этом этапе студент отвечает на вопросы:

какие задачи должны выполняться по расписанию;
какие задачи должны запускаться по событию;
какие задачи зависят друг от друга;
что должно происходить при ошибке на одном из этапов;
какие участки пайплайна нельзя оставлять на ручной запуск.

Не требуется привязка к конкретному инструменту вроде Airflow или Oozie, но логика оркестрации должна быть показана. Можно использовать блок-схему или таблицу зависимостей.

Этап 8. Разграничение ролей

На восьмом этапе студент должен показать, какие части проекта относятся к работе Data Engineer, а какие – к работе Data Scientist.

Например:

Data Engineer отвечает за загрузку данных, организацию хранения, контроль схемы, построение пайплайна и автоматизацию.

Data Scientist отвечает за постановку аналитической задачи, выбор признаков, выбор модели, интерпретацию результатов и оценку качества.

При необходимости можно выделить и третью роль – ВІ-аналитика или пользователя-эксперта, который работает с результатами.

Этап 9. Риски и проблемы качества данных

На девятом этапе студент должен указать, какие риски могут возникнуть в системе:

пропуски и дубликаты;
изменение схемы источника;
ошибки в формате времени;
задержка поступления данных;
неполнота потока;
несогласованность идентификаторов между источниками;
низкое качество текстовых данных;
проблемы доступа и разграничения прав.

Этот этап очень важен методически, потому что он показывает: архитектура – это не только схема «как красиво течёт», но и понимание того, где система может дать сбой.

Этап 10. Подготовка итоговых материалов

По итогам занятия студент готовит комплект материалов.

9. Состав отчёта по практическому занятию

Отчёт должен содержать следующие разделы.

1. Титульный лист

Оформляется по требованиям кафедры.

2. Тема и цель работы

Формулируются в кратком виде.

3. Исходное индивидуальное задание

Приводится текст варианта.

4. Краткое описание предметной задачи

1–2 абзаца.

5. Источники данных и их характеристика

Таблица и текстовый комментарий.

6. Классификация данных

Структурированные, потоковые, журнальные, справочные и др.

7. Общая схема пайплайна

Графическое изображение и пояснение.

8. Архитектура системы по слоям

Схема и краткая расшифровка функций каждого слоя.

9. Разделение offline- и online-процессов

При наличии.

10. Оркестрация и автоматизация

Описание зависимостей и принципов запуска.

11. Разграничение ролей участников проекта

Data Engineer, Data Scientist, пользователь результата.

12. Основные риски и ограничения

Краткий аналитический раздел.

13. Выводы

1–2 страницы с обобщением проектного решения.

10. Требования к итоговым материалам

Студент обязан представить:

одну архитектурную диаграмму;
одну схему общего пайплайна;
не менее одной таблицы источников данных;
не менее одной таблицы распределения ролей или архитектурных слоёв;
краткое пояснение всех ключевых решений.

Важно, чтобы схема не была чисто декоративной. Она должна отражать логику движения данных и функциональную роль основных компонентов.

11. Индивидуальные задания (20 вариантов)

Ниже приводится набор индивидуальных заданий. Каждое задание предполагает проектирование Big Data-системы и промышленного пайплайна обработки данных.

Вариант 1

Спроектировать архитектуру системы анализа банковских транзакций для выявления подозрительных операций и поддержки антифрод-мониторинга.

Вариант 2

Спроектировать архитектуру системы персонализации товарных предложений для крупного маркетплейса на основе истории просмотров, заказов и поисковых запросов.

Вариант 3

Спроектировать архитектуру системы анализа логов цифровой образовательной платформы университета для выявления активности студентов и раннего обнаружения риска академической неуспеваемости.

Вариант 4

Спроектировать архитектуру системы мониторинга телеметрии промышленного оборудования для выявления аномалий и предупреждения отказов.

Вариант 5

Спроектировать архитектуру системы анализа обращений граждан в государственную цифровую приёмную с классификацией тематики и контролем сроков обработки.

Вариант 6

Спроектировать архитектуру системы мониторинга маршрутов городского общественного транспорта на основе геоданных и журналов движения.

Вариант 7

Спроектировать архитектуру системы анализа заказов и сроков доставки в логистической компании для прогнозирования задержек.

Вариант 8

Спроектировать архитектуру системы анализа клиентской активности оператора связи для прогнозирования оттока абонентов.

Вариант 9

Спроектировать архитектуру системы анализа медицинских записей и результатов обследований для поддержки принятия решений в клинике.

Вариант 10

Спроектировать архитектуру системы анализа поведения пользователей мобильного банковского приложения для выявления сценариев использования и подозрительной активности.

Вариант 11

Спроектировать архитектуру системы анализа посещаемости и спроса в сети розничных магазинов на основе данных касс, чеков и складских остатков.

Вариант 12

Спроектировать архитектуру системы анализа заявок в службу технической поддержки ИТ-компании с автоматической маршрутизацией обращений.

Вариант 13

Спроектировать архитектуру системы анализа публикаций и пользовательской активности в социальной платформе для выявления трендов и аномального поведения.

Вариант 14

Спроектировать архитектуру системы мониторинга энергопотребления в жилом или промышленном объекте на основе данных счётчиков и датчиков.

Вариант 15

Спроектировать архитектуру системы анализа дорожной обстановки на основе камер, датчиков и сообщений от навигационных сервисов.

Вариант 16

Спроектировать архитектуру системы анализа сельскохозяйственных данных для мониторинга состояния полей, погодных факторов и прогнозирования урожайности.

Вариант 17

Спроектировать архитектуру системы анализа транзакций и клиентских действий в интернет-магазине для выявления брошенных корзин и настройки маркетинговых кампаний.

Вариант 18

Спроектировать архитектуру системы анализа документов и контрактов в крупной организации для поиска, классификации и контроля исполнения.

Вариант 19

Спроектировать архитектуру системы мониторинга киберинцидентов на основе сетевых журналов, журналов безопасности и событий аутентификации.

Вариант 20

Спроектировать архитектуру системы анализа туристических потоков и загрузки инфраструктуры региона на основе бронирований, транспортных данных и событий посещения.

12. Контрольные вопросы

1. Что такое промышленный пайплайн обработки данных?
2. Чем источник данных отличается от хранилища?
3. Почему в системе обработки данных необходимо различать offline- и online-режимы?
4. В чём состоит назначение оркестрации?
5. Какие функции в проекте выполняет Data Engineer?
6. Какие функции в проекте выполняет Data Scientist?
7. Почему архитектура Big Data-системы не сводится к одной базе данных?
8. Какие риски качества данных наиболее опасны для проектируемой системы?
9. Почему результат анализа должен быть встроен в слой представления?
10. Чем отличается разовый аналитический расчёт от эксплуатационного решения?

13. Критерии оценивания

Оценка работы может проводиться по следующим критериям:

Отлично – задача проанализирована глубоко, источники данных выявлены корректно, архитектурная схема логична и полна, пайплайн описан последовательно, offline/online-режимы выделены обоснованно, роли участников разграничены правильно, выводы аргументированы.

Хорошо – задача в целом проработана верно, схема отражает основную логику системы, но отдельные элементы раскрыты неполно или слабо аргументированы.

Удовлетворительно – проектное решение дано в общих чертах, но отсутствует достаточная детализация источников, слоёв или пайплайна; логика автоматизации и разграничения ролей раскрыта поверхностно.

Неудовлетворительно – отсутствует целостное понимание архитектуры, схема формальна, пайплайн не прослеживается, ключевые компоненты системы не выделены.

14. Рекомендации студенту

При проведении занятия важно следить, чтобы студенты не подменяли архитектурное проектирование перечислением модных технологий. Главная

цель – не назвать как можно больше известных продуктов, а показать логически непротиворечивую структуру движения данных и обработки результатов.

Также важно подробно обосновывать решения. Например, если студент указывает потоковую обработку, он должен объяснить, почему без неё нельзя обойтись. Если студент говорит о пакетном режиме, он должен показать, почему этого достаточно. Если выбирается NoSQL-хранилище, нужно указать, какие особенности данных делают его разумным.

Особое внимание будет уделено заключительному обсуждению, в котором студенты сравнивают разные варианты. Это позволяет увидеть, что одна и та же общая архитектурная логика может проявляться в разных предметных областях по-разному.

15. Вывод по ПЗ 3.3.1

Практическое занятие 3.3.1 должно привести студента к очень важному профессиональному выводу: **аналитика становится ценной только тогда, когда она встроена в архитектуру системы обработки данных**. В этом и состоит главный смысл темы «Инфраструктура Big Data и промышленные пайплайны обработки данных».