

## Практическое занятие 4.1.1

### Диагностика узких мест при обработке больших наборов данных на одном компьютере

---

*Подробная методическая разработка для студентов магистратуры*

*Дисциплина: «Системы обработки больших данных»*

|                               |                                                                                                           |
|-------------------------------|-----------------------------------------------------------------------------------------------------------|
| <b>Направление подготовки</b> | 09.04.04 Программная инженерия                                                                            |
| <b>Тема практики</b>          | Диагностика узких мест при обработке больших наборов данных на одном компьютере                           |
| <b>Формат выполнения</b>      | Индивидуальная работа в Jupyter Notebook с использованием подготовленного набора учебных файлов           |
| <b>Итоговый продукт</b>       | Заполненный ноутбук, краткий отчёт и аналитические выводы о памяти, времени и вычислительных узких местах |

#### 1. Общая характеристика занятия

Практическое занятие 4.1.1 открывает блок работ по теме обработки больших данных на одном компьютере и служит мостом между теоретическим обсуждением проблем памяти и скорости и последующими более сложными примерами single-node Big Data. Его главная особенность состоит в том, что здесь студент не строит сложную интеллектуальную модель, а учится видеть вычислительную сторону аналитической задачи: где возрастает потребление памяти, почему один и тот же файл может обрабатываться по-разному при полной загрузке и при блочном чтении, каким образом структура файла и количество проходов по данным влияют на время выполнения.

В методическом отношении занятие специально построено так, чтобы студент последовательно сравнил три режима работы с данными: полную загрузку файла в память, пофайловую обработку набора частей и блочную обработку одного крупного файла с использованием параметра `chunksize`. Такое сравнение соответствует логике Лекции 4.1, где в качестве центральных проблем выделяются нехватка памяти, чрезмерное время выполнения и возникновение вычислительных узких мест, а решения связываются с адаптацией алгоритмов, выбором структур данных и использованием подходящих инструментов.

Выполнение работы должно сформировать у обучающегося правильное профессиональное отношение к задачам обработки данных большого объёма. После практики студент должен уметь обосновать не только корректность вычислений, но и вычислительную рациональность выбранного способа обработки. Именно это умение потребуется на следующих практических и лекционных занятиях, где будут рассматриваться алгоритмы, структуры данных и инструменты для более глубокого решения подобных задач.

## 2. Цель, задачи и планируемые результаты обучения

Цель практического занятия заключается в формировании у студентов умений диагностировать узкие места при обработке данных большого объёма на одном компьютере и выбирать рациональный режим вычислений в зависимости от характеристик файла и структуры набора данных.

### Основные задачи занятия:

- освоить измерение времени выполнения и приблизительного потребления памяти в процессе обработки данных;
- сравнить полную загрузку в память, пофайловую обработку и чтение по чанкам;
- установить влияние объёма файла, числа столбцов, наличия текстовых признаков и структуры хранения на вычислительные затраты;
- научиться формулировать инженерный вывод о рациональности выбранного способа обработки данных.

### После выполнения работы студент должен:

- различать вычислительные особенности трёх способов обработки данных;
- объяснять, почему размер файла на диске и объём памяти во время обработки не совпадают;
- определять, когда полная загрузка ещё допустима, а когда её следует заменить пофайловой или блочной обработкой;
- оформлять выводы в терминах памяти, времени, формата данных и количества проходов по набору.

## 3. Материально-техническое и программное обеспечение

Для выполнения работы необходим персональный компьютер с установленной средой Python 3, Jupyter Notebook или JupyterLab, а также библиотеками pandas, numpy и, при наличии, psutil для оценки использования памяти процессом. Методическая разработка и ноутбук ориентированы на использование относительных путей, то есть предполагают, что файл ноутбука и учебные датасеты расположены в одном рабочем каталоге.

Используемые наборы данных являются синтетическими и подготовлены специально для учебных целей. Это позволяет безопасно проводить вычислительные эксперименты на типовом учебном оборудовании, не обращаясь к внешним источникам и не загружая чрезмерно слабые компьютеры. В то же время объём и структура файлов достаточны для того, чтобы различия между тремя режимами обработки были заметны и могли быть осмыслены студентами на практике.

## 4. Краткие теоретические сведения

При работе с большими данными на одном компьютере возникают три группы проблем. Первая группа связана с памятью: набор данных или промежуточные структуры не помещаются в оперативную память, вследствие чего система начинает использовать диск как расширение памяти или завершает программу ошибкой. Вторая группа проблем касается времени выполнения: программа может формально работать корректно, но требовать слишком много времени для получения результата. Третья группа — это узкие места, когда производительность всей системы определяется не самой моделью, а наиболее медленным компонентом вычислительной цепочки: диском, памятью, форматом данных или неудачным количеством проходов по файлу.

В инженерной практике один и тот же аналитический результат может быть получен несколькими способами. Если мы полностью загружаем файл в память, то получаем максимальное удобство работы с таблицей, но платим за это повышенным потреблением памяти и иногда длительным временем преобразований. Если мы обрабатываем набор пофайлово, то уменьшаем пиковую нагрузку на память, но можем увеличить накладные расходы на открытие и последовательную обработку множества файлов. Если же используем чтение по чанкам, то стремимся к компромиссу: большой файл остаётся единым, но в память попадает лишь часть строк, достаточная для текущего этапа вычисления.

Отсюда следует центральный методический тезис занятия: рациональность обработки данных определяется не только формальной правильностью вычислений, но и тем, как организован доступ к данным. Именно поэтому в данной работе измеряются не только итоговые статистики, но и время, изменение объёма занимаемой памяти, число строк, количество столбцов и особенности структуры файлов.

## 5. Структура учебного набора данных

Для практики подготовлено несколько файлов с различной структурой. Небольшой табличный файл позволяет увидеть базовую картину поведения при полной загрузке. Средний файл демонстрирует, как увеличивается цена чтения и вычислений с ростом числа строк. Широкий файл используется для анализа влияния числа столбцов на память и время. Файл со смешанными полями, включающий текстовые признаки, наглядно показывает, что размер на диске и объём памяти во время обработки могут заметно различаться. Отдельно подготовлен сенсорный набор данных как в виде одного крупного файла, так и в виде папки из нескольких частей, что делает возможным корректное сравнение блочного и пофайлового режимов.

| Файл / папка     | Назначение                | Структура                                                | Использование в работе               |
|------------------|---------------------------|----------------------------------------------------------|--------------------------------------|
| sales_small.csv  | Небольшой табличный набор | Числовые и категориальные поля, умеренное число столбцов | Базовый пример полной загрузки       |
| sales_medium.csv | Средний табличный набор   | Те же поля, больший объём строк                          | Сравнение полной и блочной обработки |

| Файл / папка        | Назначение                | Структура                                           | Использование в работе             |
|---------------------|---------------------------|-----------------------------------------------------|------------------------------------|
| sales_wide.csv      | Широкий набор             | Большое число числовых и бинарных столбцов          | Анализ влияния числа признаков     |
| events_text.csv     | Смешанный набор с текстом | Числовые, категориальные и текстовые поля           | Анализ влияния строковых признаков |
| sensor_combined.csv | Единый сенсорный файл     | Числовые и категориальные поля, большой объём строк | Блочная обработка крупного файла   |
| sensor_parts/       | Папка из частей           | Тот же сенсорный набор, разбитый на 8 CSV-файлов    | Пофайловая обработка               |

## 6. Логика выполнения практической работы

Практическая работа состоит из трёх базовых экспериментов. В первом эксперименте студент полностью загружает выбранный файл в память и вычисляет простые статистики: число строк, число столбцов, количество пропусков, число числовых полей и агрегированные показатели по варианту. Во втором эксперименте тот же принцип статистической обработки применяется к набору, разбитому на несколько файлов: каждый файл читается отдельно, частичные результаты суммируются, а затем объединяются в общую таблицу. В третьем эксперименте аналогичная статистика вычисляется при чтении большого файла по чанкам.

Во всех трёх случаях студент фиксирует время выполнения и ориентировочное изменение использования памяти процессом. Затем результаты сводятся в общую сравнительную таблицу, на основе которой формулируется инженерный вывод. Особое внимание следует уделить тому, что результаты сравниваются не как «абсолютно лучшие» и «абсолютно худшие», а применительно к свойствам конкретного набора данных. Так, файл с текстовыми признаками может вести себя иначе, чем широкий числовой файл, а слишком маленький chunksize может уменьшить пиковое потребление памяти, но увеличить накладные расходы на частое чтение.

### Пошаговая последовательность действий студента

1. Открыть ноутбук и выбрать номер варианта.
2. Проверить доступность файлов и ознакомиться с их размером на диске.
3. Выполнить эксперимент 1: полная загрузка файла в память.
4. Зафиксировать время, изменение памяти и краткие выводы.
5. Очистить промежуточные объекты и выполнить эксперимент 2: пофайловую обработку.
6. Зафиксировать время, изменение памяти, количество обработанных файлов и выводы.
7. Выполнить эксперимент 3: чтение крупного файла по чанкам с заданным размером блока.
8. Сравнить результаты в сводной таблице.

9. Ответить на аналитические вопросы и сформулировать общий вывод.

## 7. Варианты заданий

Для индивидуализации работы подготовлено пятнадцать вариантов. Варианты отличаются комбинацией файла для полной загрузки, файла для чтения по чанкам, размером чанка, агрегирующим признаком и аналитическим вопросом. Все варианты опираются на один и тот же ноутбук; студент изменяет только номер варианта, после чего требуемые параметры подставляются автоматически.

| № | Полная загрузка     | Чтение по чанкам    | Размер чанка | Группировка / метрика | Ключевой аналитический вопрос                                                                                                                                                              |
|---|---------------------|---------------------|--------------|-----------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1 | sales_small.csv     | sales_medium.csv    | 10000        | region / revenue      | Сравнить полную загрузку sales_small.csv с блочной обработкой sales_medium.csv и пофайловой обработкой sensor_parts. Определить, на каком этапе затраты памяти и времени наиболее заметны. |
| 2 | sales_medium.csv    | sensor_combined.csv | 20000        | category / revenue    | Сравнить два способа обработки крупного файла: полная загрузка и чтение по чанкам. Пояснить, как размер чанка влияет на время и память.                                                    |
| 3 | sales_wide.csv      | sales_wide.csv      | 15000        | region / metric_05    | Проанализировать влияние широкой структуры таблицы на память и время. Сравнить вычисление средних значений metric_05.                                                                      |
| 4 | events_text.csv     | events_text.csv     | 12000        | region / revenue      | Показать, как наличие текстовых признаков влияет на объём памяти при полной загрузке и при чтении по чанкам.                                                                               |
| 5 | sensor_combined.csv | sensor_combined.csv | 40000        | region / power_kw     | Сопоставить полную загрузку sensor_combined.csv, пофайловую обработку папки sensor_parts и блочную обработку того же набора.                                                               |
| 6 | sales_small.csv     | sensor_combined.csv | 25000        | status /              | Для сенсорных                                                                                                                                                                              |

| №  | Полная загрузка     | Чтение по чанкам    | Размер чанка | Группировка / метрика | Ключевой аналитический вопрос                                                                                                                |
|----|---------------------|---------------------|--------------|-----------------------|----------------------------------------------------------------------------------------------------------------------------------------------|
|    |                     |                     |              | load_score            | данных вычислить средние load_score по status разными методами и оценить цену повторных проходов по данным.                                  |
| 7  | sales_medium.csv    | sales_medium.csv    | 5000         | region / quantity     | Исследовать влияние малого размера чанка на время обработки и стабильность потребления памяти.                                               |
| 8  | sales_medium.csv    | sales_medium.csv    | 50000        | category / price      | Исследовать влияние крупного размера чанка на время и память. Сравнить с вариантом 7.                                                        |
| 9  | sales_wide.csv      | sales_medium.csv    | 20000        | region / metric_11    | Сравнить поведение широкого и узкого файлов при одинаковой схеме статистической обработки.                                                   |
| 10 | events_text.csv     | sales_medium.csv    | 10000        | category / revenue    | Оценить, как смешение числовых и текстовых полей влияет на затраты памяти при полной загрузке.                                               |
| 11 | sensor_combined.csv | sensor_combined.csv | 10000        | region / temp         | Сравнить вычисление средних temp для полного файла, папки частей и чтения по чанкам; сделать вывод о выгоде потоковой обработки.             |
| 12 | sales_small.csv     | events_text.csv     | 8000         | region / revenue      | Сравнить небольшой числовой файл и текстовый файл среднего размера; объяснить, почему размер на диске и память в процессе — не одно и то же. |
| 13 | sales_wide.csv      | sensor_combined.csv | 30000        | status / power_kw     | Показать влияние количества столбцов и структуры данных на измеряемые ресурсы.                                                               |

| №  | Полная загрузка  | Чтение по чанкам    | Размер чанка | Группировка / метрика | Ключевой аналитический вопрос                                                                                                |
|----|------------------|---------------------|--------------|-----------------------|------------------------------------------------------------------------------------------------------------------------------|
| 14 | events_text.csv  | sensor_combined.csv | 60000        | region / load_score   | Оценить компромисс между скоростью и памятью при очень крупном чанке.                                                        |
| 15 | sales_medium.csv | sensor_combined.csv | 15000        | region / power_kw     | Сформулировать рекомендации, в каких случаях следует выбирать полную загрузку, а в каких — пофайловую или блочную обработку. |

## 8. Рекомендации по интерпретации результатов

При анализе результатов студенту не следует ограничиваться констатацией того, что один из способов оказался быстрее или медленнее. Необходимо объяснить причину наблюдаемой разницы. Если потребление памяти резко возрастает при полной загрузке, нужно указать, связано ли это с числом строк, с шириной таблицы, с присутствием текстовых признаков или с внутренними преобразованиями pandas. Если чтение по чанкам оказывается медленнее полной загрузки, следует проанализировать, не слишком ли мал размер блока и не возникают ли чрезмерные накладные расходы на многократное создание объектов.

Особо рекомендуется обратить внимание на различие между размером файла на диске и изменением памяти в процессе выполнения. Сжатое или текстовое представление на диске может после чтения превращаться в более объёмную структуру в памяти. Аналогично, наличие большого числа столбцов может заметно увеличивать служебные расходы даже при умеренном числе строк. Это наблюдение подготавливает студента к следующему занятию, где специально будет рассматриваться влияние представления данных на ресурсы.

### Типичные ошибки при выполнении практики

- сравнение результатов без очистки промежуточных объектов между экспериментами;
- попытка делать вывод только по времени без анализа памяти;
- механическое переписывание цифр без объяснения причин различий;
- подмена инженерного вывода описанием только содержательных статистик набора данных;
- изменение кода ноутбука без фиксации того, что именно было изменено.

## 9. Требования к отчёту студента

Отчёт по практической работе должен быть кратким, но аналитически насыщенным. В него обязательно включаются тема, цель, номер варианта, таблицы результатов по трём экспериментам, сводное сравнение и общий вывод. При этом вывод должен быть построен не по шаблону «получено то-то», а в форме инженерного заключения: какой способ обработки

оказался рациональнее, почему именно, какое узкое место проявилось наиболее заметно и как могла бы измениться ситуация на более крупном наборе данных.

| Элемент отчёта          | Что должно быть отражено                                                   |
|-------------------------|----------------------------------------------------------------------------|
| Титульная часть         | Тема, дисциплина, ФИО студента, группа, дата, номер варианта               |
| Описание эксперимента 1 | Файл, показатели времени и памяти, краткий вывод                           |
| Описание эксперимента 2 | Число файлов, показатели времени и памяти, краткий вывод                   |
| Описание эксперимента 3 | Размер чанка, показатели времени и памяти, краткий вывод                   |
| Сводная таблица         | Сопоставление всех трёх способов обработки                                 |
| Заключение              | Инженерный вывод о выявленных узких местах и рациональном режиме обработки |

## 10. Критерии оценивания

Оценивание работы рекомендуется проводить по совокупности критериев. Наивысший балл получает студент, который корректно выполнил все три эксперимента, правильно интерпретировал результаты, сумел объяснить различие между способами обработки и сделал содержательный инженерный вывод. Снижение оценки следует применять не только за ошибки в коде, но и за формальный подход к анализу, когда таблицы результатов приведены, но причины наблюдаемой картины не раскрыты.

| Критерий                              | Содержание                                                                     | Макс. балл |
|---------------------------------------|--------------------------------------------------------------------------------|------------|
| Корректность выполнения экспериментов | Все три режима обработки запущены, результаты получены без методических ошибок | 30         |
| Точность фиксации результатов         | Корректно представлены время, память, размеры и сводная таблица                | 20         |
| Аналитическая интерпретация           | Показаны причины различий между способами обработки                            | 25         |
| Инженерный вывод                      | Сформулировано, где именно проявилось узкое место и какой способ рационален    | 15         |
| Оформление отчёта                     | Аккуратность, логичность, полнота ответов на контрольные вопросы               | 10         |

## 11. Контрольные вопросы

1. Почему размер файла на диске не равен объёму памяти, занятому данными после чтения?
2. В чём различие между полной загрузкой в память, пофайловой обработкой и чтением по чанкам?
3. Почему число столбцов и типы признаков могут существенно влиять на расход памяти?



4. Какие накладные расходы характерны для обработки множества небольших файлов?
5. Почему слишком маленький `chunksize` может ухудшить общее время работы?
6. Что в данной работе следует понимать под узким местом вычисления?
7. Почему для профессионального анализа данных недостаточно оценивать только корректность статистики, игнорируя вычислительные ресурсы?

## 12. Состав комплекта файлов

В состав учебного комплекта входят: подробная методическая разработка в формате DOCX, рабочий Jupyter Notebook для студентов, набор синтетических датасетов и файл `variant_specs.json` с автоматическим описанием вариантов. Все элементы комплекта согласованы между собой и ориентированы на автономное использование без внешних скачиваний.

**Примечание.** Если ноутбук и датасеты были перемещены в другой каталог, необходимо сохранить их совместное расположение: ноутбук должен находиться в одном рабочем каталоге с файлами CSV, JSON и папкой `sensor_parts`.

## 13. Список литературы

1. Документация `pandas`: инструменты чтения табличных данных и обработки по частям.
2. Документация Python и Jupyter Notebook по организации вычислительных экспериментов.