

РАБОЧАЯ ТЕТРАДЬ СТУДЕНТА

Практическая работа № 1

От исходного CSV до проверяемого отчёта

2 пары
практика

600 строк
учебные данные

0 пакетов
к установке

10 баллов
максимум

Результат

Вы запустите локальный пакетный конвейер, исследуете качество данных, измените параметры расчёта, заполните отчёт и загрузите один проверяемый ZIP в ЭИОС.

Фамилия и имя: _____

1. Что понадобится

- компьютер с Windows 10 или Windows 11;
- Python 3; сторонние библиотеки не требуются;
- PDF этой работы и стартовый ZIP из ЭИОС;
- Блокнот, редактор кода или другой текстовый редактор;
- доступ к ЭИОС для отправки итогового ZIP.

Безопасность

Используйте только синтетический набор из комплекта. Не добавляйте реальные фамилии, телефоны, адреса, учётные данные и иные персональные данные.

2. Где выполнять действия

Задача	Где выполнять
Скачать материалы	в ЭИОС через браузер
Распаковать ZIP и запускать CMD	в Проводнике Windows
Изменить settings.json и REPORT.md	в Блокноте или редакторе
Команды вручную, только если попросил преподаватель	в окне cmd, открытом в папке проекта
Отправить результат	в элементе «Задание» ЭИОС

Главное правило

Не работайте внутри ZIP. Сначала правый щелчок → «Извлечь всё», затем откройте распакованную папку starter_big_data.

3. Подготовка среды

1. В ЭИОС скачайте 07_Стартовый_проект_пакетной_обработки.zip.
2. В Проводнике щёлкните ZIP правой кнопкой и выберите «Извлечь всё».
3. Откройте папку starter_big_data.
4. Дважды щёлкните 00_ПРОВЕРИТЬ_СРЕДУ.cmd.
5. Успешный ответ содержит Python 3.x.x. Закройте окно после чтения.

Если Python не найден

Оставайтесь на занятии и выполняйте смысловые шаги по демонстрации. Для установки используйте официальную страницу <https://www.python.org/downloads/windows/> или разрешённый вузом способ. Не отключайте защиту Windows и не скачивайте случайные сборки.

Ручной вариант запуска: откройте папку, щёлкните адресную строку Проводника, введите cmd, нажмите Enter. Затем:

```
py -3 --version
py -3 generate_dataset.py
py -3 pipeline.py
```

Если команда py не найдена, замените `py -3` на `python`.

4. Основные понятия

Термин	Простое объяснение
Volume	объём данных
Velocity	скорость поступления и требуемая скорость ответа
Variety	разные форматы и структуры
Veracity	качество и достоверность
Value	полезность результата
Пакетная обработка	расчёт по накопленному набору
Потоковая обработка	обработка событий по мере поступления
Схема	ожидаемые поля, типы и допустимые значения

Конвейер

ИСТОЧНИК → ПОЛУЧЕНИЕ → ПРОВЕРКА → ПРЕОБРАЗОВАНИЕ → АГРЕГИРОВАНИЕ → СОХРАНЕНИЕ → КОНТРОЛЬ

5. Создание данных

- Запустите 01_СОЗДАТЬ_ДАННЫЕ.cmd.
- Убедитесь, что показано количество 600.
- Откройте папку data и файл events.csv.
- Найдите заголовок и восемь полей.
- Найдите один намеренный дефект поиском по `неизвестно`, `unknown` или `ошибка-даты`.

Поле	Смысл	Пример правила
event_id	идентификатор	не пустой и не повторяется
event_time	время события	корректная дата ISO
user_id	учебный идентификатор	не пустой
region	регион	из допустимого списка
event_type	тип	view/search/cart/purchase
amount	сумма	число, не меньше нуля
status	статус	success/failed/pending
source	источник	web/mobile/partner

6. Исходный запуск

- Запустите 02_ЗАПУСТИТЬ_КОНВЕЙЕР.cmd.
- Дождитесь сообщения об успешном завершении.
- Откройте output/quality_report.txt.

14. Перенесите исходные значения в раздел 1 файла REPORT.md и сохраните его.

Контрольная точка

Входных строк — 600; принято — 576; отклонено — 24. Остальные значения также перепишите из своего отчёта.

Исходные значения:

Показатель	Значение
Входных строк	_____
Принято	_____
Отклонено	_____
Учтено событий	_____
Учтено покупок	_____
Сумма покупок	_____

7. Анализ качества

15. Откройте output/rejected_rows.csv.

16. Выберите одну строку и запишите row_number и reason.

17. Объясните, как этот дефект мог бы исказить расчёт или помешать анализу.

Номер строки и причина: _____

Возможное последствие: _____

8. Эксперимент № 1: порог покупки

18. Откройте settings.json в Блокноте.

19. Измените только min_purchase_amount с 0 на 1000. Число пишется без кавычек.

20. Сохраните Ctrl+S.

21. Повторно запустите 02_ЗАПУСТИТЬ_КОНВЕЙЕР.cmd.

22. Сравните новый quality_report.txt с исходными значениями.

```
"min_purchase_amount": 1000
```

Что должно остаться прежним

Число входных, принятых и отклонённых строк. Порог применяется после проверки качества и не переписывает исходный CSV.

9. Эксперимент № 2: второй статус

23. В settings.json замените список статусов на показанный ниже.

24. Повторите запуск.

25. Запишите, какие показатели изменились и почему.

```
"included_statuses": ["success", "pending"]
```

Наблюдение: _____

10. Смысл выходных файлов

Файл	Что доказывает
region_summary.csv	агрегаты по регионам
event_summary.csv	число событий по типам
rejected_rows.csv	какие строки отклонены и почему
quality_report.txt	краткий отчёт о качестве и расчёте
run_metadata.json	машинно-читаемые параметры и показатели запуска

11. Завершение и сдача

26. Заполните все разделы REPORT.md и вывод из 3–5 предложений.
27. Запустите 03_СОБРАТЬ_РЕЗУЛЬТАТ.cmd.
28. Введите фамилию латиницей без пробелов.
29. Откройте созданный ZIP и проверьте: output, settings.json, REPORT.md.
30. Загрузите один ZIP в элемент «Практическая работа № 1» ЭИОС.
31. Сохраните отправку и нажмите «Отправить на проверку», если эта кнопка включена.
32. Проверьте, что статус не остался черновиком.

12. Контрольные вопросы

33. Почему фиксированного универсального размера Big Data нет?
34. Какой этап должен выполняться до агрегации и почему?
35. Чем техническая валидация отличается от бизнес-фильтра?
36. Зачем сохранять rejected_rows.csv?
37. Что потребуется изменить при переходе от локального файла к распределённой системе?

13. Самопроверка

Готово	Проверка
☐	проект распакован, а не открыт внутри ZIP
☐	исходный запуск дал 600 / 576 / 24
☐	разобрана одна отклонённая строка
☐	выполнены два изменения settings.json
☐	REPORT.md заполнен и сохранён
☐	ZIP содержит output, settings.json и REPORT.md
☐	в ЭИОС отображается отправленная работа

14. Оценивание

Критерий	Баллы
Исходный конвейер и результаты	2
Понимание 5V и этапов	2
Эксперимент с настройками	2
Анализ качества	2
Отчёт и сдача	2
Итого	10