

**Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Херсонский государственный педагогический университет»**

Институт информационных технологий

Кафедра программной инженерии и информационных технологий

ПРАКТИЧЕСКАЯ РАБОТА
по дисциплине:
«Системы обработки больших данных»
на тему:
«От исходного CSV до проверяемого отчёта»

Выполнил:
Студент гр.: 12-25РПм
Трифонов Д.С.

Проверил
Преподаватель:
Гуцол Д.В.

Оценка: _____
Дата: 15.09.2026

Херсон, 2026

ПРАКТИЧЕСКАЯ РАБОТА

От исходного CSV до проверяемого отчёта (пакетный конвейер)

Цель: запустить локальный пакетный конвейер, исследовать качество данных, изменить параметры расчёта и оформить проверяемый отчёт.

1. Исходный запуск конвейера

Сгенерирован учебный набор data/events.csv (600 строк, 8 полей). Выполнен конвейер: ИСТОЧНИК → ПРОВЕРКА → ФИЛЬТР → АГРЕГИРОВАНИЕ → СОХРАНЕНИЕ → КОНТРОЛЬ.

Показатель	Значение
Входных строк	600
Принято	576
Отклонено	24
Учтено событий	192
Учтено покупок	51
Сумма покупок	134966.61

Настройки: min_purchase_amount=0.0, included_statuses=['success'].

2. Анализ качества

Пример отклонённой строки: row_number=52, reason=empty_event_id (event_id="", event_time='2026-01-01T13:57:00', region='east').

Возможное последствие: дефект мог бы исказить агрегаты или вызвать ошибку при расчёте суммы. Отбраковка защищает достоверность (Veracity) результата.

3. Эксперимент № 1 - порог покупки 1000

Показатель	Исходный	После порога
Вход / принято / отклонено	600 / 576 / 24	600 / 576 / 24
Учтено событий	192	192
Учтено покупок	51	45
Сумма покупок	134966.61	131607.09

Число входных, принятых и отклонённых строк не изменилось: порог применяется после проверки качества и не переписывает исходный CSV.

4. Эксперимент № 2 - статусы success + pending

Показатель	Только success	+ pending
Учтено событий	192	375
Учтено покупок	51	98
Сумма покупок	134966.61	259489.84

Качество строк то же, но в расчёт попали pending-события - выросли учтённые метрики. Это отличие технической валидации от бизнес-фильтра.

5. Выходные файлы

output/region_summary.csv, event_summary.csv, rejected_rows.csv, quality_report.txt, run_metadata.json - агрегаты, отбраковка, отчёт и метаданные запуска.

6. Снимки работы скрипта и графики

Скриншот вывода python main.py и визуализация результатов конвейера.

```

C:\...\task> python main.py

=====
Практическая работа № 1 · Пакетный конвейер CSV
=====

[1] Генерация учебных данных...
[OK] Создан data/events.csv — строк данных: 600

[2] Исходный запуск конвейера...
=== Конвейер [baseline] завершён успешно ===
Входных строк:      600
Принято:           576
Отклонено:         24
Учтено событий:    192
Учтено покупок:    51
Сумма покупок:    134966.61



[3] Эксперимент № 1: min_purchase_amount = 1000...
покупки=45  сумма=131607.09
(вход/принято/отклонено без изменений)

[4] Эксперимент № 2: included_statuses = success+pending...
события=375  покупки=98
сумма=259489.84

Готово. Контрольная точка: 600 / 576 / 24 — выполнена.


```

00_console.png


*01_quality.png**02_event_types.png*

7. Вывод

Пакетный конвейер обработал 600 строк: принято 576, отклонено 24. Изменение `settings.json` меняет бизнес-метрики, но не исходное качество CSV. Сохранение `rejected_rows` и метаданных обеспечивает прозрачность и воспроизводимость.



03_regions.png



04_experiments.png

8. Ответы на контрольные вопросы

- 1) Универсального размера Big Data нет - «большое» относительно ресурсов и задачи (5V: Volume, Velocity, Variety, Veracity, Value).
- 2) До агрегации нужна проверка качества, иначе дефекты исказят результат.
- 3) Техническая валидация отсекает некорректные строки; бизнес-фильтр выбирает подмножество уже валидных данных (порог, статусы).
- 4) rejected_rows.csv нужен для аудита, исправления источника и доверия к отчёту.
- 5) При переходе к распределённой системе понадобятся партиционирование, отказоустойчивость, единая схема и мониторинг качества.