

Практическая работа 2 Форматы и качество

Дисциплина «Системы обработки больших данных». Продолжение первой работы с Python, CSV и 600 синтетическими событиями. Научитесь приводить CSV и JSON к общей схеме, различать нормализацию и дефект, проверять результат и составлять паспорт данных.

Что нужно получить

Два сохранённых запуска конвейера, очищенные CSV и JSON, журналы, заполненные REPORT.md и DATA_PASSPORT.md, один итоговый ZIP. Код уже подготовлен. Обязательная работа не требует написания программы с нуля.

Среда и файлы

Windows 10/11, Python 3.10 или новее из первой работы, Блокнот и новый стартовый архив. Дополнительных Python-пакетов нет. Старый проект сохраняйте отдельно. Для занятия достаточно локальных файлов.

Часть	Действия	Время практики
А	Подготовка, strict, журналы	55 минут
Б	normalized, паспорт, отчёт, ZIP	60 минут

Преподаватель сначала объясняет материал по слайдам, затем вы выполняете шаги у себя. При ошибке назовите шаг, файл и полное сообщение. Не переходите к зависимому шагу, пока предыдущая проверка не пройдена.

Сдача позднее

Сохраните рабочую папку и submission/BigData2_result.zip на своём компьютере. Загрузите ZIP в ЭИОС после создания задания и отдельного объявления ссылки и срока. Во время занятия отправлять результат не требуется.

Проверка. В материалах нет даты занятия и группы. Даты внутри синтетических событий относятся только к данным.

A0 Подготовьте Windows и папку

1. Скачайте 04_Стартовый_проект_Форматы_и_качество.zip. В Проводнике: правый щелчок → «Извлечь всё». Откройте starter_formats_quality. Не запускайте файлы внутри ZIP.
2. Двойным щелчком запустите 00_CHECK_ENV.cmd. Ответ должен содержать Python 3.10 или новее. Закройте окно после чтения. Если Python уже подходит, переустановка не нужна.
3. Если Python не найден, откройте DOWNLOADS.html в браузере и используйте официальный источник. После установки закройте старые окна и повторите 00. При ограничении установки обратитесь к преподавателю.

Где что делать

Задача	Место
Распаковать и запустить CMD	Проводник Windows
Изменить settings.json, REPORT.md, DATA_PASSPORT.md	«Открыть с помощью» → «Блокнот»
Просмотреть CSV и JSON	Блокнот или текстовый редактор
Ручные команды	Окно cmd из папки проекта

Ручной запуск при необходимости

В адресной строке Проводника внутри starter_formats_quality введите cmd и нажмите Enter. В появившемся окне вводите команды по одной строке:

```
py -3 --version
```

Если py не найден, используйте python --version; во всех следующих командах замените py -3 на python. Не вводите команды в Python с приглашением >>>. Для выхода из него введите exit().

Проверка. Текущая папка — starter_formats_quality; Python подходит; settings.json и шаблоны открываются в редакторе.

A1 Воспроизведите и осмотрите входы

1. Запустите 01_CREATE_DATA.cmd. Ручной эквивалент в cmd:

```
py -3 generate_dataset.py
```

Проверка. CSV = 300; JSON = 306; total = 606 records. Два готовых файла также уже вложены в проект.

2. Откройте data/events_part1.csv и data/events_part2.json в Блокноте. В CSV найдите заголовок, в JSON — массив объектов. Исходные файлы не редактируйте. Повтор 01 восстанавливает входы, но не сбрасывает настройки.

3. В REPORT.md запишите количества и два переименования полей.

Соответствие общей схеме:

CSV	JSON	Общая схема
event_id	id	event_id
event_time	timestamp	event_time
user_id	user_id	user_id
region	region	region
event_type	event_type	event_type
amount	amount	amount
status	status	status
source	source	source

Формат описывает запись файла, схема — имена, смысл, типы и правила полей. Число строк текста JSON не равно числу объектов. Шесть дополнительных записей — повторы событий первого файла.

Проверка. Найдены оба источника и их структура. Старая папка первой работы не изменялась.

A2 Выполните исходный запуск

1. Откройте settings.json в Блокноте. Перед первым запуском должно быть ровно:

```
{  
  "allow_decimal_comma": false  
}
```

2. Сохраните Ctrl+S. Запустите 02_RUN_PIPELINE.cmd. Ручной эквивалент:

```
py -3 pipeline.py
```

Ожидаемый ответ

Mode: strict

Input: 606 | accepted: 556 | rejected: 50

Unique IDs: 556 | balance: OK | CSV/JSON equality: OK

Results: runs/strict

3. Откройте runs/strict/quality_report.txt. Перенесите числа в колонку strict файла REPORT.md и сохраните.

Файл внутри runs/strict	Что проверять
clean_events.csv / clean_events.json	Принятые события в общей схеме
rejected_rows.csv	Источник, номер и причина отклонения
normalization_log.csv	Какие поля изменены
quality_report.txt	Читаемый итог и причины
run_metadata.json	Настройки, счётчики, хеши и проверки

Проверка. $606 = 556 + 50$. Режим strict уже убирает пробелы и меняет регистр, но ещё не разрешает десятичную запятую.

А3 Разберите журналы

1. Откройте `runs/strict/rejected_rows.csv`. Найдите `reason` «неверный формат суммы». Затем найдите запись с другой причиной.

Поле	Смысл
<code>source_file</code>	В каком из двух источников находится запись
<code>record_number</code>	Порядковый номер записи с 1; заголовок CSV не считается
<code>event_id</code>	Исходный идентификатор
<code>reason</code>	Первая обнаруженная причина отклонения
<code>raw_record</code>	Исходное содержимое записи

2. Запишите один конкретный пример в `REPORT.md`. Для JSON `record_number` — позиция объекта, а не строка текста. Для поиска используйте `event_id` и `raw_record`.

3. Откройте `normalization_log.csv`. Найдите изменение пробелов или регистра. Запишите `source_file`, `record_number`, `field`, `before` и `after`.

Что объяснить

Почему пробелы по краям статуса можно убрать по правилу? Почему неизвестного пользователя нельзя заменить произвольным значением? Почему число изменений полей не равно числу обработанных событий?

Проверка. В журнале нормализации одна запись может дать несколько строк. Их нельзя прибавлять к принятым и отклонённым. Для каждой отклонённой записи учитывается только первая причина.

А4 Зафиксируйте первую часть

1. Сохраните заполненную колонку strict в REPORT.md. Для строки «неверный формат суммы» ожидается 20; для «повтор идентификатора» — 11.
2. Начните DATA_PASSPORT.md: назначение, источники, единица наблюдения. Одна запись описывает одно событие учебного приложения. Набор синтетический.
3. Заполните смысл полей общей схемы. Не требуется менять программный код. Переименование id и timestamp выполняет готовый конвейер.

Контроль перед перерывом

Проверка	Ваш результат
Два источника, всего 606 записей	_____
Mode strict, принято 556, отклонено 50	_____
Баланс входа и равенство CSV/JSON — OK	_____
Пример отклонения и пример нормализации найдены	_____
REPORT и начатый паспорт сохранены	_____

Пока оставьте allow_decimal_comma равным false. Эксперимент начинается во второй части. Если завершили раньше, найдите в чистом наборе корректные failed или pending и объясните, почему они не отклонены.

Проверка. Проверка качества здесь не фильтрует только успешные события и не считает выручку. Эти действия относятся к последующему анализу.

Б1 Измените одно правило

1. Откройте settings.json. Замените только false на true:

```
{  
  "allow_decimal_comma": true  
}
```

2. Сохраните Ctrl+S. Не изменяйте исходные файлы и скрипты. Снова запустите 02_RUN_PIPELINE.cmd или в cmd:

```
py -3 pipeline.py
```

Ожидаемый ответ

Mode: normalized

Input: 606 | accepted: 576 | rejected: 30

Unique IDs: 576 | balance: OK | CSV/JSON equality: OK

Results: runs/normalized

3. Откройте runs/normalized/quality_report.txt. Заполните вторую колонку REPORT.md. Папка strict сохраняется отдельно.

Проверка. Разрешено только однозначное десятичное представление вида 1250,50. Разделители тысяч не угадываются. Пропуски, неверные даты, неизвестные значения, отрицательные суммы и повторы по-прежнему проверяются.

Если ответ всё ещё strict, проверьте сохранение settings.json и папку проекта. Если ошибка JSONDecodeError, проверьте двойные кавычки, скобки и написание true без кавычек. При повторе одного режима обновляются только его результаты.

Б2 Сравните два запуска

Показатель	strict	normalized
Входных записей	606	606
Принято	556	576
Отклонено	50	30
Уникальных event_id	556	576
Неверный формат суммы	20	0
Повтор идентификатора	11	11

1. Запишите в REPORT.md разницу принятых и отклонённых. Если причина в отчёте не перечислена, для неё количество равно нулю.
2. Проверьте баланс вручную: $556 + 50 = 606$; $576 + 30 = 606$. В обоих запусках источник не изменился.
3. В normalization_log второго режима найдите изменение суммы с запятой на точку. В rejected_rows найдите один оставшийся дефект; внесите пример в отчёт.

Связь с первой работой

Первая работа: 600 → 576 принято + 24 отклонено. Вторая после нормализации: 606 → те же 576 корректных событий + 30 отклонений. Дополнительные шесть — повторы. Нормализация не создаёт новые факты.

Проверка. Правило повторов: сначала CSV, затем JSON; сохраняется первая корректная запись с данным event_id. Следующие корректные записи с тем же ключом отклоняются. Конфликт значений требует отдельного решения, которого эта учебная модель не выбирает.

Б3 Проверьте сохранённые результаты

1. Откройте `clean_events.csv` и `clean_events.json` из `runs/normalized`. В обоих файлах восемь одинаково названных полей. В JSON больше нет отдельных имён `id` и `timestamp`.

2. Откройте `run_metadata.json` и найдите объект `checks`. В нём должны быть три значения `true`:

```
{
  "balance_ok": true,
  "unique_ids_ok": true,
  "roundtrip_equal": true
}
```

Проверка	Что подтверждает
balance_ok	Входные = принятые + отклонённые
unique_ids_ok	В принятом наборе нет повторных <code>event_id</code>
roundtrip_equal	CSV и JSON прочитаны обратно и все записи совпадают с принятыми

3. Найдите `settings` и `input_sha256` в метаданных обоих запусков. Настройка различается; хеши двух входных файлов совпадают между режимами.

4. Запишите в `REPORT.md`, почему равного количества строк недостаточно. Одна изменённая сумма не меняет размер набора, но меняет его содержание.

Проверка. `amount` в очищенных CSV и JSON хранится строкой с двумя знаками после точки. При проверке используется `Decimal`. В паспорте отдельно укажите логический денежный тип и строковое представление в файлах.

Не редактируйте результаты перед проверкой. При случайном изменении повторите 02 в нужном режиме, затем снова сверяйте контроль.

Б4 Завершите паспорт данных

Откройте DATA_PASSPORT.md через Блокнот. Заполните все поля, сохранив названия колонок и полей. Коротких конкретных формулировок достаточно.

Раздел	Что указать
Происхождение	Синтетический набор на основе генератора первой работы
Источники	Два имени файла, CSV 300 и JSON 306
Представление	CSV UTF-8 с BOM, запятая; JSON UTF-8, массив объектов
Единица и ключ	Одно событие; event_id; правило первой корректной записи
Общая схема	Смысл и логический тип всех восьми полей
Качество	Обязательные поля, допустимые значения, даты, суммы, повторы
Нормализация	Пробелы, регистр в трёх полях, десятичная запятая по параметру
Воспроизведение	Python, генератор, settings, pipeline, порядок запусков
Ограничения	Небольшая локальная модель; синтаксис не доказывает истинность события

Для event_type перечислите view/search/cart/purchase, для status — success/failed/pending, для source — web/mobile/partner. Для region используется список из первой работы.

Проверка. Не пишите «ошибок нет»: оставшиеся дефекты не исправлены, они помещены в отдельный журнал. Укажите итоговый режим normalized и расположение его результатов.

Б5 Сохраните отчёт и соберите ZIP

1. Завершите REPORT.md: два запуска, обе формулы баланса, конкретные примеры, ответы и вывод из 3–5 предложений. Сохраните его и DATA_PASSPORT.md сочетанием Ctrl+S.

2. Запустите 03_BUILD_RESULT.cmd. Ручной эквивалент:

```
py -3 package_result.py
```

3. Откройте submission/BigData2_result.zip и проверьте состав:

Внутри ZIP	Назначение
runs/strict — 6 файлов	Первый запуск и его настройка в метаданных
runs/normalized — 6 файлов	Второй запуск и его настройка в метаданных
REPORT.md, DATA_PASSPORT.md	Ваши заполненные документы
settings.json	Итоговый параметр true
pipeline.py, generate_dataset.py, lesson1_generator.py	Воспроизводимые скрипты

4. Убедитесь, что документы внутри ZIP заполнены. При исправлении отчёта снова выполните 03, чтобы обновить архив. Исходные данные воспроизводятся генератором и в итоговый ZIP не входят.

5. Сохраните ZIP и всю рабочую папку. Можно переименовать копию ZIP в Familiya_BigData2.zip. Загрузите один ZIP в ЭИОС позднее по объявленной ссылке и сроку. Подтвердите отправку, если система показывает отдельную кнопку.

Проверка. Сборщик проверяет наличие файлов, но не смысл ваших ответов. Пустые шаблоны внутри успешно собранного ZIP не считаются выполненным отчётом.

Б6 Самопроверка и оценивание

Критерий	Баллы
Работоспособность и полный результат двух запусков	0-3
Корректность данных и проверки	0-2
Эксперимент и объяснение изменения результата	0-2
Паспорт данных и осмысленный вывод	0-2
Оформление и воспроизводимость	0-1

Работоспособность: 3 — оба полных запуска; 2 — оба есть, но часть результатов отсутствует; 1 — завершён один; 0 — результатов нет. Для критериев по 2 балла: 2 — выполнен полностью, 1 — частично, 0 — отсутствует или неверно. Оформление: 1 — комплект можно проверить и повторить, иначе 0.

Перед сдачей

Проверьте: оба запуска сохранены; значения объяснены; найден реальный пример изменения и оставшегося дефекта; паспорт заполнен; CSV и JSON совпадают; ZIP открывается; отчёт внутри содержит ваши ответы.

Ответьте своими словами

Чем формат отличается от схемы? Почему timestamp не является пропуском event_time? Что изменилось при true? Почему не исчезли все отклонения? Чем изменение представления отличается от исправления факта? Как проверить сохранённый файл?

Дополнительно по желанию

Откройте pipeline.py как текст. Найдите соответствие имён JSON, set для проверки event_id и сравнение csv_back == json_back. Объясните три участка без изменения программы. Это не требуется для максимальной оценки.

Помощь при ошибках и источники

Симптом	Действие
Python не найден	Повторите A0; используйте официальный источник и разрешённый способ установки
Окно быстро закрывается	Откройте cmd в папке и выполните ручную команду, чтобы увидеть сообщение
JSONDecodeError	Проверьте settings.json: false/true без кавычек, двойные кавычки вокруг имени, без лишней запятой
FileNotFoundError	Проверьте распаковку; запустите 01 и наличие двух файлов в data
Остался strict	Сохраните true; проверьте, из какой папки запущен 02
Числа не совпали	Сверьте 606, режим и входные файлы; 01 восстановит только входы
В ZIP старые ответы	Сохраните документы, снова выполните 03
CMD ограничен системой	Сообщите преподавателю; не обходите ограничения компьютера

На консультации назовите шаг, файл и полный текст ошибки. Если работа не закончена, сохраните папку и последний выполненный шаг.

Официальная документация

Python для Windows: <https://docs.python.org/3/using/windows.html>

Чтение CSV: <https://docs.python.org/3/library/csv.html>

Чтение JSON: <https://docs.python.org/3/library/json.html>

Точные десятичные числа: <https://docs.python.org/3/library/decimal.html>