

**Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Херсонский государственный педагогический университет»**

Институт информационных технологий

Кафедра программной инженерии и информационных технологий

ПРАКТИЧЕСКАЯ РАБОТА
по дисциплине:
«Системы обработки больших данных»
на тему:
«Форматы и качество»

Выполнил:
Студент гр.: 12-25РПм
Трифонов Д.С.

Проверил
Преподаватель:
Гуцол Д.В.

Оценка: _____
Дата: 22.09.2026

Херсон, 2026

ПРАКТИЧЕСКАЯ РАБОТА

Форматы и качество (CSV + JSON → общая схема)

Цель: привести CSV и JSON к общей схеме, сравнить режимы strict и normalized (параметр allow_decimal_comma), проверить баланс и равенство очищенных файлов, заполнить отчёт и паспорт данных.

1. Подготовка и входы

Сгенерированы data/events_part1.csv (300 записей, UTF-8 с BOM) и data/events_part2.json (306 объектов). Итого 606 записей. В JSON поля id и timestamp соответствуют event_id и event_time общей схемы. Шесть дополнительных JSON-записей — повторы событий CSV.

2. Режим strict (allow_decimal_comma = false)

Запуск конвейера: Mode strict. Input: 606 | accepted: 556 | rejected: 50. Unique IDs: 556 | balance: OK | CSV/JSON equality: OK. Результаты: runs/strict (clean_events, rejected_rows, normalization_log, quality_report, run_metadata).

Среди отклонений: «неверный формат суммы» — 20; «повтор идентификатора» — 11. Пример отклонения: source_file=events_part1.csv, record_number=6, event_id=E0006, reason=неверный формат суммы (сумма с десятичной запятой).

3. Режим normalized (allow_decimal_comma = true)

После смены настройки: Mode normalized. Input: 606 | accepted: 576 | rejected: 30. Unique IDs: 576 | balance: OK | CSV/JSON equality: OK. Результаты: runs/normalized. Суммы вида 1250,50 приняты после замены запятой на точку; «неверный формат суммы» стал 0. Повторы остались (11).

Баланс: $556 + 50 = 606$; $576 + 30 = 606$. Разница принятых: +20. Пример нормализации суммы: events_part1.csv, record_number=6, field=amount, before=1141,18 → after=1141.18. Оставшийся дефект: повтор идентификатора (events_part1.csv, record_number=41, event_id=E0001).

4. Проверки и паспорт

В run_metadata.json обоих запусков checks: balance_ok=true, unique_ids_ok=true, roundtrip_equal=true. Хеши входных файлов совпадают между режимами; настройка allow_decimal_comma различается. Заполнены REPORT.md и DATA_PASSPORT.md; собран submission/BigData2_result.zip.

5. Снимки выполнения программы

```
python main.py — Форматы и качество

=====
Практическая работа № 2 · Форматы и качество
=====

Input: 606 | accepted: 576 | rejected: 30
Unique IDs: 576 | balance: OK | CSV/JSON equality: OK
Results: runs/normalized

[4] Заполнение REPORT.md и DATA_PASSPORT.md...
[5] Сохранение графиков и снимка консоли...
[6] Сборка ZIP...

=====
Готово. Контроль: strict 606/556/50; normalized 606/576/30.
Файлы: data/, runs/, charts/, REPORT.md, DATA_PASSPORT.md, submission/
=====
```

Рисунок 1 — Вывод python main.py




Рисунок 2 — Сравнение strict и normalized




Рисунок 3 — Причины отклонения




Рисунок 4 — Типы принятых событий (normalized)



Рисунок 5 — Статусы принятых событий (normalized)

6. Вывод

Конвейер привёл CSV и JSON к общей схеме и сохранил два независимых запуска. В режиме strict из 606 записей принято 556, отклонено 50; после разрешения десятичной запятой — 576 / 30. Нормализация меняет представление (пробелы, регистр, запятая), но не создаёт новых фактов: дополнительные JSON-записи — повторы. Оставшиеся дефекты вынесены в rejected_rows.csv и учтены в паспорте данных.

7. Ответы на контрольные вопросы

- 1) Формат — способ сериализации файла (CSV/JSON); схема — согласованные имена, типы и правила полей.
- 2) timestamp в JSON — другое имя того же смысла event_time, а не пропуск поля общей схемы.
- 3) При true приняты однозначные суммы с запятой; отклонений стало на 20 меньше.
- 4) Не исчезли пропуски, неверные даты, неизвестные значения, отрицательные суммы и повторы id.
- 5) Нормализация меняет представление; исправление факта подставляло бы выдуманные значения.
- 6) Проверка: balance, уникальность event_id, round-trip CSV↔JSON и сверка input_sha256.