

Пара 1 Разделение данных и создание копий

Практическая работа 3, пара 1. Дисциплина «Системы обработки больших данных». Разделение данных и создание копий.

Пара 1. Разделение данных и создание копий

Извлеките весь архив, откройте starter_pair1. Windows 10/11, Python 3.10+.

Порядок: 00_CHECK_ENV → 01_PARTITION → 02_REPLICATE → заполнение REPORT → 90_BUILD_PAIR1.

Результат: submission/BigData3_pair1_result.zip.

Рабочую папку и ZIP сохраните у себя. Ссылка и срок загрузки в ЭОС будут объявлены отдельно.

Преподаватель сначала объясняет материал по презентации, затем вы выполняете действия у себя. На самостоятельную работу выделено 55 минут.

Что сдать

Один архив BigData3_pair1_result.zip из папки submission. Сохраните его локально. Загрузите в отдельное задание этой пары в ЭОС после объявления ссылки и срока.

Среда

Windows 10/11, Python 3.10+, Проводник, Блокнот. Дополнительные пакеты не нужны. Код подготовлен. При ошибке назовите шаг и полный текст сообщения.

Оценивание

Первая часть — промежуточная проверка выполнения. Итоговая оценка практической работы 3 — до 10 баллов за обе части по рубрике второй пары.

A0. Распакуйте проект и проверьте Python

1. Скачайте 03_Проект_Пара_1.zip. В Проводнике нажмите правой кнопкой по ZIP → «Извлечь всё». Выберите новую папку, например «Документы» → BigData3. Старые проекты оставьте отдельно.
2. Откройте извлечённую папку starter_pair1. Рядом должны находиться lab.py, REPORT.md, папка data и файлы 00, 01, 02 и 90 с расширением .cmd. Не запускайте их внутри открытого ZIP.
3. Включите расширения имён файлов. Windows 11: «Вид» → «Показать» → «Расширения имён файлов». Windows 10: вкладка «Вид» → «Расширения имён файлов».
4. Дважды щёлкните 00_CHECK_ENV.cmd. Окно показывает версию Python и ждёт нажатия клавиши. Нужна версия 3.10 или новее. Запишите её в REPORT.

Проверка. Нет сообщения Python 3.10 or later was not found. Если оно есть, откройте DOWNLOADS.html: там официальный источник и инструкция. При отсутствии прав установки обратитесь к преподавателю.

Куда вводить команду вручную

В этой же папке щёлкните адресную строку Проводника, введите cmd и нажмите Enter. Команды вводите в открывшееся окно CMD по одной строке. Если py не найден, но 00 успешно нашёл python, заменяйте начало py -3 на python.

```
py -3 --version
```

Двойной щелчок по CMD — основной маршрут. Он сам выбирает доступный Python и нужную папку. Если окно сообщает ошибку, прочитайте её до закрытия и передайте полный текст преподавателю.

A1. Осмотрите исходник и начните отчёт

1. В папке data найдите clean_events.csv. Правой кнопкой → «Открыть с помощью» → «Блокнот». Содержимое только просматривайте. CSV уже содержит 576 корректных событий, без необходимости запуска старой работы.

Поле	Смысл
event_id	Уникальное событие
event_time	Время события
user_id	Пользователь; ключ разделения
region / event_type	Регион и тип события
amount / status / source	Сумма, статус, источник

2. Откройте REPORT.md в Блокноте. Заполняйте ответы вместо [ЗАПОЛНИТЬ], сохраняйте Ctrl+S. Не создавайте REPORT.md.txt. Все ответы находятся в одном отчёте.

3. Запишите правило: $\text{int}(\text{user_id}[1:]) \% 3$. Берём цифры после U, преобразуем в число и находим остаток от деления на 3.

4. Рассчитайте номер раздела для U0007 и U0129. Запишите вычисление, а не только номер. Все события одного пользователя получают один номер раздела.

Проверка. U0007 → 1; U0129 → 0. Ключ разделения user_id может повторяться; уникальность событий проверяется по event_id.

Исходный CSV, manifest и созданные CSV не редактируем и не пересохраняем через Excel. Это может изменить байты файлов и контрольные суммы.

A2. Создайте разделы и оцените распределение

1. Вернитесь в папку рядом с lab.py. Дважды щёлкните 01_PARTITION.cmd. Альтернатива в CMD:

```
py -3 lab.py partition
```

2. После успешного запуска откройте lab/primary. Найдите три CSV. Количество в таблице — записи без строки заголовка.

Раздел	Событий
part_0.csv	206
part_1.csv	178
part_2.csv	192
Всего	576

3. В REPORT запишите три размера, сумму и разницу максимального и минимального размера: $206 - 178 = 28$. Объясните, почему правило по пользователю не обещает одинакового числа событий.

4. Откройте lab/manifest.json в Блокноте. Найдите rule, source_rows и partitions. Для каждой части указаны rows, sha256 и два пути. Файл только просматривайте.

5. Откройте lab/checks/01_partition.txt. До копирования ожидаются primary_rows: 576, replica_rows: 0, readable_rows: 576, all_fields_equal_to_source: True.

Проверка. Разделы вместе содержат все 576 событий; в них нет повторов event_id. Разница размеров не является ошибкой.

Повторный 01 защищает уже созданный lab и останавливается. Продолжите со следующего шага. Для нового полного опыта извлеките новый стартовый проект в другую папку.

А3. Создайте реплики и проверьте baseline

1. Запустите 02_REPLICATE.cmd. Альтернатива:

```
py -3 lab.py replicate
```

2. В lab/replica должны появиться part_0.csv, part_1.csv и part_2.csv. Это дополнительные копии соответствующих основных файлов. Коэффициент репликации 2 означает две копии всего.

3. Откройте lab/checks/02_baseline.txt. Перенесите показатели в колонку 02_baseline в REPORT.

Поле	Ожидается
primary_rows / replica_rows	576 / 576
physical_active_rows	1152
readable_rows / unique_ids	576 / 576
all_fields_equal_to_source	True
read_from для part_1	primary/part_1.csv

4. Найдите строки каждого раздела. Обе проверки primary и replica должны быть True. Данные читаются из primary.

Как считать

physical_active_rows — строки данных во всех исправных активных основных файлах и репликах. Заголовки, источник, removed и журналы исключены.

readable_rows — чтение по одной исправной копии раздела. Не складывайте основную и дополнительную копии как разные события.

Проверка. Контрольная сумма проверяет байты; all_fields_equal_to_source сравнивает все восемь полей прочитанного набора с источником. Одинакового количества строк недостаточно.

А4. Зафиксируйте первую часть

1. В REPORT заполните автора, версию Python, правило и примеры пользователей, распределение и объяснение разницы размеров. Сохраните baseline в первой колонке таблицы.
2. Объясните коэффициент репликации и различие физических записей и уникальных событий. Не добавляйте исходный CSV к показателям активного хранилища.
3. Убедитесь, что baseline существует в двух форматах: TXT для чтения и JSON для структурированных данных. Они созданы одним запуском и описывают одно состояние.

Перед перерывом

Проверка	Ожидаемый результат
Исходник	data/clean_events.csv, без правок
Основные разделы	3 CSV, всего 576 событий
Реплики	3 CSV, ещё 576 физических записей
Журнал	02_baseline, все проверки True
Отчёт	Часть А и первая колонка заполнены

Моделирование отказа относится ко второй паре. Сохраните REPORT. Если возникло затруднение, отметьте последний успешный шаг и полный текст ошибки.

Если закончили раньше

Найдите в исходном CSV два события одного пользователя и определите их раздел по правилу. Объясните, почему при изменении числа разделов с 3 на 4 потребуется перераспределять записи. Файлы менять не нужно.

А5 Сохраните результат первой пары

1. Заполните все метки [ЗАПОЛНИТЬ] в REPORT.md и сохраните Ctrl+S. В этом отчёте только результаты первой пары.
2. Дважды щёлкните 90_BUILD_PAIR1.cmd. Для ручного запуска откройте CMD через адресную строку Проводника в starter_pair1 и выполните:
py -3 pack_pair1.py
3. Откройте submission/BigData3_pair1_result.zip. Внутри: REPORT.md, код, исходный CSV, manifest, основные файлы, реплики и журналы 01_partition / 02_baseline.
4. Проверьте, что в ZIP попала последняя версия отчёта. После правок сохраните REPORT и повторите 90. Рабочую папку тоже сохраните.
5. Загрузите ZIP в задание первой пары в ЭОС после объявления ссылки и срока. Для второй пары будет отдельный проект и отдельное задание.

Проверка. Ожидается 206 / 178 / 192 записи в разделах; 576 основных и 576 в репликах; 1152 активных физических записи; 576 доступных уникальных событий; сравнение всех полей True.

Если сборка остановилась

Complete 01... — завершите разделение и копирование. Fill all fields... — заполните отчёт и сохраните. lab already exists — первый этап уже создавал lab; продолжите по порядку. Для полного повторения используйте новую распакованную папку.