

Федеральное государственное бюджетное образовательное учреждение высшего образования «Херсонский государственный педагогический университет»
Институт информационных технологий
Направление подготовки: «09.04.04 Программная инженерия»
Специализация «Разработка программно-информационных систем»
Форма обучения: очная
Курс: 2, Магистратура, группа 12-25РПм
Херсонская область - 2026

Дисциплина:
«Системы обработки больших данных»

Выполнил:
Дмитрий Сергеевич Трифонов
обучающийся 2-го курса

Проверил:
Гуцол Д.В.

ПРАКТИЧЕСКАЯ РАБОТА 3

«Разделение данных и создание копий»

I. ЦЕЛЬ И ЗАДАЧИ

1.1. Цель

Целью данной практической работы является освоение методов разделения набора данных на несколько частей и создания реплик этих частей с использованием заданного правила распределения. В ходе работы необходимо сформировать три раздела исходного набора событий, проверить полноту и целостность разделения, создать дополнительные копии разделов и оценить различие между физическими записями и уникальными событиями.

1.2. Задачи

- Проверить рабочее окружение и версию Python 3.10 или новее.
- Изучить структуру исходного набора данных `clean_events.csv`.
- Зафиксировать правило распределения данных по разделам `int(user_id[1:]) % 3`.
- Рассчитать номера разделов для пользователей U0007 и U0129.
- Создать три основных раздела исходного набора данных.
- Проверить количество событий в каждом разделе и суммарное количество записей.
- Проанализировать причины различия размеров разделов.
- Проверить `manifest.json` и результаты контроля целостности разделения.
- Создать реплики всех трёх основных разделов.
- Проверить `baseline` после создания реплик.
- Определить количество физических активных записей и доступных уникальных событий.
- Проверить соответствие данных исходному CSV по всем полям.
- Заполнить отчёт по результатам первой пары.
- Сформировать итоговый архив `BigData3_pair1_result.zip`.

II. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ

2.1. Разделение данных

Разделение данных, или `partitioning`, представляет собой распределение исходного набора записей между несколькими логическими разделами. Такой подход позволяет обрабатывать части большого набора данных независимо друг от друга и организовывать их хранение в распределённой системе. В данной работе исходный набор содержит 576 корректных событий, которые распределяются между тремя разделами по значению `user_id`.

2.2. Правило распределения

Для определения раздела используется правило `int(user_id[1:]) % 3`. Из идентификатора пользователя удаляется символ `U`, оставшиеся цифры преобразуются в целое число, после чего вычисляется остаток от деления на 3. Полученный остаток определяет номер раздела: 0, 1 или 2. Все события одного пользователя получают один и тот же номер раздела.

2.3. Ключ разделения и уникальность событий

В качестве ключа разделения используется `user_id`. Один пользователь может иметь несколько событий, поэтому значение `user_id` не является уникальным идентификатором записи. Уникальность отдельных событий определяется по полю `event_id`. Благодаря использованию `user_id` все события одного пользователя попадают в один раздел, а проверка `event_id` позволяет убедиться в отсутствии повторов событий.

2.4. Репликация данных

Репликация представляет собой создание дополнительных копий данных для повышения доступности и устойчивости хранения. В данной работе коэффициент репликации 2 означает наличие двух физических копий каждого события: основной записи в `primary` и дополнительной записи в `replica`. При этом реплика не является новым уникальным событием, поэтому количество доступных уникальных событий остаётся равным исходному количеству.

2.5. Физические и логические записи

Физическое количество записей характеризует фактически хранящиеся строки во всех исправных активных копиях данных. После создания реплик в работе имеется 576 основных и 576 дополнительных физических записей, то есть 1152 физические записи. Логически доступный набор при чтении одной исправной копии содержит 576 уникальных событий. Исходный CSV не включается в расчёт активного физического хранилища.

2.6. Контроль целостности данных

Для проверки результата используются контрольные файлы и `manifest.json`. Manifest содержит сведения о правиле распределения, количестве исходных строк, параметрах разделов, количестве строк, контрольных суммах SHA-256 и путях к соответствующим файлам. Проверка `all_fields_equal_to_source` сравнивает значения всех восьми полей с исходным набором, а контрольная сумма позволяет дополнительно подтвердить соответствие содержимого файлов.

III. МЕТОДЫ И ПОДХОДЫ К ВЫПОЛНЕНИЮ РАБОТЫ

3.1. Подготовка рабочего окружения

Работа выполняется в Windows 10/11 с использованием Python 3.10 или более новой версии. После распаковки `starter_pair1` проверяется наличие `lab.py`, `REPORT.md`, каталога `data` и командных файлов `00_CHECK_ENV.cmd`, `01_PARTITION.cmd`, `02_REPLICATE.cmd` и `90_BUILD_PAIR1.cmd`. Исходный CSV открывается только для просмотра, а рабочие файлы не редактируются через Excel, чтобы не изменять их байтовое содержимое и контрольные суммы.

3.2. Проверка версии Python

- Запускается файл 00_CHECK_ENV.cmd.
- Проверяется наличие Python версии 3.10 или новее.
- При необходимости команда `py -3 --version` выполняется вручную в CMD.
- Полученная версия Python фиксируется в отчёте.
- Работа продолжается только при корректно найденном Python.

3.3. Анализ исходного набора данных

- В каталоге data открывается файл `clean_events.csv`.
- Исходный набор содержит 576 корректных событий.
- В данных используются поля `event_id`, `event_time`, `user_id`, `region`, `event_type`, `amount`, `status` и `source`.
- Поле `user_id` используется как ключ разделения.
- Поле `event_id` используется для проверки уникальности событий.
- Исходный CSV не изменяется и не пересохраняется.

3.4. Расчёт номеров разделов

- Для каждого пользователя применяется правило $\text{int}(\text{user_id}[1:]) \% 3$.
- Для пользователя U0007 вычисление имеет вид: $\text{int}("0007") \% 3 = 7 \% 3 = 1$.
- Следовательно, события пользователя U0007 относятся к разделу `part_1`.
- Для пользователя U0129 вычисление имеет вид: $\text{int}("0129") \% 3 = 129 \% 3 = 0$.
- Следовательно, события пользователя U0129 относятся к разделу `part_0`.
- Все события одного пользователя получают один и тот же номер раздела.

3.5. Создание основных разделов

- Запускается 01_PARTITION.cmd либо команда `py -3 lab.py partition`.
- Создаются файлы `part_0.csv`, `part_1.csv` и `part_2.csv` в каталоге `lab/primary`.
- В `part_0.csv` содержится 206 событий.
- В `part_1.csv` содержится 178 событий.
- В `part_2.csv` содержится 192 события.
- Суммарное количество событий составляет 576.
- Разница между максимальным и минимальным разделом составляет $206 - 178 = 28$ событий.

3.6. Проверка результата разделения

- Открывается manifest.json и проверяются параметры rule, source_rows и partitions.
- Для каждого раздела проверяются количество строк, SHA-256 и пути к файлам.
- В 01_partition.txt ожидаются значения primary_rows: 576 и replica_rows: 0.
- Параметр readable_rows равен 576.
- Параметр all_fields_equal_to_source имеет значение True.
- Проверяется отсутствие повторов event_id между разделами.

3.7. Создание реплик

- Запускается 02_REPLICATE.cmd либо команда py -3 lab.py replicate.
- В каталоге lab/replica создаются part_0.csv, part_1.csv и part_2.csv.
- Каждая реплика соответствует своему основному разделу.
- Коэффициент репликации 2 означает наличие двух физических копий всего набора данных.
- Размер основного набора составляет 576 строк, а размер набора реплик также составляет 576 строк.

3.8. Проверка baseline после репликации

- Открывается lab/checks/02_baseline.txt.
- Проверяется значение primary_rows / replica_rows: 576 / 576.
- Количество physical_active_rows составляет 1152.
- Количество readable_rows равно 576.
- Количество unique_ids равно 576.
- Параметр all_fields_equal_to_source имеет значение True.
- Для part_1 значение read_from указывает на primary/part_1.csv.
- Для каждого раздела проверки primary и replica должны иметь значение True.

IV. ПРАКТИЧЕСКОЕ ВЫПОЛНЕНИЕ И АНАЛИТИЧЕСКОЕ ОСМЫСЛЕНИЕ

4.1. Исходная конфигурация и набор данных

- Работа выполнена в подготовленном проекте starter_pair1.
- Для обработки использовался исходный файл data/clean_events.csv.
- Исходный набор содержит 576 корректных событий.
- В наборе используются восемь полей: event_id, event_time, user_id, region, event_type, amount, status и source.
- Исходные данные не изменялись.

4.2. Применение правила разделения

- В качестве ключа распределения выбран user_id.
- Правило распределения: $\text{int}(\text{user_id}[1:]) \% 3$.
- Для U0007: $\text{int}("0007") \% 3 = 7 \% 3 = 1$, поэтому пользователь относится к part_1.
- Для U0129: $\text{int}("0129") \% 3 = 129 \% 3 = 0$, поэтому пользователь относится к part_0.
- Все события одного пользователя направляются в один и тот же раздел.

4.3. Результаты разделения данных

- Основной раздел part_0 содержит 206 событий.
- Основной раздел part_1 содержит 178 событий.
- Основной раздел part_2 содержит 192 события.
- Общее количество событий во всех трёх разделах составляет 576.
- Разница между самым большим и самым маленьким разделом составляет 28 событий.
- Получившееся распределение не является ошибочным, поскольку правило определяется идентификатором пользователя, а количество событий у разных пользователей может различаться.

4.4. Анализ неравномерности разделов

Правило $\text{int}(\text{user_id}[1:]) \% 3$ гарантирует, что события одного пользователя не будут распределены между разными разделами, но не гарантирует одинаковое количество событий в каждом разделе. Причина заключается в том, что пользователи могут иметь различное количество событий. Если в одном из классов остатков оказалось больше пользователей с большим количеством событий, соответствующий раздел будет содержать больше записей. Поэтому размеры 206, 178 и 192 являются допустимым результатом.

4.5. Создание и анализ реплик

- После выполнения репликации в каталоге `lab/replica` появились три дополнительных CSV-файла.
- Количество строк в основных разделах составляет 576, а в репликах также 576.
- Общее количество физических активных записей составляет $576 + 576 = 1152$.
- При этом количество уникальных доступных событий равно 576, поскольку каждая реплика является копией уже существующего события.
- Исходный файл `clean_events.csv` не включается в расчёт `physical_active_rows`.

4.6. Проверка целостности и читаемости

- Проверка `01_partition` подтверждает `primary_rows`: 576.
- До создания реплик `replica_rows` равно 0.
- Количество `readable_rows` равно 576.
- Проверка `all_fields_equal_to_source` имеет значение `True`.
- После создания реплик `primary_rows` и `replica_rows` равны 576.
- `physical_active_rows` равно 1152.
- `readable_rows` и `unique_ids` равны 576.
- Сравнение всех полей с исходным набором даёт `True`.
- Основным источником чтения для `part_1` является `primary/part_1.csv`.

4.7. Аналитические вопросы

- Правило `int(user_id[1:]) % 3` выбрано для детерминированного распределения событий по трём разделам. Для каждого `user_id` номер раздела определяется однозначно.
- Одинаковое количество событий в разделах не гарантируется, потому что один пользователь может иметь несколько событий, а количество пользователей и их активность в каждом классе остатков различаются.
- При коэффициенте репликации 2 каждый набор данных представлен двумя физическими копиями: основной и дополнительной. Поэтому физическое количество строк удваивается с 576 до 1152.
- Количество уникальных событий при репликации не увеличивается: оно остаётся равным 576.
- Контрольная сумма SHA-256 проверяет соответствие байтового содержимого файлов, а `all_fields_equal_to_source` дополнительно проверяет совпадение значений всех восьми полей.
- Если изменить количество разделов с 3 на 4, потребуется перераспределить записи, поскольку остаток должен будет вычисляться по модулю 4. Часть пользователей перейдёт в другие разделы, поэтому старое распределение нельзя просто использовать без изменений.

4.8. Формирование итогового результата

- В `REPORT.md` заполнены результаты первой пары практической работы.
- В отчёте зафиксированы правило распределения, вычисления для пользователей U0007 и U0129, размеры разделов и результаты `baseline`.
- После сохранения отчёта запускается `90_BUILD_PAIR1.cmd` либо команда `py -3 pack_pair1.py`.
- Формируется архив `submission/BigData3_pair1_result.zip`.
- В итоговый архив входят `REPORT.md`, код, исходный CSV, `manifest`, основные разделы, реплики и журналы `01_partition` и `02_baseline`.
- Итоговый архив предназначен для загрузки в соответствующее задание первой пары в ЭОС.

V. ВЫВОДЫ

В результате выполнения практической работы были освоены методы разделения набора данных и создания его копий. Исходный набор `clean_events.csv` содержит 576 корректных событий и был распределён между тремя разделами по правилу `int(user_id[1:]) % 3`. Для пользователя U0007 получен раздел 1, а для U0129 — раздел 0. В результате разделения сформированы `part_0.csv` с 206 событиями, `part_1.csv` со 178 событиями и `part_2.csv` с 192 событиями. Общее количество событий составило 576, а разница между максимальным и минимальным размером раздела — 28 записей. Неравномерность распределения является допустимой, поскольку правило гарантирует совместное размещение событий одного пользователя, но не одинаковое количество событий в каждом разделе. После создания реплик количество основных записей составило 576, количество записей в репликах также составило 576, а общее количество физических активных записей — 1152. При этом количество доступных уникальных событий осталось равным 576. Проверки целостности подтвердили корректность разделения и соответствие всех полей исходному набору: `all_fields_equal_to_source` имеет значение `True`. Таким образом, практическая работа показала различие между логическим количеством уникальных событий и физическим количеством хранимых копий, а также продемонстрировала назначение разделения и репликации данных в системах обработки больших данных.