

Пара 2 Отказ и восстановление данных

Практическая работа 3, пара 2. Дисциплина «Системы обработки больших данных». Отказ и восстановление данных.

Пара 2. Отказ и восстановление данных

Извлеките весь архив, откройте starter_pair2. Windows 10/11, Python 3.10+.

Проект уже содержит исходное состояние первой пары: три основных раздела, три реплики и baseline. Старую папку не заменяйте.

Порядок: 00_CHECK_ENV → просмотр baseline и прогноз в REPORT → 03_SIMULATE_FAILURE → 04_RESTORE → заполнение REPORT → 05_BUILD_RESULT.

Результат: submission/BigData3_pair2_result.zip.

Рабочую папку и ZIP сохраните у себя. Ссылка и срок загрузки в ЭОС будут объявлены отдельно.

Преподаватель сначала объясняет материал по презентации, затем вы выполняете действия у себя. На самостоятельную работу выделено 60 минут.

Что сдать

Один архив BigData3_pair2_result.zip из папки submission. Сохраните его локально. Загрузите в отдельное задание этой пары в ЭОС после объявления ссылки и срока.

Среда

Windows 10/11, Python 3.10+, Проводник, Блокнот. Дополнительные пакеты не нужны. Код подготовлен. При ошибке назовите шаг и полный текст сообщения.

Оценивание

Первая часть — промежуточная проверка выполнения. Итоговая оценка практической работы 3 — до 10 баллов за обе части по рубрике второй пары.

Б0 Откройте подготовленный проект второй пары

1. Скачайте 03_Проект_Пара_2.zip. Правой кнопкой → «Извлечь всё». Откройте starter_pair2 в новой папке; проект первой пары оставьте отдельно.
2. Включите расширения имён файлов в меню «Вид» Проводника. Дважды щёлкните 00_CHECK_ENV.cmd. Нужен Python 3.10 или новее.
3. В проекте уже есть lab/primary, lab/replica, manifest и проверки 01_partition / 02_baseline. Повторно создавать разделы не нужно. Откройте lab/checks/02_baseline.txt в Блокноте.
4. Откройте новый REPORT.md. Запишите автора, версию Python и исходное состояние по включённым файлам. Укажите, что использовали подготовленный проект второй пары. Заполните колонку baseline.
5. Числа: основные 576; реплики 576; активные физические 1152; доступные и уникальные 576; сравнение всех полей True. Только после этого переходите к прогнозу и 03.

Куда вводить команды

Основной способ — двойной щелчок по CMD. Для ручного запуска напечатайте cmd в адресной строке Проводника в starter_pair2. Вводите команды по одной строке в открывшееся окно. Если ru не найден, но 00 обнаружил python, заменяйте ru -3 на python.

Проверка. Исходное состояние включено в архив. Отсутствие готовой папки первой пары не мешает выполнять вторую.

Б1–Б2. Прогноз и моделирование отказа

1. Убедитесь, что Б0 завершён и baseline проверен. До запуска запишите в REPORT прогноз: что будет с основными и доступными событиями, если убрать основной part_1.csv с 178 событиями.
2. Запустите 03_SIMULATE_FAILURE.cmd. Альтернатива:
`py -3 lab.py fail`
3. В lab/primary теперь отсутствует part_1.csv. Он перемещён в lab/removed/part_1.csv. Реплика остаётся на месте. Ничего вручную не удаляйте и не возвращайте.
4. Откройте lab/checks/03_failure.txt и заполните колонку 03_failure.

Поле	После отказа
primary_rows / replica_rows	398 / 576
physical_active_rows	974
readable_rows / unique_ids	576 / 576
all_fields_equal_to_source	True
read_from для part_1	replica/part_1.csv

5. Сравните прогноз с фактом. Для part_1 primary=False, replica=True. Читатель не использует removed или исходник как резерв. События доступны через replica.

Проверка. $576 - 178 = 398$; $398 + 576 = 974$. Недоступна одна основная копия, а не 178 уникальных событий. У part_1 остаётся одна активная исправная копия.

Б3. Восстановите основной раздел

1. Сначала зафиксируйте показатели failure в отчёте. Затем запустите 04_RESTORE.cmd. Альтернатива:

```
py -3 lab.py restore
```

2. Программа проверит реплику по SHA-256 и числу событий, затем скопирует её в primary/part_1.csv. Источником восстановления служит replica, а не removed и не входной CSV.

3. Откройте lab/checks/04_restored.txt. Заполните третью колонку REPORT.

Поле	После восстановления
primary_rows / replica_rows	576 / 576
physical_active_rows	1152
readable_rows / unique_ids	576 / 576
all_fields_equal_to_source	True
read_from для part_1	primary/part_1.csv

4. В Проводнике проверьте, что все три основных CSV снова на месте. Файл в removed остаётся как след моделирования; он не учитывается при чтении и не включается в сдачу.

5. Объясните: восстановление возвращает запас копий. Во время отказа чтение работало, но у первого раздела оставалась только одна исправная активная копия.

Проверка. При сообщении Replica check failed программа не восстанавливает файл. Не заменяйте журнал ожидаемыми числами. Сообщите преподавателю; для повторения используйте новую папку.

Б4. Завершите содержательный отчёт

Ответьте на все поля REPORT своими словами. Числа берите из своих журналов. Общий исходник означает одинаковые контрольные числа, но вывод должен объяснять ваши действия.

Что обязательно объяснить

1. Почему распределение 206 / 178 / 192 неравномерно и что означает правило по user_id.
2. Почему 1152 активные физические записи представляют 576 уникальных событий. Почему нельзя прочитать обе копии как разные данные.
3. Что стало недоступно при отказе, откуда прочитан part_1 и почему чтение сохранилось.
4. Откуда выполнено восстановление, какие проверки ему предшествуют и почему одного количества строк недостаточно.
5. Что произойдёт, если обе копии part_1 недоступны: читатель не получит 178 событий; источник и removed не используются для обхода отказа.
6. Почему папки одного диска не имеют независимых отказов. Чем наша модель отличается от HDFS: локальные CSV по ключу вместо распределённых блоков файлов.
7. Зачем нужны резервные копии состояний, если существуют текущие реплики: ошибочное изменение может затронуть все актуальные копии. В нашем опыте нет автоматической синхронизации и одновременной записи.

Проверка. В итоговом выводе 3–5 предложений: правило → наблюдение отказа → восстановление → проверка → ограничение. Не удаляйте незаполненные вопросы вместо ответа.

Б5–Б6. Соберите и проверьте ZIP

1. Сохраните REPORT.md сочетанием Ctrl+S. Проверьте, что не осталось меток [ЗАПОЛНИТЬ]. Запустите 05_BUILD_RESULT.cmd. Альтернатива:

```
py -3 lab.py package
```

2. Если программа сообщает о незаполненном отчёте, исправьте его, сохраните и повторите 05. Если отсутствует журнал этапа, вернитесь к первому невыполненному шагу.

3. Откройте submission/BigData3_pair2_result.zip. Проверьте содержимое:

Внутри ZIP	Назначение
data/clean_events.csv + lab.py	Вход и код воспроизведения
lab/primary + lab/replica	Основные файлы и копии
lab/manifest.json	Правило и контрольные суммы
lab/checks	TXT и JSON всех четырёх этапов
REPORT.md	Ваши заполненные ответы

4. Откройте REPORT именно из архива и убедитесь, что в него попала последняя версия. После любых изменений отчёта снова запускайте 05.

5. Сохраните рабочую папку и ZIP до проверки преподавателем. Не загружайте результат в неизвестное задание. Ссылка и срок сдачи в ЭОС будут объявлены отдельно.

Проверка. Архив не включает removed, эталоны преподавателя и старые проекты. Автоматическая проверка наличия ответов не оценивает их смысл: перечитайте вывод самостоятельно.

Типовые затруднения

Сообщение или симптом	Действие
Python ... was not found	Откройте DOWNLOADS.html; проверьте среду. При отсутствии прав обратитесь к преподавателю.
lab already exists	01 уже выполнен. Продолжите со следующего шага; для нового опыта извлеките новую папку.
Run 02_REPLICATE.cmd first	Проверьте, что открыт подготовленный проект второй пары.
Failure already simulated	03 уже выполнен. Прочитайте failure и переходите к 04.
Replica check failed	Копия изменена. Восстановление остановлено. Сохраните ошибку и обратитесь за помощью.
Fill every ... field	Заполните все метки в REPORT, сохраните и повторите 05.
Числа отличаются	Найдите первый неверный этап; не правьте CSV, manifest и журналы.
Открылся не тот редактор	Правой кнопкой по TXT/MD/JSON → «Открыть с помощью» → «Блокнот».

Как задать вопрос

Укажите шаг, имя запущенного CMD, полное сообщение и последний успешный журнал. Для ручного запуска откройте CMD через адресную строку именно извлечённой папки проекта.

Повторный 01 не очищает lab. Программа не перезаписывает подозрительный основной файл при восстановлении. Эти остановки защищают состояние опыта; их не нужно обходить вручную.

Критерии и итоговая самопроверка

Критерий	Баллы
Разделы, реплики и журналы всех этапов	0-3
Корректность данных и проверок	0-2
Прогноз и объяснение эксперимента	0-2
Содержательный отчёт и ограничения модели	0-2
Оформление и воспроизводимость	0-1

3 балла за комплект: по одному за основные разделы с manifest, реплики, полный набор журналов. 2 за корректность: один за распределение и итоговые файлы, один за проверки уникальности и всех полей. 2 за опыт: один за прогноз и сопоставление трёх состояний, один за объяснение переключения и восстановления. 2 за отчёт: один за правило и осмысленный вывод, один за ограничения и отличие резервной копии. 1 за читаемый полный ZIP и указанный порядок воспроизведения.

Перед завершением

Есть 3 основных CSV и 3 реплики; размеры 206 / 178 / 192. Сохранены четыре этапа проверки. Таблица REPORT отражает 576 → 398 → 576 основных записей. Доступных уникальных событий во всех трёх состояниях 576. Совпадение всех полей — True.

В отчёте нет пустых ответов; прогноз и результат сопоставлены; объяснены источник восстановления и ограничения одного диска. ZIP открыт, последняя версия отчёта проверена. Рабочая папка сохранена.

Для самостоятельного чтения

Архитектура HDFS:

<https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html>

Контрольные суммы Python: <https://docs.python.org/3/library/hashlib.html>

Копирование файлов Python: <https://docs.python.org/3/library/shutil.html>

В этой работе изучается принцип на малом неизменяемом наборе.

Производительность сети, реальный отказ оборудования и согласованность параллельных записей не проверяются.