Практикум студента

Среднее и повторная обработка

Цель: вычислить общее среднее с правильными весами, обнаружить повтор результата задачи и получить верный итог после контроля повторов.

После объяснения у вас 60 минут самостоятельной работы. Скрипты готовы: программирование с нуля не требуется. Обязательны собственный запуск, ручные расчёты и объяснения в отчёте. Это локальная последовательная модель на Python, без установки Hadoop и без измерения ускорения кластера.

Шаг Б0 — подготовить Windows 10/11

1. Скачайте 03_Стартовый_проект.zip этой пары. В Проводнике выберите «Извлечь всё» и новую папку в Документах. Не работайте прямо внутри ZIP и не распаковывайте поверх старой попытки.

2. Откройте распакованную папку, где рядом лежат lab.py, REPORT.txt и 00_CHECK_ENV.cmd. Дважды щёлкните по 00_CHECK_ENV.cmd. Ожидается Python OK; source rows=576. Нажатие клавиши после чтения закроет окно.

3. Если Python прошлой работы установлен, переустановка не нужна. Требуется Python 3.10 или новее, дополнительные пакеты не нужны. Если Python не найден, откройте DOWNLOADS.html: там официальный источник https://www.python.org/downloads/windows/. Выберите стабильный Python 3 для своей системы; при наличии пункта добавления в PATH включите его. После установки откройте новое окно.

4. Если установка недоступна, сообщите преподавателю. Во время пары выполните ручные расчёты и ответы по примерам; технические этапы завершите позже. Такой отчёт пока неполный. После подготовки среды все вычисления работают без интернета.

Что находится в проекте

data/clean_events.csv — 576 учебных событий; lab.py — программа; REPORT.txt — ваш отчёт. Контрольные JSON-описания нужны для проверки целостности: их не редактируют. results создаётся при запуске, submission — после упаковки. parts и partials уже подготовлены: результаты первой пары переносить не нужно.

Как запускать и читать результаты

Основной способ

Двойной щелчок по соответствующему CMD-файлу. Дождитесь сообщения, прочитайте его, затем нажмите любую клавишу. Помощник сам выбирает папку проекта и Python. Последовательность файлов начинается с 00, заканчивается 05. Не используйте запуск от администратора.

Резервный ручной способ

В Проводнике откройте папку с lab.py. Щёлкните адресную строку, напишите cmd и нажмите Enter. Откроется командная строка Windows уже в этой папке. Введите одну строку и Enter:

```
py -3 lab.py check
```

Если py не найден, но установлен Python, попробуйте:

```
python lab.py check
```

Далее заменяйте слово check на команду шага. Если используете python, во всех командах заменяйте начало py -3 на python. Команды вводятся в командную строку Windows, не в Блокнот, не в Git Bash и не после приглашения Python >>>. Для выхода из >>> введите exit().

Основной и ручной запуск — два способа выполнить один этап. Не запускайте их оба подряд. Символ $ и строки ожидаемого вывода не вводятся. Пути вида results/01_parts.txt обозначают файлы, их нужно открыть в Проводнике через Блокнот.

Если что-то пошло не так

Если cannot open file lab.py — открыта не та папка: вернитесь в Проводник к lab.py и снова откройте cmd. Если окно закрылось, используйте ручной способ, чтобы прочитать сообщение. Если нет Python — подготовьте среду. Если есть ERROR, сохраните полный текст и номер шага, не переходите дальше без разбора.

Браузер или Windows могут блокировать CMD-файлы. Используйте ручной запуск Python из папки проекта; не отключайте системную защиту ради задания. При запрете установки обратитесь к преподавателю.

Как читать JSON

Правой кнопкой по JSON → «Открыть с помощью» → Блокнот. task_id — идентификатор логической задачи, groups — итоги по регионам, count — количество, sum_cents — сумма в копейках. Деление sum_cents на 100 даёт рубли. Формат с точкой в выводе и формат с запятой в тексте обозначают те же десятичные числа.

Б1 Сравнить два средних

Действие

Дважды щёлкните 01_AVERAGES.cmd. Резервная команда в окне cmd из папки проекта:

```
py -3 lab.py averages
```

Затем откройте results/01_averages.txt в Блокноте.

Ожидаемый результат

WRONG_UNWEIGHTED_MEAN=2734.42; CORRECT_WEIGHTED_MEAN=2722.31. Формула: 245008.13 / 90.

Сделайте самостоятельно

Запишите локальные количества, суммы и средние. Объясните, почему весом не могут служить 206, 178 и 192. Решите ручной пример из REPORT.txt: одна покупка на 100 и три на общую сумму 900. Покажите все деления и правильный итог.

Если результат отличается

Run local aggregation first: вероятно, выбран проект первой пары или ZIP извлечён не целиком. Возьмите отдельный стартовый проект второй пары. Нужны готовые parts, partials и manifest-файлы.

Программа считает неверное среднее из неокруглённых локальных средних, а отображает их с двумя знаками. Не восстанавливайте общую сумму из округлённых значений. Нужны исходные суммы и количества.

Б2 Создать повтор результата

Действие

Дважды щёлкните 02_REPEAT.cmd. Резервная команда в окне cmd из папки проекта:

```
py -3 lab.py repeat
```

Затем откройте results/02_repeat.txt в Блокноте.

Ожидаемый результат

FILES=4; UNIQUE_TASKS=3. NAIVE_COUNT=128; NAIVE_AMOUNT=344604.66. В partials появился part_0_retry.json.

Сделайте самостоятельно

Откройте part_0.json и part_0_retry.json в Блокноте. Сравните task_id и содержимое: они одинаковы. Вычислите 90 + 38 и 245008.13 + 99596.53. Объясните, почему получились лишние покупки, хотя исходный CSV не изменён.

Если результат отличается

Repeat experiment already created: повтор уже есть, переходите к Б3. Не удаляйте повтор до проверки guard и safe.

Б3 Зафиксировать ожидаемую остановку

Действие

Дважды щёлкните 03_GUARD.cmd. Резервная команда в окне cmd из папки проекта:

```
py -3 lab.py guard
```

Затем откройте results/03_guard.txt в Блокноте.

Ожидаемый результат

EXPECTED STOP: Duplicate task_id=part_0. Strict reducer refused double counting.

Сделайте самостоятельно

Перепишите сообщение в отчёт. Объясните, почему это полезный отказ строгого объединения. Помощник guard специально перехватывает ожидаемый отказ и завершает свою проверку успешно. Следующий шаг — safe, а не переустановка программы.

Если результат отличается

Run repeat experiment first: выполните Б2. Changed/conflicting partial и Missing expected partial result — другие, непредусмотренные ошибки. Сохраните их и обратитесь к преподавателю.

Б4 Учесть идентичный повтор один раз

Действие

Дважды щёлкните 04_SAFE.cmd. Резервная команда в окне cmd из папки проекта:

```
py -3 lab.py safe
```

Затем откройте results/04_safe.txt в Блокноте.

Ожидаемый результат

IGNORED_IDENTICAL_REPEATS=1; PURCHASES=90; AMOUNT=245008.13; MEAN=2722.31. PASS: every region matches the direct reference.

Сделайте самостоятельно

Сравните значения с неверным итогом Б2. Повторно запустите 04_SAFE.cmd: итог должен остаться прежним. Запишите наблюдение. Объясните разницу между идентичным повтором задачи, конфликтом её результатов и двумя настоящими покупками с одинаковой ценой.

Если результат отличается

Run guard first: сначала Б3. Changed/conflicting partial: файлы расходятся с контрольными описаниями, такой повтор исключать нельзя. Не исправляйте task_id или контрольные суммы вручную.

Дополнительно, если осталось время: откройте lab.py, найдите load_partials и проверки task_id, dataset_sha256 и sha. Объясните, почему одного имени файла для распознавания повтора мало. Код и контрольные описания не изменяйте.

Б5 Отчёт и последующая сдача

Откройте REPORT.txt в Блокноте. Замените все пометки [заполнить] своими наблюдениями. Укажите автора, расчёты, пояснения и затруднения. Ctrl+S сохраняет файл; при «Сохранить как» выберите UTF-8. Проверьте, что файл не назван REPORT.txt.txt.

Включить расширения: Windows 10 → Проводник → «Вид» → «Расширения имён файлов»; Windows 11 → «Вид» → «Показать» → «Расширения имён файлов».

Запустите 05_PACK.cmd. Резервная команда:

```
py -3 lab.py pack
```

Ожидается READY и путь к submission/BigData4_pair2_result.zip. Откройте папку submission и убедитесь, что архив появился.

Архив включает REPORT.txt, исходный CSV, контрольные описания, частичные JSON-результаты и папку results. Не упаковывайте повторно весь стартовый проект вместо результата. Если отчёт не заполнен или этапы не завершены, упаковка выдаст ERROR; сначала исправьте указанную причину.

Сохраните ZIP и рабочую папку локально до проверки. После объявления ссылки и срока загрузите один ZIP в соответствующее задание ЭОС. Если есть кнопка окончательной отправки, нажмите её и убедитесь, что файл принят. Пока раздела нет, отправлять результаты немедленно не требуется.

Критерии — максимум 10 баллов

Верное среднее, формула и ручной учебный пример	2
Повтор результата: четыре файла, три задачи, неверный итог	2
Ожидаемая остановка guard и объяснение причины	2
Правильный safe, повторный запуск и совпадение по регионам	2
Полный отчёт, архив, различение повтора и конфликта	2

По каждому критерию: 2 — выполнено верно и объяснено; 1 — выполнено частично либо объяснение неполное; 0 — отсутствует или неверно. Ручные ответы проверяет преподаватель: сама упаковка не подтверждает их правильность.