Практикум студента

Частичная агрегация данных

Цель: вычислить частичные количества и суммы, объединить их по регионам и проверить каждый регион прямым расчётом.

После объяснения у вас 60 минут самостоятельной работы. Скрипты готовы: программирование с нуля не требуется. Обязательны собственный запуск, ручные расчёты и объяснения в отчёте. Это локальная последовательная модель на Python, без установки Hadoop и без измерения ускорения кластера.

Шаг A0 — подготовить Windows 10/11

1. Скачайте 03_Стартовый_проект.zip этой пары. В Проводнике выберите «Извлечь всё» и новую папку в Документах. Не работайте прямо внутри ZIP и не распаковывайте поверх старой попытки.

2. Откройте распакованную папку, где рядом лежат lab.py, REPORT.txt и 00_CHECK_ENV.cmd. Дважды щёлкните по 00_CHECK_ENV.cmd. Ожидается Python OK; source rows=576. Нажатие клавиши после чтения закроет окно.

3. Если Python прошлой работы установлен, переустановка не нужна. Требуется Python 3.10 или новее, дополнительные пакеты не нужны. Если Python не найден, откройте DOWNLOADS.html: там официальный источник https://www.python.org/downloads/windows/. Выберите стабильный Python 3 для своей системы; при наличии пункта добавления в PATH включите его. После установки откройте новое окно.

4. Если установка недоступна, сообщите преподавателю. Во время пары выполните ручные расчёты и ответы по примерам; технические этапы завершите позже. Такой отчёт пока неполный. После подготовки среды все вычисления работают без интернета.

Что находится в проекте

data/clean_events.csv — 576 учебных событий; lab.py — программа; REPORT.txt — ваш отчёт. Контрольные JSON-описания нужны для проверки целостности: их не редактируют. results создаётся при запуске, submission — после упаковки. parts и partials появятся после первых шагов.

Как запускать и читать результаты

Основной способ

Двойной щелчок по соответствующему CMD-файлу. Дождитесь сообщения, прочитайте его, затем нажмите любую клавишу. Помощник сам выбирает папку проекта и Python. Последовательность файлов начинается с 00, заканчивается 05. Не используйте запуск от администратора.

Резервный ручной способ

В Проводнике откройте папку с lab.py. Щёлкните адресную строку, напишите cmd и нажмите Enter. Откроется командная строка Windows уже в этой папке. Введите одну строку и Enter:

```
py -3 lab.py check
```

Если py не найден, но установлен Python, попробуйте:

```
python lab.py check
```

Далее заменяйте слово check на команду шага. Если используете python, во всех командах заменяйте начало py -3 на python. Команды вводятся в командную строку Windows, не в Блокнот, не в Git Bash и не после приглашения Python >>>. Для выхода из >>> введите exit().

Основной и ручной запуск — два способа выполнить один этап. Не запускайте их оба подряд. Символ $ и строки ожидаемого вывода не вводятся. Пути вида results/01_parts.txt обозначают файлы, их нужно открыть в Проводнике через Блокнот.

Если что-то пошло не так

Если cannot open file lab.py — открыта не та папка: вернитесь в Проводник к lab.py и снова откройте cmd. Если окно закрылось, используйте ручной способ, чтобы прочитать сообщение. Если нет Python — подготовьте среду. Если есть ERROR, сохраните полный текст и номер шага, не переходите дальше без разбора.

Браузер или Windows могут блокировать CMD-файлы. Используйте ручной запуск Python из папки проекта; не отключайте системную защиту ради задания. При запрете установки обратитесь к преподавателю.

Как читать JSON

Правой кнопкой по JSON → «Открыть с помощью» → Блокнот. task_id — идентификатор логической задачи, groups — итоги по регионам, count — количество, sum_cents — сумма в копейках. Деление sum_cents на 100 даёт рубли. Формат с точкой в выводе и формат с запятой в тексте обозначают те же десятичные числа.

A1 Создать разделы

Действие

Дважды щёлкните 01_PARTITION.cmd. Резервная команда в окне cmd из папки проекта:

```
py -3 lab.py partition
```

Затем откройте results/01_parts.txt в Блокноте.

Ожидаемый результат

SOURCE_ROWS=576; part_0: rows=206; part_1: rows=178; part_2: rows=192.

Сделайте самостоятельно

Сложите размеры разделов вручную. Запишите расчёт и ответ в пункт 1 REPORT.txt. Объясните, почему на этом этапе ещё не получено количество покупок.

Если результат отличается

Parts already exist: разделы уже созданы. Если это ваш первый успешный запуск, переходите дальше. Для новой попытки распакуйте новый проект; не удаляйте отдельные файлы наугад.

A2 Получить частичные агрегаты

Действие

Дважды щёлкните 02_LOCAL.cmd. Резервная команда в окне cmd из папки проекта:

```
py -3 lab.py local
```

Затем откройте results/02_local.txt в Блокноте.

Ожидаемый результат

part_0: 38 покупок, 99596.53 руб.; part_1: 27, 79029.15; part_2: 25, 66382.45. Созданы partials/part_0.json, part_1.json, part_2.json.

Сделайте самостоятельно

Запишите фильтр и частичные числа. В Проводнике откройте partials/part_0.json через «Открыть с помощью» → Блокнот. Найдите task_id, groups, count и sum_cents. Объясните назначение каждого поля. Исходный файл не редактируйте.

Если результат отличается

Run partition first или Missing or changed partition: проверьте выполнение A1. Не изменяйте исходный CSV и контрольные описания. Сообщите полный текст ошибки.

A3 Объединить по регионам

Действие

Дважды щёлкните 03_REDUCE.cmd. Резервная команда в окне cmd из папки проекта:

```
py -3 lab.py reduce
```

Затем откройте results/03_reduce.txt в Блокноте.

Ожидаемый результат

Пять регионов. Общий итог: purchases=90; amount=245008.13. Машинный результат: results/aggregate.json.

Сделайте самостоятельно

Перенесите таблицу пяти регионов в отчёт. В трёх partials/part_N.json найдите Херсонскую область: отдельно сложите count и sum_cents. Разделите сумму копеек на 100 и сравните со своей строкой результата. Затем сложите итоги трёх разделов для всего набора.

Если результат отличается

Missing expected partial result: нет одного из трёх результатов. Changed/conflicting partial: файл изменён. Проверьте шаг A2 и работайте с согласованным проектом; не исправляйте манифест ради прохождения проверки.

Подсказка: отсутствие ключа региона в каком-либо частичном результате означало бы нулевой вклад. В данном наборе Херсонская область присутствует во всех трёх результатах. Сначала считайте копейки целыми числами, затем переводите в рубли.

A4 Сверить с исходными данными

Действие

Дважды щёлкните 04_VERIFY.cmd. Резервная команда в окне cmd из папки проекта:

```
py -3 lab.py verify
```

Затем откройте results/04_verify.txt в Блокноте.

Ожидаемый результат

PASS: per-region count and exact sum match direct source. Logical purchases=90; amount=245008.13.

Сделайте самостоятельно

Объясните, почему сравнение всех регионов сильнее проверки одной общей суммы. Откройте lab.py в Блокноте, найдите def summarize и строку с purchase и success. Запишите словами условие отбора. Не изменяйте код.

Если результат отличается

Run reduction first: выполните A3. Aggregate differs from direct reference: итог не совпал; сохраните файлы и сообщение, не подменяйте итог готовым числом.

A5 Отчёт и последующая сдача

Откройте REPORT.txt в Блокноте. Замените все пометки [заполнить] своими наблюдениями. Укажите автора, расчёты, пояснения и затруднения. Ctrl+S сохраняет файл; при «Сохранить как» выберите UTF-8. Проверьте, что файл не назван REPORT.txt.txt.

Включить расширения: Windows 10 → Проводник → «Вид» → «Расширения имён файлов»; Windows 11 → «Вид» → «Показать» → «Расширения имён файлов».

Запустите 05_PACK.cmd. Резервная команда:

```
py -3 lab.py pack
```

Ожидается READY и путь к submission/BigData4_pair1_result.zip. Откройте папку submission и убедитесь, что архив появился.

Архив включает REPORT.txt, исходный CSV, контрольные описания, частичные JSON-результаты и папку results. Не упаковывайте повторно весь стартовый проект вместо результата. Если отчёт не заполнен или этапы не завершены, упаковка выдаст ERROR; сначала исправьте указанную причину.

Сохраните ZIP и рабочую папку локально до проверки. После объявления ссылки и срока загрузите один ZIP в соответствующее задание ЭОС. Если есть кнопка окончательной отправки, нажмите её и убедитесь, что файл принят. Пока раздела нет, отправлять результаты немедленно не требуется.

Критерии — максимум 10 баллов

Разделение: 576 строк сохранены, показаны размеры трёх разделов	2
Частичные количества и суммы, верно указан фильтр	2
Итог по пяти регионам и успешная проверка каждого региона	2
Ручной расчёт одного региона и объяснение ключа группировки	2
Заполненный отчёт, архив и объяснение границ модели	2

По каждому критерию: 2 — выполнено верно и объяснено; 1 — выполнено частично либо объяснение неполное; 0 — отсутствует или неверно. Ручные ответы проверяет преподаватель: сама упаковка не подтверждает их правильность.