Практикум студента

Обработка порциями и контрольная точка

Цель: получить одинаковую агрегацию при полном расчёте и последовательной обработке порциями, воспроизвести остановку до сохранения состояния и продолжить с правильного места.

После объяснения у вас 60 минут самостоятельной работы. Скрипты готовы, писать программу с нуля не требуется. Обязательны собственный запуск, чтение файлов, ручная таблица и пояснения в отчёте. Это последовательная локальная модель на конечном CSV; настоящий поток и Spark не запускаются.

A0 Подготовка Windows 10 и 11

1. Скачайте 03_Стартовый_проект.zip. В Проводнике выберите «Извлечь всё» и новую папку в Документах. Не работайте внутри архива и не распаковывайте поверх прошлой попытки.

2. Откройте папку, в которой рядом лежат lab.py, REPORT.txt, data и 00_CHECK_ENV.cmd. Дважды щёлкните по 00_CHECK_ENV.cmd. Ожидается Python OK; source rows=576. После чтения сообщения нажмите любую клавишу, чтобы закрыть окно.

3. Нужен Python 3.10 или новее. Если он работал в предыдущей практике, переустановка не нужна. Дополнительных библиотек нет. Если Python не найден, откройте DOWNLOADS.html с официальной ссылкой https://www.python.org/downloads/windows/. Выберите стабильный Python 3 для своей Windows и архитектуры; при наличии опции добавления в PATH включите её. После установки заново откройте окно запуска.

4. Если установка недоступна, сообщите преподавателю. Пока выполните ручные расчёты и прогнозы по примерам, затем завершите техническую часть отдельно. Такой результат до завершения запусков считается неполным. После подготовки среды вычисления работают без интернета.

Файлы проекта

data/clean_events.csv — 576 учебных событий; lab.py — программа; REPORT.txt — отчёт. batches содержит порции, results — протоколы и эталон, checkpoint.json — текущее состояние. Эти результаты появятся по мере выполнения. Контрольные описания и исходный CSV вручную не редактируйте.

Запуск команд и чтение результатов

Основной способ

Дважды щёлкайте CMD-файлы по очереди от 00 до 07. Помощник сам выбирает папку проекта и Python. Читайте сообщение до закрытия окна. Открывать CMD-файлы от имени администратора не требуется.

Резервный ручной способ

Откройте папку с lab.py в Проводнике. В адресной строке напишите cmd и нажмите Enter. В появившейся командной строке Windows введите:

```
py -3 lab.py check
```

Если py не найден, попробуйте:

```
python lab.py check
```

Если сработал python, заменяйте начало py -3 на python во всех командах следующих шагов. Команды вводятся в cmd Windows, не в Git Bash, не в Блокнот и не в окно Python >>>. Для выхода из >>> введите exit(). Символ $ и строки ожидаемого вывода не вводятся.

Основной и ручной способы выполняют один и тот же этап. Не запускайте оба подряд. Если cannot open file lab.py — откройте cmd заново из нужной папки. Если оболочка или защита не разрешает CMD-файл, используйте ручную команду; отключать защиту ради практики не требуется.

Просмотр JSON и текстов

Путь results/01_reference.txt означает файл внутри папки results. Откройте его в Блокноте. Для JSON: правая кнопка → «Открыть с помощью» → Блокнот. sum_cents — целая сумма в копейках; деление на 100 даёт рубли. count — число выбранных покупок. Точка в выводе и запятая в русской записи обозначают те же десятичные числа.

Порции нумеруются с нуля. batch_0 — первая, batch_1 — вторая. Порядок совпадает с порядком строк CSV; это не временные окна и не распределение по user_id. При ошибке сохраните сообщение, номер шага и рабочую папку; не подгоняйте checkpoint вручную.

A1 Пакетный эталон и порции

Действие

Дважды щёлкните 01_REFERENCE.cmd. Резервная команда из cmd в папке проекта:

```
py -3 lab.py reference
```

После выполнения откройте results/01_reference.txt в Блокноте.

Ожидаемый результат

576 строк, четыре порции по 144. Вклады покупок 25,24,22,19; эталон 90 / 245008.13. Созданы batches и batch_manifest.json.

Сделайте самостоятельно

Начните ручную таблицу в REPORT.txt: номер порции, количество, сумма и накопленные значения. Сложите четыре количества. Объясните, почему 144 строки не означают 144 покупки.

Если результат отличается

Experiment already started: порции уже созданы. Продолжайте следующими шагами или извлеките новый проект отдельно; не запускайте reference повторно.

A2 Первая контрольная точка

Действие

Дважды щёлкните 02_START.cmd. Резервная команда из cmd в папке проекта:

```
py -3 lab.py start
```

После выполнения откройте results/02_start.txt в Блокноте.

Ожидаемый результат

COMMITTED_BATCH=0; PROCESSED_ROWS=144; PURCHASES=25; AMOUNT=71734.48. NEXT_BATCH=1.

Сделайте самостоятельно

Откройте checkpoint.json в Блокноте. Найдите last_batch, processed_rows и groups. Суммы хранятся в копейках. Запишите соответствующие значения и предскажите, какая порция будет следующей.

Если результат отличается

Run reference first: выполните A1. Checkpoint exists: состояние уже создано; для новой попытки нужна новая папка. Не удаляйте checkpoint отдельно.

A3 Запланированная остановка

Действие

Дважды щёлкните 03_INTERRUPT.cmd. Резервная команда из cmd в папке проекта:

```
py -3 lab.py interrupt
```

После выполнения откройте results/03_interrupt.txt в Блокноте.

Ожидаемый результат

PLANNED STOP; код 2. Кандидат 49 / 131463.19, сохранённое состояние last_batch=0 и 144 строки.

Сделайте самостоятельно

Сравните results/checkpoint_before_stop.json и checkpoint_after_stop.json: они должны совпадать. Сравните их с uncommitted_candidate.json. Объясните, почему кандидат не определяет следующий номер. Не изменяйте checkpoint вручную.

Если результат отличается

Код 2 предусмотрен только этим опытом. Если Planned stop already recorded, переходите к A4. Любой ERROR с другим сообщением сохраните и покажите преподавателю.

uncommitted_candidate.json сохраняется только для наблюдения. Рабочей контрольной точкой остаётся checkpoint.json. Остановка происходит до его обновления. Это управляемое завершение скрипта, а не имитация всех возможных аварий.

A4 Восстановление обработки

Действие

Дважды щёлкните 04_RESUME.cmd. Резервная команда из cmd в папке проекта:

```
py -3 lab.py resume
```

После выполнения откройте results/04_resume.txt в Блокноте.

Ожидаемый результат

RESTORE: last_batch=0; next_batch=1. Затем фиксируются порции 1,2,3: 49 / 131463.19; 71 / 193992.56; 90 / 245008.13.

Сделайте самостоятельно

Проверьте накопленные суммы ручным сложением. Откройте финальный checkpoint: last_batch=3, processed_rows=576. Объясните, почему вторая порция обрабатывалась повторно, но вошла в итог только один раз.

Если результат отличается

Run the planned interrupt experiment first: выполните A3. Missing or changed batch: отсутствует или изменена порция. Checkpoint does not match: состояние не согласовано. Не исправляйте контрольные файлы ради PASS.

A5 Сравнение по регионам

Действие

Дважды щёлкните 05_VERIFY.cmd. Резервная команда из cmd в папке проекта:

```
py -3 lab.py verify
```

После выполнения откройте results/05_verify.txt в Блокноте.

Ожидаемый результат

PASS: batch and micro-batch results match for EVERY region. TOTAL: purchases=90; amount=245008.13. Снимки checkpoint при остановке одинаковы.

Сделайте самостоятельно

Перенесите таблицу пяти регионов в отчёт. Объясните, почему совпадения общей суммы недостаточно. Укажите, какие ограничения остаются у этого опыта.

Если результат отличается

Not all batches are committed: сначала завершите A4. Batch reference changed or missing: пакетный эталон изменён или отсутствует. Сохраните файлы и сообщение, не подгоняйте JSON.

A6 Повтор после завершения

Действие

Дважды щёлкните 06_REPEAT.cmd. Резервная команда из cmd в папке проекта:

```
py -3 lab.py repeat
```

После выполнения откройте results/06_noop.txt в Блокноте.

Ожидаемый результат

NO NEW BATCHES; checkpoint unchanged. PROCESSED_ROWS=576; PURCHASES=90; AMOUNT=245008.13.

Сделайте самостоятельно

Запишите сообщение. Вычислите вручную ошибочный итог при дополнительном прибавлении вклада порции 1. Объясните, почему при отсутствии новых порций ничего прибавлять не нужно.

Если результат отличается

Finish resume before repeat: выполните A4. Повторный resume после завершения также создаёт no-op сообщение; исходный протокол восстановления сохраняется.

Для завершивших раньше: откройте lab.py в Блокноте, найдите функции resume и save_state. Укажите, где обновляются номер порции и группы. Объясните, почему при размере порции 72 вместо 144 изменились бы число порций и номера контрольных точек, но при том же отборе конечный итог должен остаться прежним. Код основной попытки не меняйте.

A7 Отчёт и последующая сдача

В Блокноте откройте REPORT.txt в корне проекта. Замените все пометки [заполнить] своими числами и объяснениями. Заполните автора, ручную таблицу и описание затруднений. Ctrl+S сохраняет файл; при «Сохранить как» выберите UTF-8.

Включите расширения имён: Windows 10 → Проводник → «Вид» → «Расширения имён файлов»; Windows 11 → «Вид» → «Показать» → «Расширения имён файлов». Отчёт должен называться REPORT.txt, а не REPORT.txt.txt.

Запустите 07_PACK.cmd. Резервная команда:

```
py -3 lab.py pack
```

Ожидается READY и путь submission/BigData5_result.zip. Этот ZIP уже сформирован автоматически: упаковывать весь проект вручную не нужно.

Внутри результата находятся REPORT.txt, исходный CSV, описания источника и порций, финальный checkpoint и папка results. Откройте ZIP и убедитесь в наличии отчёта и протоколов. Если упаковка сообщает о незавершённых этапах или незаполненном отчёте, сначала исправьте причину.

Сохраните ZIP и рабочую папку до проверки. После объявления ссылки и срока загрузите один BigData5_result.zip в задание ЭОС. Если предусмотрена отдельная окончательная отправка, нажмите соответствующую кнопку и проверьте, что ответ принят. До создания раздела результаты остаются у вас.

Критерии оценивания

Пакетный эталон и ручная таблица четырёх порций	2
Сохранённая контрольная точка после первой порции	2
Объяснены запланированная остановка и незаписанный результат	2
Восстановление, сравнение всех регионов и повтор без изменений	2
Полный отчёт, объяснение границ модели и архив результата	2

По каждому критерию: 2 — выполнено верно и объяснено; 1 — частично или объяснение неполное; 0 — отсутствует или неверно. Максимум 10 баллов. Автоматическая упаковка не проверяет смысл ответов.