Федеральное государственное бюджетное образовательное учреждение высшего образования
«Херсонский государственный педагогический университет»

Институт информационных технологий

Кафедра программной инженерии и информационных технологий

ПРАКТИЧЕСКАЯ РАБОТА
по дисциплине:
«Системы обработки больших данных»

на тему:
«Обработка порциями и контрольная точка
Временные окна и запоздавшие события»

Выполнил:
Студент гр.: 12-25РПм
Трифонов Д.С.

Проверил
Преподаватель:
Гуцол Д.В.

Оценка:_____
Дата: 27.10.2026

Херсон, 2026

ПРАКТИЧЕСКАЯ РАБОТА

Цель работы

Освоить последовательную обработку больших наборов данных порциями с контрольной точкой и исследовать распределение событий по временным окнам при разных правилах watermark для запоздавших записей. Расчёты выполнены на вымышленных учебных CSV в каталоге app/.

Часть 1. Обработка порциями и контрольная точка

Проект: app/work1_batch. Источник data/clean_events.csv (576 строк), разбиение на 4 порции по 144 строки. Команды: check → reference → start → interrupt → resume → verify → repeat → pack.

Эталон: 90 успешных покупок на сумму 245008.13 руб. (25+24+22+19 по порциям). После start зафиксирована первая порция (25 покупок, 71734.48 руб.). При interrupt порция 1 посчитана в памяти (кандидат 49 / 131463.19), checkpoint не обновлён. Resume довёл обработку до 576 строк; verify подтвердил совпадение агрегатов по пяти регионам.

Практикум 1 — пакетный эталон

```
Практикум 1 — пакетный эталон

ROWS=576
BATCHES=4x144
BATCH_PURCHASES=25, 24, 22, 19
TOTAL_PURCHASES=90
TOTAL_AMOUNT=245008.13
sum_cents=24500813
```

Практикум 1 — запланированная остановка

```
Практикум 1 — запланированная остановка

PLANNED STOP; code 2.
CANDIDATE_PURCHASES=49; CANDIDATE_AMOUNT=131463.19.
SAVED_STATE last_batch=0; PROCESSED_ROWS=144.
```

Практикум 1 — сравнение по регионам

```
Практикум 1 — сравнение по регионам

PASS: batch and micro-batch results match for EVERY region.
R1: checkpoint={'count': 19, 'sum_cents': 5174172} reference={'count': 19, 'sum_cents': 5174172}
R2: checkpoint={'count': 19, 'sum_cents': 5174172} reference={'count': 19, 'sum_cents': 5174172}
R3: checkpoint={'count': 18, 'sum_cents': 4889948} reference={'count': 18, 'sum_cents': 4889948}
R4: checkpoint={'count': 18, 'sum_cents': 4889947} reference={'count': 18, 'sum_cents': 4889947}
R5: checkpoint={'count': 16, 'sum_cents': 4372574} reference={'count': 16, 'sum_cents': 4372574}
TOTAL: purchases=90; amount=245008.13.
```

Часть 2. Временные окна и запоздавшие события

Проект: app/work2_windows. 12 событий с event_time и arrival_time; окна по 5 минут; три политики отставания watermark: 0, 2 и 4 минуты.

Эталон: 10 покупок / 5500.00 руб. strict отклонил E005 и E009 как поздние (4400.00). delay2 принял E005 (4800.00), E009 остался поздним. delay4 принял все покупки (5500.00), два последних окна остаются открытыми.

Практикум 2 — режим strict

```
Практикум 2 — режим strict

POLICY=strict; DELAY_MIN=0
ACCEPTED=8; AMOUNT=4400.00
LATE_IDS=E005,E009
FILTERED_IDS=E004,E006
LAST_WATERMARK=10:16:00
```

Практикум 2 — отставание 2 мин

```
Практикум 2 — отставание 2 мин

POLICY=delay2; DELAY_MIN=2
ACCEPTED=9; AMOUNT=4800.00
LATE_IDS=E009
FILTERED_IDS=E004,E006
LAST_WATERMARK=10:14:00
```

Практикум 2 — сравнение режимов

```
Практикум 2 — сравнение режимов

PASS: each policy follows the rule; accepted + late equals reference.
Mode delay4 matches reference on every closed window.
Open windows remain preliminary.
```

Вывод

Контрольная точка позволяет продолжить потоковую агрегацию без двойного учёта порций. Выбор отставания watermark меняет полноту отчёта: строгий режим недосчитывает опоздавшие события, увеличение допуска восстанавливает эталон, но оставляет часть окон предварительными.

Архивы для сдачи: app/work1_batch/submission/BigData5_result.zip и app/work2_windows/submission/BigData6_result.zip.