

Лекция 3. Линейная регрессия: наименьшие квадраты, абсолютные отклонения, метрики качества

Введение

Задача регрессии является одной из фундаментальных проблем статистики и машинного обучения. Под регрессией понимается предсказание количественной переменной (отклика) на основе наблюдаемых признаков (факторов). В отличие от классификации, где результатом работы модели является дискретная метка класса, регрессия ориентирована на непрерывные значения. Именно поэтому методы регрессии столь широко применяются в экономике, технике, медицине и социальных науках: необходимо прогнозировать цены на рынке недвижимости, уровень спроса на товар, изменение физиологических показателей у пациента или параметры технологического процесса.

Среди множества методов регрессии особое место занимает линейная регрессия. Она представляет собой простейшую, но в то же время чрезвычайно полезную модель, в которой предполагается, что зависимость отклика y от признаков $x_1, x_2, \dots, x_d$ можно аппроксимировать линейной комбинацией этих признаков:

$$\hat{y}(x) = w_0 + \sum_{j=1}^d w_j x_j$$

Несмотря на кажущуюся ограниченность, линейная модель обладает целым рядом преимуществ. Во-первых, она интерпретируема: коэффициенты модели напрямую показывают вклад каждого признака в итоговое предсказание. Во-вторых, линейная регрессия имеет прозрачную математическую основу, позволяющую глубоко проанализировать свойства оценок и обосновать статистические выводы. Наконец, она является естественной отправной точкой для перехода к более сложным моделям — от полиномиальных регрессий до современных нейросетей.

Исторически линейная регрессия возникла задолго до появления машинного обучения. Уже в XIX веке К. Гаусс и А.-М. Лежандр разработали метод наименьших квадратов, который позволяет оценивать параметры линейной модели, минимизируя сумму квадратов ошибок:

$$L(w) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Этот метод до сих пор остается одним из краеугольных камней статистики, а его геометрическая интерпретация в терминах проекции вектора наблюдений на линейное подпространство делает его особенно наглядным для понимания.

Современное машинное обучение расширяет и углубляет классические идеи регрессии. Помимо метода наименьших квадратов, активно используются альтернативные подходы, например минимизация суммы абсолютных отклонений:

$$L(w) = \sum_{i=1}^n |y_i - \hat{y}_i|$$

Эта функция потерь обладает устойчивостью к выбросам. Также разработаны различные метрики качества регрессии: среднеквадратичная ошибка (MSE), средняя абсолютная ошибка (MAE), корень из среднеквадратичной ошибки (RMSE), коэффициент детерминации (R^2). Эти показатели позволяют количественно оценивать, насколько хорошо модель описывает данные и прогнозирует новые наблюдения.

Таким образом, изучение линейной регрессии выполняет сразу несколько задач. Оно дает студентам инструмент для решения реальных прикладных проблем, формирует понимание ключевых статистических принципов и подготавливает базу для освоения более сложных моделей машинного обучения. Именно поэтому линейная регрессия традиционно занимает центральное

место в курсе и рассматривается как «первый шаг» в мире предсказательного моделирования.

2. Линейная модель

Линейная модель устанавливает аппроксимационную зависимость между количественным откликом и вектором признаков, предполагая аддитивность вкладов отдельных компонентов. В скалярной записи это выражается формулой:

$$\hat{y}(x) = w_0 + \sum_{j=1}^d w_j x_j.$$

Здесь w_0 — свободный член (сдвиг), а коэффициенты w_j количественно отражают предельное влияние признака x_j на прогноз при прочих равных: $\partial \hat{y} / \partial x_j = w_j$. Такая трактовка обеспечивает интерпретируемость и делает линейную регрессию базовым инструментом прикладного анализа.

Удобно использовать векторно-матричную запись. Для набора из n наблюдений определим дизайн-матрицу $X \in \mathbb{R}^{n \times d}$ со строками $x_i^\top$ и вектор ответов $y \in \mathbb{R}^n$. Тогда предсказания модели при фиксированных параметрах $w \in \mathbb{R}^d$ записываются как $\hat{y} = Xw$. Чаше свободный член включают в модель добавлением столбца единиц: $\tilde{x} = [1; x]$, $\tilde{w} = [w_0; w]$, $\tilde{X} = [1; X]$, и тогда $\hat{y} = \tilde{X}\tilde{w}$. Такое переписывание упрощает выводы и реализацию алгоритмов обучения.

Качество параметризации существенно зависит от предварительной обработки признаков. Стандартизация и центрирование уменьшают различие масштабов, стабилизируют численные процедуры и облегчают интерпретацию:

$\tilde{x}_j = (x_j - \mu_j) / s_j$, где μ_j — среднее, s_j — масштаб (например, стандартное отклонение). Если признаки имеют разную размерность (рубли, метры, часы), масштабирование предотвращает доминирование крупноизмеряемых признаков и повышает устойчивость оценок.

Категориальные переменные кодируются индикаторами (one-hot). Пусть категориальный признак имеет K уровней; тогда вводятся бинарные столбцы $z_1, \dots, z_K \in \{0, 1\}$ с ограничением $\sum_{k=1}^K z_k = 1$. Чтобы избежать «ловушки фиктивной переменной» (линейной зависимости столбцов), один из индикаторов опускают (или исключают свободный член). Коэффициенты при индикаторах интерпретируются как сдвиг прогноза относительно базовой категории.

Выразительность линейной модели можно расширять через набор признаков (feature engineering). Полиномиальные и взаимодействующие члены сохраняют линейность по параметрам, оставаясь в классе линейных моделей: например, добавление x_j^2 или произведений $x_p x_q$ приводит к модели вида $\hat{y}(x) = w_0 + \sum_j w_j x_j + \sum_j u_j x_j^2 + \sum_{p < q} v_{pq} x_p x_q$, которая всё ещё линейна по вектору параметров $\theta = (w, u, v)$. Такой подход повышает аппроксимирующую способность без перехода к нелинейной оптимизации по параметрам.

Важным условием корректной идентификации модели является полноранговость дизайн-матрицы: $\text{rank}(X) = d$ (или $\text{rank}(\tilde{X}) = d + 1$ при явном свободном члене). При мультиколлинеарности (линейной зависимости столбцов) решение параметров перестаёт быть единственным, а дисперсии оценок растут; численно это проявляется в большом числе обусловленности $\kappa(X^\top X)$ и нестабильности коэффициентов при малых изменениях выборки. Практические меры включают удаление или агрегацию коррелированных признаков, ортогонализацию, а также регуляризацию (будет рассмотрена далее).

С точки зрения применения модель используется для прогнозирования на новых объектах. Для нового вектора признаков x получаем детерминированный прогноз $\hat{y} = w_0 + w^\top x = \tilde{w}^\top \tilde{x}$. Если совместно предположить стохастическую структуру шума ε (например, нулевое среднее и конечную дисперсию), то линейная модель выступает детерминированным ядром генеративной схемы $y = w_0 + w^\top x + \varepsilon$, а задача обучения сводится к оцениванию параметров по обучающей выборке.

Итак, линейная модель — это прозрачная, интерпретируемая и вычислительно удобная основа для регрессии. Её сила — в линейности по параметрам, что позволяет проводить строгие выводы, легко расширять базис признаков и интегрировать модель в более сложные ансамбли и источники информации анализа данных.

3. Метод наименьших квадратов (OLS)

Метод наименьших квадратов (Ordinary Least Squares, OLS) является базовым способом оценки параметров линейной регрессии и играет ключевую роль как в классической статистике, так и в машинном обучении. Идея метода восходит к работам К. Гаусса и А.-М. Лежандра начала XIX века. Она заключается в том, что оптимальными считаются такие коэффициенты модели, которые минимизируют суммарное квадратичное отклонение предсказаний от наблюдаемых данных.

Пусть заданы наблюдения $\{(x_i, y_i)\}_{i=1}^n$, где $x_i \in \mathbb{R}^d$ — вектор признаков, $y_i \in \mathbb{R}$ — отклик. Линейная модель имеет вид:

$$\hat{y}_i = w_0 + w^\top x_i.$$

В матричной записи:

$$\hat{y} = Xw,$$

где $X \in \mathbb{R}^{n \times d}$ — матрица признаков, $w \in \mathbb{R}^d$ — вектор коэффициентов.

Если учитывать свободный член w_0 , то используют расширенную матрицу $\tilde{X}$ с добавленным столбцом единиц и параметр $\tilde{w}$.

Метод наименьших квадратов выбирает w так, чтобы минимизировать функцию потерь (сумму квадратов остатков):

$$L(w) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \|y - Xw\|_2^2.$$

Для нахождения минимума берём градиент функции потерь по параметрам w и приравниваем его к нулю:

$$\nabla_w L(w) = -2X^\top (y - Xw) = 0.$$

Отсюда получаем систему нормальных уравнений:

$$X^\top Xw = X^\top y.$$

При условии, что матрица $X^\top X$ невырождена (полный ранг признаков), решение имеет явный вид:

$$w^* = (X^\top X)^{-1} X^\top y.$$

Таким образом, OLS обеспечивает аналитическую формулу для оценки параметров. Однако на практике это решение может быть численно неустойчивым при высокой корреляции признаков, поэтому используют численные методы (QR-разложение, SVD).

Геометрическая интерпретация OLS заключается в следующем: вектор наблюдений y проецируется ортогонально на линейное подпространство, натянутое на столбцы матрицы X . Вектор предсказаний $\hat{y} = Xw^*$ принадлежит этому подпространству, а вектор остатков $r = y - \hat{y}$ ортогонален ему. Это записывается как:

$$X^{\top} r = 0.$$

Иными словами, ошибки модели ортогональны каждому признаку. Этот факт делает метод наименьших квадратов теоретически обоснованным и позволяет строить статистические выводы.

Среди достоинств OLS можно выделить: простоту, наличие явного решения, интерпретируемость коэффициентов. Однако метод имеет и ограничения. Во-первых, он чувствителен к выбросам: одно аномальное наблюдение может существенно исказить оценки. Во-вторых, мультиколлинеарность признаков приводит к большой дисперсии оценок и нестабильности решения. В-третьих, в задачах с очень высокой размерностью прямое вычисление обратной матрицы $(X^{\top} X)^{-1}$ становится неэффективным и заменяется более устойчивыми алгоритмами.

Тем не менее, метод наименьших квадратов остаётся центральным инструментом анализа данных. Он служит отправной точкой для понимания более сложных моделей: взвешенного МНК, робастных методов, регуляризованных оценок (ридж-регрессия, лассо). Поэтому освоение OLS имеет фундаментальное значение для подготовки специалистов в области машинного обучения и прикладной статистики.




Рис. 1. Геометрическая интерпретация OLS — проекция вектора y на подпространство $Col(X)$




Рис. 2. Сравнение аппроксимации данных прямой с учётом и без учёта выбросов

4. Метод минимизации абсолютных отклонений (MAE)

Метод минимизации абсолютных отклонений (Mean Absolute Error, MAE) является альтернативой классическому методу наименьших квадратов и представляет собой более робастный подход к оценке параметров линейной регрессии. В отличие от квадратичной функции потерь, усиливающей влияние крупных ошибок, метод MAE минимизирует сумму модулей отклонений предсказанных значений от наблюдаемых.

Пусть заданы наблюдения $\{(x_i, y_i)\}_{i=1}^n$, где $x_i \in \mathbb{R}^d$, $y_i \in \mathbb{R}$. Линейная модель записывается в стандартном виде:

$$\hat{y}_i = w_0 + w^\top x_i.$$

Функция потерь метода минимизации абсолютных отклонений имеет вид:

$$L(w) = \sum_{i=1}^n |y_i - \hat{y}_i|.$$

В отличие от метода наименьших квадратов, здесь не происходит возведения ошибки в квадрат, что делает метод менее чувствительным к выбросам. Геометрически это соответствует минимизации L1-нормы вектора остатков:

$$L(w) = \|y - Xw\|_1.$$

Для одномерной регрессии можно показать, что решение задачи МАЕ связано с выбором медианы распределения ошибок. В частности, если рассматривать модель вида $y_i = w_0 + \varepsilon_i$, то оценка w_0 по критерию МАЕ совпадает с выборочной медианой y_i . Это свойство объясняет робастность метода: медиана устойчива к отдельным аномально большим значениям.

Задача минимизации суммы модулей ошибок не имеет простого аналитического решения в общем случае. В многомерной постановке она сводится к задаче линейного программирования. Типичная постановка формулируется так:

$$\min_{w, \xi_i^+, \xi_i^-} \sum_{i=1}^n (\xi_i^+ + \xi_i^-),$$

при условиях

$$y_i - w^\top x_i \leq \xi_i^+, \quad w^\top x_i - y_i \leq \xi_i^-, \quad \xi_i^+, \xi_i^- \geq 0.$$

Здесь ξ_i^+ и ξ_i^- — дополнительные переменные, описывающие положительные и отрицательные отклонения. Такая формулировка позволяет решать задачу с помощью стандартных методов линейного программирования.

Основные свойства метода МАЕ:

- Робастность к выбросам: единичный экстремальный объект не оказывает значительного влияния на оценку.

- Интерпретация через медиану ошибок.
- Отсутствие аналитического решения в многомерном случае — требуется численная оптимизация.

Сравнение с методом наименьших квадратов показывает, что выбор функции потерь оказывает значительное влияние на характер аппроксимации. MSE стремится «подтянуть» модель к выбросам, тогда как MAE игнорирует их сильное влияние и формирует более устойчивую прямую. Именно поэтому MAE часто применяется при наличии шумных или загрязнённых данных.

Ограничения метода связаны с тем, что оптимизация L1-нормы вычислительно сложнее: отсутствует замкнутая формула, алгоритмы медленнее сходятся, чем в случае квадратичной функции потерь. Тем не менее современные численные методы и средства оптимизации позволяют эффективно применять MAE даже для больших выборок.

В заключение отметим, что метод минимизации абсолютных отклонений служит важным дополнением к методу наименьших квадратов. Он демонстрирует иной взгляд на проблему аппроксимации, подчеркивая значимость выбора функции потерь в зависимости от структуры данных. В дальнейшем MAE становится основой для построения более сложных робастных и регуляризованных методов регрессии.

Рис. 1. Сравнение регрессии MSE и MAE на данных с выброс




Рис. 1. Сравнение линий регрессии по критериям MSE и MAE на данных с выбросами




Рис. 2. Иллюстрация медианы как оптимальной оценки при MAE

5. Метрики качества регрессии

Оценка качества регрессионной модели является ключевым этапом анализа данных. Даже если модель хорошо аппроксимирует обучающую выборку, важно количественно измерить её точность и способность к обобщению. Для этого применяются специальные метрики, позволяющие сопоставлять различные алгоритмы и интерпретировать полученные результаты.

Среднеквадратичная ошибка (Mean Squared Error, MSE):

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Корень СКО (Root Mean Squared Error, RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

Средняя абсолютная ошибка (Mean Absolute Error, MAE):

$$L(w) = \sum_{i=1}^n |y_i - \hat{y}_i|.$$

Коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Интерпретация метрик:

- MSE/RMSE — чувствительны к выбросам, удобны для оптимизации.
- MAE — робастна к выбросам, легко интерпретируется.
- R^2 — относительная мера качества, показывает долю объяснённой дисперсии.

Пример расчёта ($y = [3, 5, 7]$, $\hat{y} = [2.5, 5.5, 6]$):

$$MSE = 0.5, RMSE \approx 0.707, MAE = 0.667, R^2 = 0.875.$$

Таблица: Сравнение метрик качества регрессии

Метрика	Формула	Свойства	Интерпретация
MSE	$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$	Чувствительна к выбросам, удобна для оптимизации	Средний квадрат ошибки в условных единицах
RMSE	$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$	Та же чувствительность, измеряется в тех же единицах, что и y	Среднее отклонение прогноза от истинного значения
MAE	$\frac{1}{n} \sum y_i - \hat{y}_i $	Робастна к выбросам, линейное измерение ошибок	Средняя ошибка предсказания в исходных единицах
R^2	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Относительная мера, зависит от дисперсии выборки	Доля объяснённой дисперсии отклика

6. Сравнение методов: OLS и MAE

Рассмотрим сравнение двух ключевых методов оценки параметров линейной регрессии: метода наименьших квадратов (Ordinary Least Squares, OLS) и метода минимизации абсолютных отклонений (Mean Absolute Error, MAE). Сопоставление этих методов важно, поскольку выбор функции потерь напрямую определяет свойства модели, её устойчивость к шуму и выбросам, а также применимость в конкретных задачах.

Аналитические различия между методами начинаются с функций потерь. Для OLS используется квадратичная функция:

$$L_{\text{MSE}}(w) = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Для MAE, напротив, используется сумма модулей ошибок:

$$L_{\text{MAE}}(w) = \sum_{i=1}^n |y_i - \hat{y}_i|.$$

OLS усиливает влияние крупных ошибок за счёт возведения их в квадрат, что делает метод чувствительным к выбросам. Однако при нормальном распределении ошибок и отсутствии значительных аномалий OLS обеспечивает наилучшие статистические свойства и является несмещённым и эффективным оценщиком (теорема Гаусса–Маркова). MAE, напротив, снижает влияние выбросов, так как все ошибки учитываются линейно. В результате модель остаётся устойчивой при наличии загрязнённых данных или распределений с тяжёлыми хвостами.

С точки зрения решения задачи методы также различаются. Для OLS градиент функции потерь имеет вид:

$$\nabla_w L(w) = -2X^T (y - Xw),$$

и приводит к системе нормальных уравнений:

$$X^{\top} X w = X^{\top} y.$$

Отсюда аналитическое решение:

$$w^* = (X^{\top} X)^{-1} X^{\top} y.$$

Таким образом, OLS имеет замкнутую формулу для коэффициентов. В отличие от него, MAE не допускает аналитического решения в многомерном случае. Оптимизация сводится к задаче линейного программирования с дополнительными переменными, что делает процесс вычислительно более затратным.

Геометрическая интерпретация методов также различается. OLS соответствует ортогональной проекции вектора наблюдений y на линейное подпространство признаков $\text{Col}(X)$ в смысле L2-нормы. Вектор ошибок при этом ортогонален каждому признаку. MAE можно рассматривать как аппроксимацию в L1-норме, где минимизируется сумма абсолютных расстояний. Это приводит к иному положению регрессионной гиперплоскости, более ориентированному на медианные свойства данных.

Практическое применение методов зависит от конкретной задачи. OLS применяется в экономике, инженерии и социальных науках, когда данные относительно чистые, а важна вычислительная скорость. MAE востребован в задачах, связанных с шумными данными, аномалиями и асимметричными распределениями, например, в обработке финансовых данных или анализе социальных процессов.

Заключая, отметим, что OLS и MAE представляют собой два фундаментальных подхода к линейной регрессии. OLS удобен и эффективен в условиях классических предположений, MAE же демонстрирует робастность и обеспечивает надёжные оценки в сложных эмпирических ситуациях. Выбор метода должен определяться характеристиками данных и целями анализа.

7. Применение линейной регрессии

Линейная регрессия является одной из наиболее универсальных и широко используемых моделей как в прикладной статистике, так и в машинном обучении. Благодаря своей простоте, интерпретируемости и вычислительной эффективности она находит применение в самых разных областях науки и практики.

В экономике линейная регрессия используется для прогнозирования цен и спроса на товары и услуги. Например, модель может оценивать влияние уровня дохода населения, инфляции и сезонных факторов на объём продаж. Формально прогноз задаётся выражением:

$$\hat{y} = w_0 + \sum_{j=1}^d w_j x_j,$$

где y — цена или спрос, а x_j — набор объясняющих переменных (доход, цена конкурента, индекс инфляции и др.).

В социальных науках линейная регрессия применяется для выявления зависимостей между характеристиками населения. Например, модель может описывать, как уровень образования и возраст влияют на доход. Интерпретируемость коэффициентов делает регрессию удобным инструментом для социологических и демографических исследований.

В медицине регрессионный анализ используется для оценки факторов риска и прогноза показателей здоровья пациентов. Так, можно исследовать зависимость артериального давления от возраста, массы тела и уровня физической активности. При этом величина коэффициента w_j показывает, насколько

изменяется прогнозируемый показатель при изменении соответствующего признака на единицу.

В инженерии линейная регрессия находит применение в задачах контроля качества и прогнозирования характеристик продукции. Примером может служить моделирование зависимости прочности материала от температуры и времени обработки. В этих случаях регрессионная модель позволяет заранее оценивать поведение системы и принимать оптимальные решения.

В машинном обучении линейная регрессия используется как базовая модель, служащая отправной точкой для сравнения с более сложными алгоритмами. Она помогает оценить, насколько существенное улучшение дают методы регуляризации или нелинейные модели. Кроме того, линейная регрессия входит в состав ансамблей и сложных систем в качестве отдельного компонента.

Рассмотрим иллюстративный пример. Пусть необходимо спрогнозировать цену квартиры на основе её площади, этажа и района. Модель имеет вид:

$$\hat{y} = w_0 + w_1 \cdot \text{Площадь} + w_2 \cdot \text{Этаж} + w_3 \cdot \text{Район}.$$

Если $w_1 = 50$, это означает, что при увеличении площади на один квадратный метр прогнозируемая цена увеличивается в среднем на 50 условных единиц, при фиксированных остальных факторах. Аналогично, коэффициенты w_2 и w_3 описывают влияние этажа и района соответственно.

Несмотря на универсальность, линейная регрессия имеет ограничения. Она предполагает линейную зависимость между переменными, что не всегда соответствует реальности. При высокой корреляции признаков (мультиколлинеарности) оценки коэффициентов становятся нестабильными. Кроме того, выбросы в данных могут существенно исказить результаты. Эти ограничения частично преодолеваются с помощью методов регуляризации (ридж-регрессия, лассо) и робастных подходов.

Закljučая, отметим: линейная регрессия — это фундаментальный инструмент анализа данных, который сочетает простоту и объяснимость с достаточной мощностью для решения широкого спектра прикладных задач. Она служит основой для понимания более сложных моделей и остаётся незаменимой в практике анализа данных.




Рис. 1. Пример зависимости цены квартиры от её площади

Выводы по лекции

В ходе лекции была рассмотрена линейная регрессия — фундаментальная модель машинного обучения и прикладной статистики. Основное внимание было уделено формулировке задачи регрессии, построению линейной модели, методам оценки параметров и метрикам качества.

Линейная регрессия основана на предположении, что зависимость между откликом и признаками может быть аппроксимирована линейной комбинацией последних. Простота модели обеспечивает её высокую интерпретируемость: каждый коэффициент напрямую показывает вклад соответствующего признака в итоговое предсказание. Благодаря этому линейная регрессия активно применяется в экономике, медицине, инженерии и социальных науках.

Ключевым методом оценки параметров выступает метод наименьших квадратов (OLS), обладающий аналитическим решением и геометрической интерпретацией через ортогональную проекцию. Его достоинствами являются простота, эффективность и хорошие статистические свойства при классических предположениях о нормальности и гомоскедастичности (свойство, означающее постоянство условной дисперсии вектора или последовательности случайных величин) ошибок. В то же время метод чувствителен к выбросам и нестабилен при мультиколлинеарности.

Альтернативой OLS является метод минимизации абсолютных отклонений (MAE). Он не имеет простого аналитического решения, но демонстрирует устойчивость к выбросам и может рассматриваться как более робастный инструмент. Геометрически этот метод соответствует минимизации L1-нормы ошибок и тесно связан с медианными свойствами распределений.

Оценка качества регрессионных моделей проводится с использованием метрик. Были рассмотрены среднеквадратичная ошибка (MSE), её корень (RMSE), средняя абсолютная ошибка (MAE) и коэффициент детерминации R^2 . Каждая метрика имеет собственную интерпретацию и область применения: MSE и RMSE акцентируют внимание на больших ошибках, MAE устойчив к выбросам, а R^2 позволяет оценить долю объяснённой дисперсии и служит удобным инструментом для сравнения моделей.

Сравнение OLS и MAE показало, что выбор функции потерь существенно влияет на свойства модели. OLS предпочтителен в «чистых» данных, где

ошибки близки к нормальным, а вычислительная эффективность играет ключевую роль. MAE же оправдан в случаях с шумными и загрязнёнными выборками, где важна устойчивость к аномалиям.

Применение линейной регрессии охватывает широкий спектр практических задач: прогнозирование цен, анализ факторов риска, моделирование технологических процессов, социальные исследования. Несмотря на ограничения, линейная регрессия остаётся фундаментальной моделью, формирующей основу для понимания и развития более сложных алгоритмов машинного обучения.

Таким образом, лекция заложила теоретическую и практическую базу для работы с линейными моделями, показала роль функции потерь в формировании свойств оценок и продемонстрировала, как метрики качества позволяют объективно оценивать предсказательную силу моделей.

Контрольные вопросы по лекции

1. В чём состоит задача регрессии и чем она отличается от задачи классификации?
2. Как формулируется линейная модель регрессии в общем виде?
3. Какова роль свободного члена w_0 в линейной регрессии?
4. Что называют дизайн-матрицей X и как она формируется?
5. В чём заключается метод наименьших квадратов (OLS)?
6. Запишите нормальные уравнения для метода наименьших квадратов.
7. Каково аналитическое решение задачи OLS и при каких условиях оно существует?
8. Какова геометрическая интерпретация метода OLS?
9. Почему метод наименьших квадратов чувствителен к выбросам?
10. Сформулируйте функцию потерь для метода минимизации абсолютных отклонений (MAE).
11. В чём состоит основное преимущество MAE по сравнению с OLS?

12. Почему задача MAE в многомерном случае сводится к задаче линейного программирования?
13. Какие метрики качества регрессии вы знаете? Приведите их формулы.
14. Что показывает коэффициент детерминации R^2 и как его интерпретировать?
15. В каких практических ситуациях целесообразно использовать OLS, а в каких — MAE?